

Mění se vztah mezi dvěma znaky podle skupiny?

Interakce číselného a skupinového znaku i dvou skupinových znaků

22. září 2026

Obsah

1 Liší se vztah délky a zadní šířky krunýře mezi samicemi a samci?	1
2 Kdy předpovídají dvě přímky stejný sklon?	2
3 Co se v této lekci naučíte	2
4 Jeden řádek tabulky představuje jednoho kraba	2
5 Které délky a šířky jsou v datech zastoupené?	3
6 Jak souvisí délka a zadní šířka krunýře?	4
7 Rovnoběžné přímky předpokládají společný sklon	5
8 Mění se rozdíl mezi samicemi a samci s délkou krunýře?	6
9 Model s interakcí dovoluje samicím a samcům různé sklony	7
10 Co model předpovídá pro stejně dlouhou samici a samce?	8
11 Co znamenají koeficienty modelu s interakcí?	9
12 Jak dobře přímky popisují naměřené kraby?	12
13 Liší se rozdíl v délce krunýře mezi pohlavími u obou barevných forem?	14
14 Jaké délky krunýře vidíme ve čtyřech skupinách?	15
15 Jak model zachytí změnu rozdílu mezi pohlavími podle formy?	16
16 Co znamenají čtyři koeficienty modelu se dvěma skupinovými znaky?	18
17 Co o jednotlivých krabech čtyři průměry neříkají?	21
18 Kdy potřebujeme při výkladu modelu uvést další prediktor?	21

1 Liší se vztah délky a zadní šířky krunýře mezi samicemi a samci?

Představte si dva kraby se stejně dlouhým krunýřem, jednoho samce a jednu samici. Musí mít stejně širokou zadní část krunýře? A bude případný rozdíl stejný u kratších i delších krabů? To je otázka **vztahu dvou měřených znaků v různých skupinách**, nikoli otázka, které pohlaví je obecně větší.

Zadní šířku budeme odhadovat z délky krunýře a pohlaví. Data jsou pozorovací: samotný rozdíl mezi skupinami nám neřekne, co jej způsobilo.

2 Kdy předpovídají dvě přímky stejný sklon?

V minulé lekci jste viděli model se dvěma prediktory: číselným znakem a skupinou. Jeho dvě předpovědní přímky byly rovnoběžné. Jak se podle takového modelu změní rozdíl mezi skupinami, když se číselný prediktor zvětší?

Vybavte si minulou lekci

Nakreslete dvě rovnoběžné přímky. Vyberte na ose x dvě různé hodnoty. Je svislá vzdálenost mezi přímkami v obou místech stejná?

Ano. Rovnoběžné přímky mají společný sklon, takže jejich svislá vzdálenost zůstává stejná. Teď zkusíme zjistit, zda takové omezení dává smysl i pro kraby.

3 Co se v této lekci naučíte

Po přečtení dokážete:

1. poznat otázku, v níž se vztah číselného znaku a odezvy mění podle skupiny, i otázku, v níž se rozdíl mezi dvěma skupinami mění podle další skupiny;
2. odhadnout a zobrazit jednoduchý lineární model pro oba typy interakce;
3. vyložit všechny koeficienty obou modelů pomocí předpovědi a určit, jak jejich význam závisí na délce nebo skupině;
4. porovnat předpovědi při stejné délce nebo uvnitř téže barevné formy a uvést, co z pozorovacích dat nelze vyvozovat.

4 Jeden řádek tabulky představuje jednoho kraba

Použijeme měření krabů z práce Campbell a Mahon (1974), zpřístupněná v datové sadě `MASS::crabs`. Zaměříme se na jedince modré barevné formy (`sp == "B"`). Jeden řádek znamená **jednoho změřeného kraba**, ne opakované měření téhož jedince. Sloupec `CL` označuje délku krunýře, `RW` šířku jeho zadní části; obě hodnoty jsou v milimetrech. `sex` označuje pohlaví (`F` pro samici, `M` pro samce). Délka a zadní šířka jsou dvě různé osy téhož krunýře.

```
# Vybereme modrou barevnou formu a tři znaky potřebné pro otázku
data_krabi <- MASS::crabs[MASS::crabs$sp == "B", c("sex", "CL", "RW")]

# Přejmenujeme sloupce podle toho, co znamenají
names(data_krabi) <- c("pohlavi", "delka_krunyre_mm", "zadni_sirka_mm")
data_krabi$pohlavi <- factor(
  x = data_krabi$pohlavi,
  levels = c("F", "M"),
  labels = c("samice", "samec")
)
```

```
# Každý řádek tabulky patří jednomu krabovi
head(x = data_krabi, n = 6)
```

	pohlavi	delka_krunyre_mm	zadni_sirka_mm
1	samec	16.1	6.7
2	samec	18.1	7.7
3	samec	19.0	7.8
4	samec	20.1	7.9
5	samec	20.3	8.0
6	samec	23.0	9.0

Původ a dosah dat

Campbell, N. A. a R. J. Mahon (1974): A multivariate study of variation in two species of rock crab of the genus *Leptograpsus*. *Australian Journal of Zoology* 22, 417–425. Datová sada je součástí balíčku MASS (?MASS::crabs). Popis zdroje nedokládá náhodný výběr ze všech krabů; naše závěry proto vztahujeme k těmto měřením, ne automaticky k celé populaci.

5 Které délky a šířky jsou v datech zastoupené?

Před modelem zkontrolujeme typy proměnných, chybějící hodnoty a rozsahy. To nám také ukáže, při jakých délkách má smysl porovnávat předpovědi obou pohlaví.

```
# Ověříme typy sloupců a chybějící hodnoty
str(object = data_krabi)
```

```
'data.frame': 100 obs. of 3 variables:
 $ pohlavi      : Factor w/ 2 levels "samice","samec": 2 2 2 2 2 2 2 2 2 2 ...
 $ delka_krunyre_mm: num 16.1 18.1 19 20.1 20.3 23 23.8 24.5 24.2 25.2 ...
 $ zadni_sirka_mm : num 6.7 7.7 7.8 7.9 8 9 9.9 9.1 9.6 10.5 ...
```

```
colSums(x = is.na(data_krabi))
```

pohlavi	delka_krunyre_mm	zadni_sirka_mm
0	0	0

```
# Rozdělíme kraby podle pohlaví a prohlédneme každou skupinu zvlášť
data_samice <- data_krabi[data_krabi$poohlavi == "samice", ]
```

```
data_samci <- data_krabi[data_krabi$pohlavi == "samec", ]
summary(object = data_samice)
```

pohlavi	delka_krunyre_mm	zadni_sirka_mm
samice:50	Min. :14.70	Min. : 6.50
samec : 0	1st Qu.:23.93	1st Qu.:10.62
	Median :27.90	Median :12.20
	Mean :28.10	Mean :12.14
	3rd Qu.:32.75	3rd Qu.:13.88
	Max. :40.90	Max. :16.90

```
summary(object = data_samci)
```

pohlavi	delka_krunyre_mm	zadni_sirka_mm
samice: 0	Min. :16.10	Min. : 6.70
samec :50	1st Qu.:27.23	1st Qu.:10.65
	Median :32.45	Median :11.70
	Mean :32.01	Mean :11.72
	3rd Qu.:37.15	3rd Qu.:13.28
	Max. :47.10	Max. :15.80

V souboru je 100 krabů, z toho 50 samic a 50 samců. V těchto třech sloupcích chybí 0 hodnot. Délka krunýře samic sahá od 14.7 do 40.9 mm, u samců od 16.1 do 47.1 mm. Obě skupiny tedy mají společný rozsah pozorovaných délek. To nám později umožní porovnat modelové předpovědi pro stejně dlouhou samici a samce bez extrapolace.

6 Jak souvisí délka a zadní šířka krunýře?

Každý bod v následujícím **bodovém grafu (anglicky scatter plot)** představuje jednoho kraba. Vodorovná souřadnice je délka krunýře, svislá zadní šířka. Barva a legenda rozlišují pohlaví.


```
# Barvy v celém čtení přiřazujeme stejným skupinám
vec_barvy <- c(samice = "#9A3F87", samec = "#167B88")

# Jeden bod představuje jednoho změřeného kraba
plot(
  x = data_krabi$delka_krunyre_mm,
  y = data_krabi$zadni_sirka_mm,
  col = vec_barvy[as.character(data_krabi$pohlavi)],
  pch = 16,
  cex = 0.8,
```

```

xlab = "Délka krunýře (mm)",
ylab = "Zadní šířka krunýře (mm)"
)
legend(
  x = "topleft",
  legend = names(vec_barvy),
  col = vec_barvy,
  pch = 16,
  bty = "n"
)

```



Když se pohybujete zleva doprava, co se děje se zadní šířkou? Vypadají oba soubory bodů, jako by měly stejný sklon? Body naznačují rostoucí vztah u obou pohlaví. Samice mají při podobné délce obvykle větší zadní šířku, ale samotný pohled na body zatím nestačí k přesnému vyčíslení, zda se tento rozdíl s délkou mění.

7 Rovnoběžné přímky předpokládají společný sklon


Nejprve použijeme známý aditivní model. Oba prediktory v něm mohou měnit předpovězenou šířku, ale **sklon vůči délce je pro obě pohlaví společný**.

```

# Aditivní model připouští posun mezi skupinami, ale stejný sklon
mod_rovnobezne <- lm(
  formula = zadni_sirka_mm ~ delka_krunyre_mm + pohlavi,
  data = data_krabi
)
coef(object = mod_rovnobezne)

```


(Intercept)	delka_krunyre_mm	pohlavisamec
2.819657	0.331590	-1.717180



Co by tento model předpověděl o rozdílu v zadní šířce mezi stejně dlouhými kraby u kratších a delších délek z pozorovaného rozsahu? Přímký zůstávají rovnoběžné, takže předpovězený rozdíl je v obou případech stejný. Je to vlastnost modelu, kterou jsme do něj vložili znakem +, ne výsledek samostatného testu této vlastnosti.

8 Mění se rozdíl mezi samicemi a samci s délkou krunýře?

V bodovém grafu se rozdíl mezi skupinami při různých délkách nemusí jevit jako stálý. Na stejné osy proto můžeme orientačně vést přímkou každou skupinou zvlášť. Srovnajte jejich směr s rovnoběžnými přímkami předchozího obrázku; body krabů jsou v obou grafech stejné.



Předpovězte tvar

Pokud mají samice při určité společné délce větší předpovězenou zadní šířku a jejich přímka stoupá rychleji, bude rozdíl mezi přímkami u delších krabů menší, stejný, nebo větší?


Rozdíl by byl větší. Dvě různě strmé přímky totiž mění vzájemnou svislou vzdálenost s délkou. Této závislosti vztahu délky a šířky na pohlaví říkáme interakce prediktorů. Nyní stejnou myšlenku vyjádříme jedním modelem, který dovoluje oba sklony odhadnout společně.

9 Model s interakcí dovoluje samicím a samcům různé sklony

Předchozí obrázek ukázal, proč zkusit model se dvěma různými sklony. Délku krunýře v modelu měříme v milimetrech. Zápis `delka_krunyre_mm * pohlavi` dovolí, aby se sklon vůči délce mezi pohlavími lišil. Jednotlivé členy tohoto vzorce rozebereme po konkrétní předpovědi.

```
# Hvězdička připustí odlišné sklony pro samice a samce
mod_interakce <- lm(
  formula = zadni_sirka_mm ~ delka_krunyre_mm * pohlavi,
  data = data_krabi
)
```

Předpovědní přímky kreslíme jen v rozsahu délek, které byly v dané skupině opravdu pozorovány. Za konci těchto úseků bychom už extrapolovali.



Přímka samic zde stoupá strměji než přímka samců. Čáry jsou odhadnuté hodnoty modelu, zatímco body jsou skutečná měření. Svislou vzdálenost přímek vyčíslíme pro jednu společnou délku krunýře.


10 Co model předpovídá pro stejně dlouhou samici a samce?

V grafu obou přímek můžeme porovnat jejich výšku nad stejným místem vodorovné osy. Zvolíme **30 mm**, protože tato délka leží uvnitř pozorovaného rozsahu samic i samců a snadno ji najdeme na ose. Při srovnání pohlaví tak držíme délku krunýře stejnou. Která přímka je nad 30 mm výše?

```
# Připravíme stejnou délku pro samici i samce
delka_porovnani_mm <- 30
data_porovnani <- data.frame(
  delka_krunyre_mm = rep(delka_porovnani_mm, times = 2),
  pohlavi = c("samice", "samec")
)
# Model odhadne šířku pro obě kombinace
data_porovnani$odhad_sirky_mm <- predict(
  object = mod_interakce,
  newdata = data_porovnani
)
```

Pohlaví	Délka krunýře (mm)	Odhad zadní šířky (mm)
samice	30	12.91
samec	30	11.15

Oba odhady při 30 mm jsou v grafu označeny prázdnými kruhy. Svislá tečkovaná čára ukazuje místo, kde čteme jejich **svislou vzdálenost**; malé barevné body zůstávají naměřenými kraby.



Rozdíl při délce 30 mm

Při délce 30 mm model odhaduje zadní šířku samice 12.91 mm a samce 11.15 mm. **Rozdíl samec minus samice je -1.76 mm.** Samčí předpověď tedy leží o 1.76 mm níže.

Přímky nemají stejný sklon, a proto se jejich svislá vzdálenost s délkou mění. Koeficienty modelu ukážou, o kolik se tento rozdíl změní při porovnání délek vzdálených o 1 mm.

11 Co znamenají koeficienty modelu s interakcí?

Z minulé lekce známe aditivní model se společným sklonem:

```
zadni_sirka_mm ~ delka_krunyre_mm + pohlavi
```

Aby se sklon mohl mezi pohlavími lišit, přidáme interakční člen označený dvojtečkou:

```
zadni_sirka_mm ~ delka_krunyre_mm + pohlavi + delka_krunyre_mm:pohlavi
```

R nabízí pro celý pravý výraz kratší zápis s hvězdičkou:

```
zadni_sirka_mm ~ delka_krunyre_mm * pohlavi
```

Obecně tedy platí $x * y = x + y + x:y$. Výpis `summary()` nyní ukáže čtyři koeficienty: intercept a koeficient pro každý ze tří členů na pravé straně. Jde o tentýž model, který nakreslil obě přímky a vytvořil předpovědi při 30 mm:

```
summary(object = mod_interakce)
```

```
Call:
lm(formula = zadni_sirka_mm ~ delka_krunyre_mm * pohlavi, data = data_krabi)

Residuals:
    Min       1Q   Median       3Q      Max
-0.92402 -0.34114 -0.01188  0.23472  1.23484

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)      0.70771    0.29380   2.409   0.0179 *
delka_krunyre_mm  0.40674    0.01023  39.742 < 2e-16 ***
pohlavisamec      1.97311    0.40042   4.928 3.47e-06 ***
delka_krunyre_mm:pohlavisamec -0.12445    0.01317 -9.450 2.27e-15 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.4241 on 96 degrees of freedom
Multiple R-squared:  0.9664,    Adjusted R-squared:  0.9654
F-statistic: 921.2 on 3 and 96 DF,  p-value: < 2.2e-16
```

V tabulce **Coefficients** jsou čtyři řádky. Sloupec **Estimate** obsahuje odhady v milimetrech nebo v milimetrech šířky na milimetr délky. Referenční skupinou jsou samice, protože jsme je při tvorbě faktoru `pohlavi` uvedli jako první.

- **(Intercept)**, tedy intercept, je odhad zadní šířky **samice s délkou krunýře 0 mm**: 0.708 mm. Takto malého kraba jsme neměřili; číslo samo o sobě biologicky nevykládáme.
- **delka_krunyre_mm** je sklon **samičí** přímky: při délce o 1 mm větší model odhaduje šířku větší o 0.407 mm. Nejde o růst jednoho kraba v čase, ale o porovnání různě dlouhých jedinců.
- **pohlavisamec** je rozdíl **samec minus samice při délce 0 mm**: +1.973 mm. Není to rozdíl mezi pohlavími při každé délce ani odhad pro některého ze změřených krabů.
- **delka_krunyre_mm:pohlavisamec** je interakční člen: rozdíl **sklon samce minus sklon samice**, -0.124 mm/mm. Záporná hodnota říká, že samčí přímka stoupá pomaleji.

Hodnota 0 mm určuje pouze to, co v tomto zápisu znamenají dva koeficienty. Pro srovnání skutečně měřených délek použijeme oba koeficienty sklonu a dosadíme délku z pozorovaného rozsahu. **Rozdíl -1.76 mm jsme už odečetli z předpovědi při 30 mm.** Následující výpočet nepřináší nový výsledek; ukazuje, jak se stejná hodnota sestaví ze čtyř řádků tabulky **Coefficients**. Odhad šířky samice a rozdíl **samec minus samice** mají tuto stavbu:

odhad šířky samice při zvolené délce = odhad šířky samice při 0 mm + zvolená délka × samičí sklon,
rozdíl samec minus samice při zvolené délce = rozdíl při 0 mm + zvolená délka × rozdíl sklonů .

Při 30 mm dosadíme odhady z tabulky **Coefficients**:

$$\begin{aligned}\text{odhad šířky samice} &= 0.7077 + 30 \cdot 0.4067 \approx 12.91 \text{ mm}, \\ \text{rozdíl samec minus samice} &= +1.9731 + 30 \cdot (-0.1245) \approx -1.76 \text{ mm} .\end{aligned}$$

Ve výpočtu používáme nezaokrouhlené koeficienty modelu; zobrazená čtyři desetinná místa jsou jen pro čitelnost. Po vynásobení se výpočet zkrátí na dva součty:

$$\begin{aligned}\text{odhad šířky samice} &\approx 0.7077 + 12.2023 \approx 12.91 \text{ mm}, \\ \text{rozdíl samec minus samice} &\approx +1.9731 + (-3.7336) \approx -1.76 \text{ mm} .\end{aligned}$$

Stejný postup lze zapsat stručně pro libovolnou délku:

$$\begin{aligned}\hat{y}_{\text{samice}}(x) &= \beta_0 + \beta_1 x, \\ \hat{y}_{\text{samec}}(x) - \hat{y}_{\text{samice}}(x) &= \beta_2 + \beta_3 x.\end{aligned}$$

Zde x znamená zvolenou délku krunýře v mm a $\hat{y}$ modelový odhad zadní šířky v mm. β_0 je řádek **(Intercept)** pro samici při 0 mm, β_1 její sklon, β_2 řádek **pohlavisamec** pro rozdíl při 0 mm a β_3 interakční řádek pro rozdíl sklonů.

Odhad šířky samce získáme přičtením druhého výsledku k prvnímu: $12.91 + (-1.76) = 11.15$ mm. To souhlasí s řádkem samce v tabulce předpovědi. Pro biologické porovnání čteme **předpovědi při konkrétní délce** a jejich rozdíl.

Samčí sklon získáme sečtením samičího sklonu a interakčního koeficientu. Vyjde 0.282 mm/mm oproti 0.407 mm/mm u samic. Rozdíl **samec minus samice** se při porovnání o 1 mm delších krabů změnil o -0.124 mm. Pro tento rozdíl sklonů získáme z téhož modelu 95% interval spolehlivosti:

```
# Interval patří rozdílu sklonů samce a samice
confint(
  object = mod_interakce,
  parm = "delka_krunyre_mm:pohlavisamec"
)
```

```
                2.5 %      97.5 %
delka_krunyre_mm:pohlavisamec -0.1505977 -0.0983116
```

Odhadovaný rozdíl sklonů je -0.124 mm/mm; interval sahá od -0.151 do -0.098 mm/mm. Jde o nejistotu odhadu při předpokladech modelu, nikoli o rozsah šířek jednotlivých krabů.

Koeficient pohlaví neplatí při každé délce

Samotný koeficient `pohlavisamec` popisuje rozdíl při **0 mm**, tedy mimo pozorované délky. Při biologickém porovnání vždy uveďte **konkrétní délku** a porovnejte dvě modelové předpovědi při této délce.

Doplňující: co dalšího ukazuje `summary()`?

Sloupec **Std. Error** popisuje nejistotu jednotlivých koeficientů. **t value** a **Pr(>|t|)** slouží k testování, zda by příslušný *podmíněný* koeficient mohl být nulový při předpokladech modelu. Hvězdičky u p-hodnot nejsou velikostí biologického rozdílu: například test u (**Intercept**) se ptá na nulovou šířku samice při délce 0 mm, což zde není zajímavá biologická otázka.

Část **Residuals** stručně shrnuje odchylky jednotlivých krabů od přímek. **Residual standard error** popisuje jejich typickou velikost v milimetrech. Údaje **Multiple R-squared**, **Adjusted R-squared** a **F-statistic** zatím nepotřebujeme k výkladu interakce; k porovnávání biologicky zdůvodněných modelů se vrátíme v následující lekci.

Doplňující: modelové průměry při délce 30 mm pomocí `emmeans`

Funkci `emmeans()` znáte z předchozích lekcí. Pracuje se stejným odhadnutým modelem jako naše tabulka předpovědí; nastavíme v ní délku krunýře na 30 mm.

```
# Odhadneme průměrnou zadní šířku obou pohlaví při 30 mm
prumery_sirka <- emmeans::emmeans(
  object = mod_interakce,
  specs = ~ pohlavi | delka_krunyre_mm,
  at = list(delka_krunyre_mm = delka_porovnani_mm)
```

```
)
prumery_sirka
```

```
delka_krunyre_mm = 30:
  pohlavi emmean      SE df lower.CL upper.CL
  samice   12.9 0.0630 96    12.8    13.0
  samec    11.1 0.0623 96    11.0    11.3
```

Confidence level used: 0.95

Sloupec `emmean` obsahuje stejné dvě bodové předpovědi jako naše tabulka z `predict()`. Sloupce `lower.CL` a `upper.CL` vymezují modelový interval pro **průměrnou šířku skupiny**, ne rozsah šířek jednotlivých krabů. Chceme-li interval přímo pro rozdíl **samec minus samice**, vypočteme jej zvlášť:

```
# Odečteme samičí odhad od samčího odhadu
rozdily_sirka <- emmeans::contrast(
  object = prumery_sirka,
  method = "revpairwise"
)
confint(object = rozdily_sirka)
```

```
delka_krunyre_mm = 30:
  contrast      estimate      SE df lower.CL upper.CL
  samec - samice   -1.76 0.0886 96    -1.94    -1.58
```

Confidence level used: 0.95


Odhad rozdílu odpovídá dříve vypočteným -1.76 mm. **Interval pro rozdíl vzniká z obou předpovědí a jejich společné nejistoty**; nelze jej spolehlivě vyčíst jen z překryvu dvou intervalů pro jednotlivé průměry. Způsob výběru krabů stále omezuje, na koho lze výsledek přenést.

12 Jak dobře přímky popisují naměřené kraby?

Přímky procházejí oběma mračny bodů, ale jednotlivé šířky se od nich odchylují. Pro každého kraba je residuum rozdíl mezi naměřenou a odhadnutou šířkou. Graf reziduí proti odhadům pomůže odhalit zakřivení nebo změnu rozptylu, které by dvě přímky nezachytily.

```
# Spočteme rozdíl mezi měřením a předpovědí pro každého kraba
data_krabi$odhad_sirky_mm <- fitted(object = mod_interakce)
data_krabi$residuum_mm <-
  data_krabi$zadni_sirka_mm - data_krabi$odhad_sirky_mm

# Nula znamená dokonalou shodu měření a předpovědi
plot(
  x = data_krabi$odhad_sirky_mm,
  y = data_krabi$residuum_mm,
  col = vec_barvy[as.character(data_krabi$pohlavi)],
  pch = 16,
  cex = 0.8,
  xlab = "Odhadnutá zadní šířka (mm)",
  ylab = "Residuum (mm)"
)
abline(h = 0, lty = 2)
```



Rezidua se nacházejí na obou stranách nuly. Hledejte v grafu soustavné zakřivení nebo nápadně větší rozptyl na jedné straně: tím bychom poznali, že dvě přímky některou část vztahu nevystihují. Vraťte se také k bodovému grafu a prohlédněte kraby na koncích rozsahu délek. V těchto místech je méně sousedních měření, a jednotlivý krajní bod může sklon přímky více ovlivnit. Takový bod je důvod k ověření měření a citlivosti závěru, ne k automatickému odstranění.

Diagnostika modelu sama nezaručí, že je vztah v populaci přesně lineární, že výběr krabů byl reprezentativní, ani že pohlaví něco způsobilo. Předpovědi mimo pozorované délky jsme nekontrolovali.

Co ukázal první příklad

U těchto změřených krabů modré formy roste odhadnutá zadní šířka s délkou u obou pohlaví. Sklon je u samic přibližně 0.407 mm šířky na 1 mm délky a u samců 0.282 mm/mm. Při 30 mm je modelový rozdíl **samec minus samice** –1.76 mm. Samčí sklon je o 0.124 mm/mm menší, takže u krabů s větší délkou model předpovídá ještě menší rozdíl samec minus samice. Jde o souvislost v těchto měřeních, nikoli o důkaz, že ji pohlaví způsobuje.

13 Liší se rozdíl v délce krunýře mezi pohlavími u obou barevných forem?

Vztah zadní šířky k délce jsme sledovali pouze u modré formy. Původní soubor obsahuje také oranžovou barevnou formu. Můžeme se proto zeptat na jiný rozměr těchto krabů: **je rozdíl v délce krunýře mezi samci a samicemi stejný u obou forem?** Odezvou je tentokrát délka krunýře v milimetrech. Barevná forma i pohlaví jsou kategoriální proměnné neboli skupinové znaky; pro tento příklad nepotřebujeme číselný prediktor.

```
# Vrátime se k celému původnímu souboru a vybereme novou odezvu
# i oba skupinové znaky
data_formy <- MASS::crabs[, c("sp", "sex", "CL")]
names(data_formy) <- c("forma", "pohlavi", "delka_krunyre_mm")

data_formy$forma <- factor(
  x = data_formy$forma,
  levels = c("B", "O"),
  labels = c("modrá", "oranžová")
)
data_formy$pohlavi <- factor(
  x = data_formy$sex,
  levels = c("F", "M"),
  labels = c("samice", "samec")
)

# Počty ve čtyřech skupinách a chybějící délky
table(data_formy$forma, data_formy$pohlavi)
```

	samice	samec
modrá	50	50
oranžová	50	50

```
colSums(x = is.na(data_formy))
```

```

      forma      pohlavi delka_krunyre_mm
      0          0          0

```

```
str(object = data_formy)
```

```

'data.frame':  200 obs. of  3 variables:
 $ forma      : Factor w/ 2 levels "modrá","oranžová": 1 1 1 1 1 1 1 1 1 1 ...
 $ pohlavi    : Factor w/ 2 levels "samice","samec": 2 2 2 2 2 2 2 2 2 2 ...
 $ delka_krunyre_mm: num  16.1 18.1 19 20.1 20.3 23 23.8 24.5 24.2 25.2 ...

```

```
summary(object = data_formy$delka_krunyre_mm)
```

```


   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
14.70  27.27   32.10   32.11   37.23   47.60

```

V souboru je 200 krabů. V každé ze čtyř kombinací je 50 měření; v délce krunýře chybí 0 hodnot. Pozorované délky v celém souboru sahají od 14.7 do 47.6 mm. Jeden řádek stále představuje jednoho kraba. Názvy forem zde označují dvě skupiny v datovém souboru, nikoli zásah, který bychom krabům přidělili.

14 Jaké délky krunýře vidíme ve čtyřech skupinách?

Nejprve se podívejte pouze na jednotlivé naměřené délky. Každý bod představuje jednoho kraba. Body samic a samců jsou uvnitř každé barevné formy mírně posunuté do stran, aby se méně překrývaly; barvy pohlaví zůstávají stejné jako v předchozích grafech.




Barevná forma	Samice: průměr (mm)	Samec: průměr (mm)
modrá	28.10	32.01
oranžová	34.62	33.69

Ve které formě mají samci větší průměrnou délku než samice? Platí to i ve druhé formě? U modré formy činí rozdíl **samec minus samice** +3.91 mm. U oranžové formy je to -0.93 mm. Rozdíl má opačný směr. Průměry popisují skupiny, zatímco jednotlivé body v obrázku připomínají velkou proměnlivost délek mezi kraby uvnitř každé skupiny.

15 Jak model zachytí změnu rozdílu mezi pohlavími podle formy?

Vrátíme se ke **stejnému obrázku se všemi jednotlivými kraby**. Body ani osy neměníme. Přidáme pouze velké kosočtverce pro čtyři průměry a v každé barevné formě spojíme průměr samic s průměrem samců. Sklon spojnice zde nevyjadřuje spojitou předpověď; pouze zvýrazňuje velikost a směr rozdílu mezi dvěma kategoriemi.



Na modré formě leží průměr samců nad průměrem samic; na oranžové pod ním. Zajímá nás, **o kolik se rozdíl samec minus samice změní mezi formami**. Tento rozdíl dvou rozdílů je druhým typem interakce:

$$\begin{aligned}
 \text{změna rozdílu mezi pohlavími} &= \text{průměr délky oranžových samců} \\
 &\quad - \text{průměr délky oranžových samic} \\
 &\quad - \text{průměr délky modrých samců} \\
 &\quad + \text{průměr délky modrých samic} .
 \end{aligned}$$

Vezmeme čtyři průměry z tabulky a odečteme vždy dvě hodnoty ze stejného řádku:

$$\begin{aligned}
\text{změna rozdílu mezi pohlavími} &= (33.688 - 34.618) - (32.014 - 28.102) \\
&= -0.930 - 3.912 \\
&= -4.842 \text{ mm}
\end{aligned}$$

Stručně lze stejné čtyři průměry označit $\bar{y}_{O,M}$, $\bar{y}_{O,F}$, $\bar{y}_{B,M}$ a $\bar{y}_{B,F}$; O a B označují oranžovou a modrou formu, M a F samce a samici a pruh nad y průměr délky. Pak platí $\Delta = (\bar{y}_{O,M} - \bar{y}_{O,F}) - (\bar{y}_{B,M} - \bar{y}_{B,F})$, kde Δ označuje změnu rozdílu mezi pohlavími při přechodu od modré k oranžové formě.

Jediným modelem můžeme tyto čtyři skupinové průměry odhadnout společně. Hvězdička zahrne obě skupiny i jejich interakci:

```
# Referenční kombinací je modrá forma a samice
mod_formy <- lm(
  formula = delka_krunyre_mm ~ forma * pohlavi,
  data = data_formy
)
summary(object = mod_formy)
```

```
Call:
lm(formula = delka_krunyre_mm ~ forma * pohlavi, data = data_formy)

Residuals:
    Min       1Q   Median       3Q      Max
-16.988  -4.636   0.184   5.130  15.086

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)      28.1020     0.9499  29.584 < 2e-16 ***
formaoranžová      6.5160     1.3434   4.851 2.5e-06 ***
pohlavisamec       3.9120     1.3434   2.912 0.00401 **
formaoranžová:pohlavisamec -4.8420     1.8998  -2.549 0.01158 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 6.717 on 196 degrees of freedom
Multiple R-squared:  0.1232,    Adjusted R-squared:  0.1098
F-statistic: 9.181 on 3 and 196 DF,  p-value: 1.031e-05
```

V tabulce **Coefficients** se opět soustředíte na sloupec **Estimate**. Řádky nejsou čtyři nezávislé průměry: jeden je referenční průměr a zbylé tři popisují, jak se od něj dostaneme k ostatním skupinám.

16 Co znamenají čtyři koeficienty modelu se dvěma skupinovými znaky?

Protože referenčními kategoriemi jsou **modrá forma** a **samice**, každý koeficient má přesně určené srovnání. Odhady vytáhneme ze stejného modelu, který vytvořil výpis `summary()`.

- **(Intercept)** je odhad průměrné délky **modré samice**: 28.102 mm. Najdete jej v tabulce průměrů v řádku modré formy a sloupci samic.
- **formaoranžová** je rozdíl **oranžová minus modrá mezi samicemi**: +6.516 mm. Po přičtení k interceptu dostaneme průměr oranžových samic; tento koeficient nepopisuje rozdíl forem u obou pohlaví stejně.
- **pohlavisamec** je rozdíl **samec minus samice v modré formě**: +3.912 mm. Souhlasí se svislou vzdáleností obou průměrů u modré formy.
- **formaoranžová:pohlavisamec** je změna rozdílu samec minus samice při přechodu **od modré k oranžové formě**: -4.842 mm. Jde přesně o výše vypočtený rozdíl dvou rozdílů, nikoli o další samostatnou skupinu.

```
# Interval patří k rozdílu dvou rozdílů, ne k jedné skupině
confint(
  object = mod_formy,
  parm = "formaoranžová:pohlavisamec"
)
```

```
                2.5 %    97.5 %
formaoranžová:pohlavisamec -8.588674 -1.095326
```

Modelový 95% interval spolehlivosti pro změnu rozdílu sahá od -8.59 do -1.10 mm. Celý leží pod nulou: při předpokladech modelu data podporují menší rozdíl samec minus samice u oranžové než u modré formy. Způsob výběru krabů navíc neumožňuje automaticky zobecnit tento interval na všechny kraby.

Jak model sestaví předpověď pro oranžového samce? K odhadu modré samice přidá rozdíl forem mezi samicemi, rozdíl pohlaví u modré formy a změnu tohoto rozdílu u oranžové formy:

$$\begin{aligned} \text{odhad délky oranžového samce} &= \text{odhad délky modré samice} \\ &+ \text{rozdíl forem mezi samicemi} \\ &+ \text{rozdíl pohlaví u modré formy} \\ &+ \text{změna rozdílu pohlaví u oranžové formy} . \end{aligned}$$

Dosazené hodnoty jsou právě čtyři řádky výpisu modelu:

$$\begin{aligned} \text{odhad délky oranžového samce} &= 28.102 + 6.516 + 3.912 + (-4.842) \\ &= 38.530 + (-4.842) \\ &= 33.688 \text{ mm} \end{aligned}$$

V obecném zkráceném zápisu je to $\hat{y}_{O,M} = \beta_0 + \beta_O + \beta_M + \beta_{OM}$. Symbol $\hat{y}_{O,M}$ značí modelový odhad délky oranžového samce, β_0 referenční průměr modré samice, β_O rozdíl forem u samic, β_M rozdíl pohlaví u modré formy a β_{OM} změnu tohoto rozdílu u oranžové formy.

```
# Vytvoříme všechny čtyři kombinace a pro každou spočteme odhad
data_kombinace <- expand.grid(
  forma = levels(data_formy$forma),
  pohlavi = levels(data_formy$poohlavi)
)
data_kombinace$delka_odhad_mm <- predict(
  object = mod_formy,
  newdata = data_kombinace
)
data_kombinace
```

```
      forma pohlavi delka_odhad_mm
1   modrá   samice      28.102
2 oranžová samice      34.618
3   modrá   samec      32.014
4 oranžová   samec      33.688
```

Barevná forma	Samice: odhad (mm)	Samec: odhad (mm)
modrá	28.10	32.01
oranžová	34.62	33.69

V řádku oranžové formy je rozdíl samec minus samice -0.93 mm. Získáme jej také sečtením koeficientů `pohlavisamec` a `formaoranžová:pohlavisamec`: $3.912 + (-4.842) = -0.930$ mm. **Samotný koeficient pohlaví tedy platí pro modrou formu; u oranžové se k němu přidá interakce.**

Doplňující: čtyři skupinové předpovědi pomocí `emmeans`

Stejně jako v předchozím příkladu můžeme z již odhadnutého modelu získat předpovědi pomocí `emmeans()`. Tentokrát žádnou číselnou hodnotu nenastavujeme: žádáme o **obě pohlaví uvnitř každé barevné formy**, tedy o čtyři skutečně zastoupené kombinace.

```
# Ze stejného modelu získáme odhad pro každou kombinaci formy a pohlaví
prumery_formy <- emmeans::emmeans(
  object = mod_formy,
  specs = ~ pohlavi | forma
)
prumery_formy
```

```
forma = modrá:
  pohlavi emmean   SE  df lower.CL upper.CL
samice    28.1 0.95 196    26.2    30.0
samec     32.0 0.95 196    30.1    33.9
```

```
forma = oranžová:
  pohlavi emmean   SE  df lower.CL upper.CL
samice    34.6 0.95 196    32.7    36.5
samec     33.7 0.95 196    31.8    35.6
```

Confidence level used: 0.95

Sloupec `emmean` ukazuje stejné délky jako tabulka předpovědí z `predict()`. Protože model obsahuje obě skupiny i jejich interakci, tyto čtyři odhady jsou zde také rovny pozorovaným průměrům čtyř skupin. Intervaly `lower.CL` a `upper.CL` se vztahují ke **skupinovým průměrům**. Rozdíl **samec minus samice** pro každou formu vypočteme přímo:

```
# Opačné pořadí dvojice dává rozdíl samec minus samice
rozdily_formy <- emmeans::contrast(
  object = prumery_formy,
  method = "revpairwise"
)
confint(object = rozdily_formy)
```

```
forma = modrá:
  contrast      estimate    SE  df lower.CL upper.CL
samec - samice    3.91 1.34 196    1.26    6.56
```


```
forma = oranžová:
  contrast      estimate    SE  df lower.CL upper.CL
samec - samice   -0.93 1.34 196   -3.58    1.72
```

Confidence level used: 0.95

Řádek modré formy odpovídá rozdílu +3.91 mm a řádek oranžové -0.93 mm. Interval u každého řádku se týká **rozdílu pohlaví v dané formě**; interval pro změnu tohoto rozdílu mezi formami jsme získali výše z interakčního koeficientu. Tyto tři otázky mají odlišné intervaly, i když vycházejí z téhož modelu.

17 Co o jednotlivých krabech čtyři průměry neříkají?

Model čtyř skupin přesně vystihuje jejich průměry. To však neznamená, že stejně dobře vystihuje každého kraba: jednotlivé délky se od skupinových průměrů výrazně liší. Zkontrolujeme proto rezidua uvnitř skupin; jejich nulový průměr je zde vlastností odhadu skupinových průměrů, nikoli důkazem bezchybného modelu. V houslovém grafu (anglicky *violin plot*) širší část naznačuje, kde se odchylky častěji vyskytují, a každý bod ukazuje skutečné měření jednoho kraba.



Ve všech skupinách jsou délky na obou stranách odhadu. Rozpětí a krajní hodnoty se mezi skupinami mohou lišit; graf proto nečtěte jako důkaz, že čtyři průměry popisují jednotlivce přesně. Bez popisu způsobu výběru krabů také nelze rozdíly automaticky zobecnit na všechny kraby ani z nich vyvozovat účinek pohlaví nebo barevné formy.

18 Kdy potřebujeme při výkladu modelu uvést další prediktor?

První příklad vyjádřil interakci jako **změnu rozdílu v šířce mezi pohlavími při různých délkách**: dva sklony nemusí být stejné. Druhý příklad ji vyjádřil jako **změnu rozdílu v délce mezi pohlavími u dvou barevných forem**: dvě srovnání samce se samicí nemusí dát stejný výsledek. V obou případech musíme při výkladu jednoho prediktoru uvést hodnotu druhého.

Co si odnést

U modelu s interakcí se ptejte „**při jaké délce?**“ nebo „**v jaké barevné formě?**“. V prvním modelu se samotný koeficient pohlaví vztahuje k 0 mm, délce mimo data; ve druhém k referenční barevné formě. Předpovědi pro konkrétní kombinace ukazují, jak se skupinový rozdíl mění. U modrých krabů je při 30 mm odhadovaný rozdíl zadní šířky **samec minus samice** -1.76 mm; u krabů s délkou o 1 mm větší se podle modelu tento rozdíl změní o -0.124 mm. Rozdíl délky **samec minus samice** je u modré formy $+3.91$ mm a u oranžové -0.93 mm.

mm; změna mezi formami činí -4.84 mm. Jednotlivá měření a diagnostické grafy připomínají nejistotu těchto odhadů a jejich omezený dosah.

Závěry popisují pozorované souvislosti v tomto souboru. V následující lekci se zeptáme, jak mezi biologicky smysluplnými modely vybírat a jak vyvážit popis dat se složitostí modelu. Úplné definice použitých pojmů najdete v [kurzovém slovníku](#).