BIOSTATISTIKA

L08

Liší se vztah délky a zadní šířky krunýře mezi samicemi a samci?



Interakce prediktorů

cuni-natur-biostatistics.github.io/materialy.html

Ilustrace vytvořená pomocí AI.

Co vlastně na krabovi měříme?



Ilustrace vytvořená pomocí AI.

Délka krunýře a **zadní šířka krunýře** jsou dvě měření téhož kraba.

Co si pamatujete z minulé lekce?

Odpovězte samostatně na tři krátké otázky. Společné odpovědi projdeme po hlasování.

Proč se po přidání maximální teploty změnil sklon roční teploty i jeho SE?

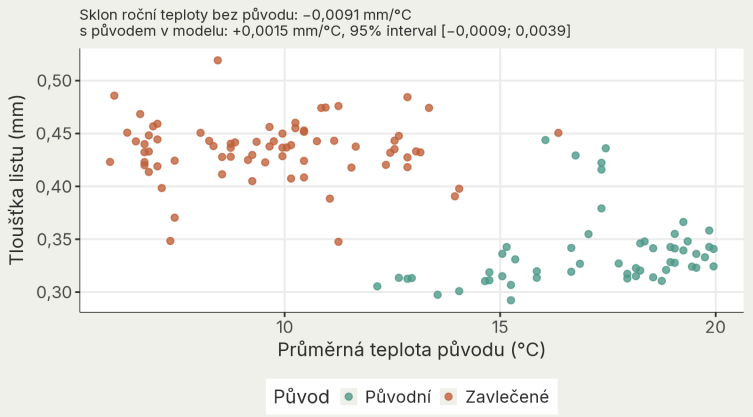
```
> round(coef(summary(mod_rocni_teplota))[, 1:2], 4)
                Estimate Std. Error
(Intercept)       0.5105     0.0115
teplota_rocni_C  -0.0091     0.0008
> round(coef(summary(mod_dve_teploty))[, 1:2], 4)
                Estimate Std. Error
(Intercept)       0.5899     0.0301
teplota_rocni_C  -0.0053     0.0016
teplota_max_C    -0.0048     0.0017
> c(nobs(mod_rocni_teplota), nobs(mod_dve_teploty))
[1] 128 128
```

- První model byl chybný; až druhý ukazuje skutečný účinek roční teploty.
- Maximální teplota stojí ve formuli druhá, a proto převzala část efektu.
- Koeficient teď platí při stejné max. teplotě; obě teploty silně korelují.
- Po přidání prediktoru model použil méně populací než předtím.

SPRÁVNÁ ODPOVĚĎ

: Koeficient teď platí při stejné max. teplotě; obě teploty silně korelují.
Nový koeficient odpovídá na užší otázku při stejné maximální teplotě (r ≈ 0,85) a tu nese málo populací, proto SE roste.
Pořadí ve formuli koeficienty nemění.

S původem v modelu změnil sklon roční teploty znaménko. Proč?



Celkový sklon mísil rozdíl obou původů, které žijí v různě teplých oblastech.

Roční teplota ve skutečnosti list zesiluje, první model měl opačné znaménko.

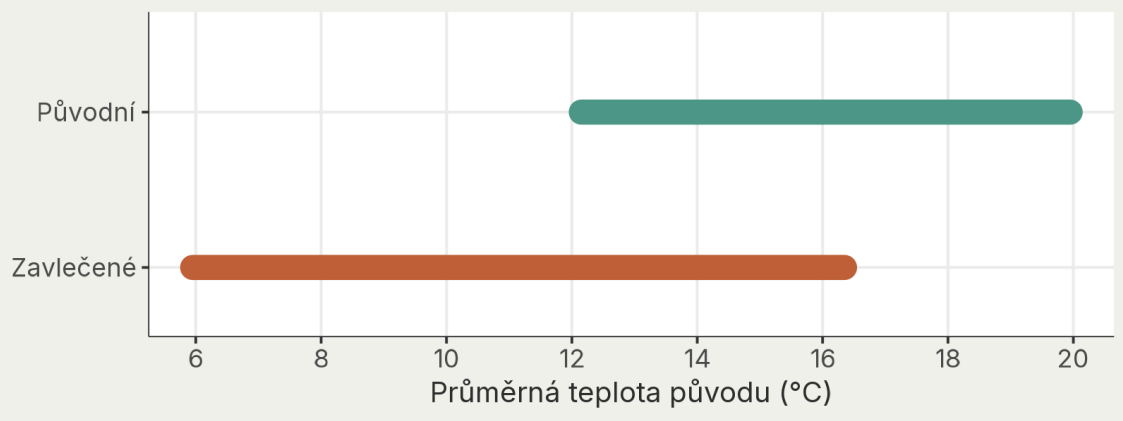
Podmíněný sklon je nevýznamný, roční teplota tedy na list nemá vliv.

Původ a roční teplota spolu nesouvisejí, změna je jen výběrová variabilita.

SPRÁVNÁ ODPOVĚĎ

: Celkový sklon mísil rozdíl obou původů, které žijí v různě teplých oblastech.
Zavlečené populace mají tlustší listy a pocházejí z chladnějších oblastí. Původ je konfundující proměnná; uvnitř původu je vztah slabý a jeho interval zahrnuje nulu.

Chceme porovnat zavlečené a původní populace při roční teplotě 8 °C. Co platí?



- 8 °C leží v rozsahu všech populací (6–20 °C), odhad je proto podložený.
- Původní populace pod 12 °C nemáme; rozdíl při 8 °C stojí na extrapolaci.
- Aditivní model dává stejný rozdíl při každé teplotě, takže na 8 °C nezáleží.
- Model s původem a teplotou neumí predikovat pro konkrétní teplotu.

SPRÁVNÁ ODPOVĚĎ

: Původní populace pod 12 °C nemáme; rozdíl při 8 °C stojí na extrapolaci.

Model rozdíl vypočte při každé teplotě, ale data ho podporují jen v překryvu obou skupin, asi 12–16 °C. Při 8 °C existují jen zavlečené populace.

Výsledky učení

Po absolvování této přednášky budete schopni:

- rozpoznat biologickou otázku, ve které vztah jednoho prediktoru k odezvě závisí na druhém prediktoru;
- fitovat model s interakcí a zobrazit jeho predikce pro kombinace numerických i kategoriálních prediktorů;
- vyložit koeficienty modelu s interakcí jako podmíněné a porovnávat skupiny nebo různé hodnoty prediktoru pomocí predikcí;
- vysvětlit interakci dvou kategoriálních prediktorů jako rozdíl dvou rozdílů;
- omezit závěr na pozorovaný rozsah dat a na souvislost v pozorovacích datech.

Platí rovnoběžné přímky i pro kraby?

Proč by se samice a samci mohli lišit tvarem krunýře?

CO VÍME O KRABECH

- Zadní část krunýře leží zhruba nad zadečkem.
- Samice pod zadečkem nosí vajíčka.
- Samice a samci se liší poměrem zadní šířky a délky krunýře.

Bude rozdíl v zadní šířce mezi stejně dlouhou samicí a samcem stejný u malých i velkých krabů?

Campbell a Mahon (1974), *Australian Journal of Zoology* 22: 417–425.

Jeden bod představuje jednoho kraba

```r
data_krabi_vse <-
  read.csv(file = "data/krabi.csv")

# Modrá forma, pohlaví, délka a zadní šířka
data_krabi <-
  data_krabi_vse[
    data_krabi_vse$sp == "B",
    c("sex", "CL", "RW")
  ]
names(data_krabi) <-
  c("pohlavi", "delka_krunyre_mm",
    "zadni_sirka_mm")
data_krabi$pohlavi <-
  factor(
    x = data_krabi$pohlavi,
    levels = c("F", "M"),
    labels = c("samice", "samec")
  )
head(x = data_krabi, n = 3)
```

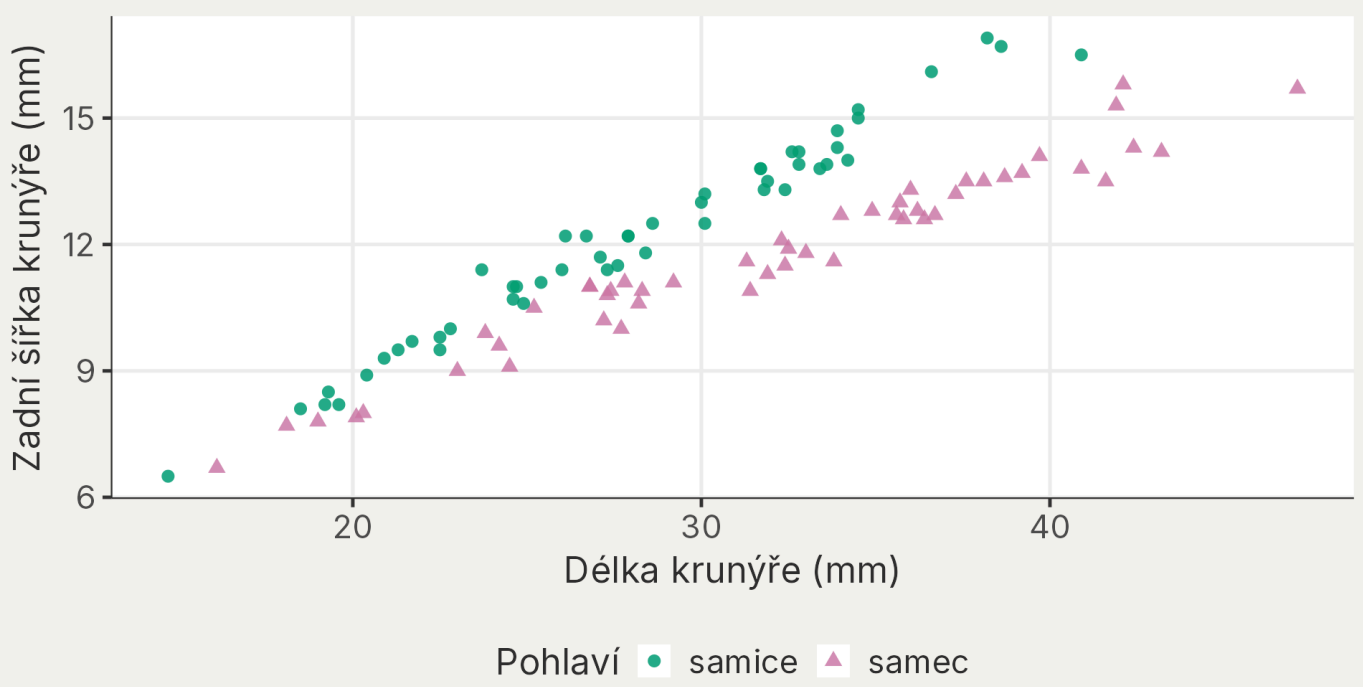
```
  pohlavi delka_krunyre_mm zadni_sirka_mm
1   samec             16.1            6.7
2   samec             18.1            7.7
3   samec             19.0            7.8
```

100 KRABŮ

- 🔵 modrá barevná forma
- 50 samic · 50 samců
- délka krunýře v mm
- zadní šířka v mm

Campbell a Mahon (1974) · `data/krabi.csv`

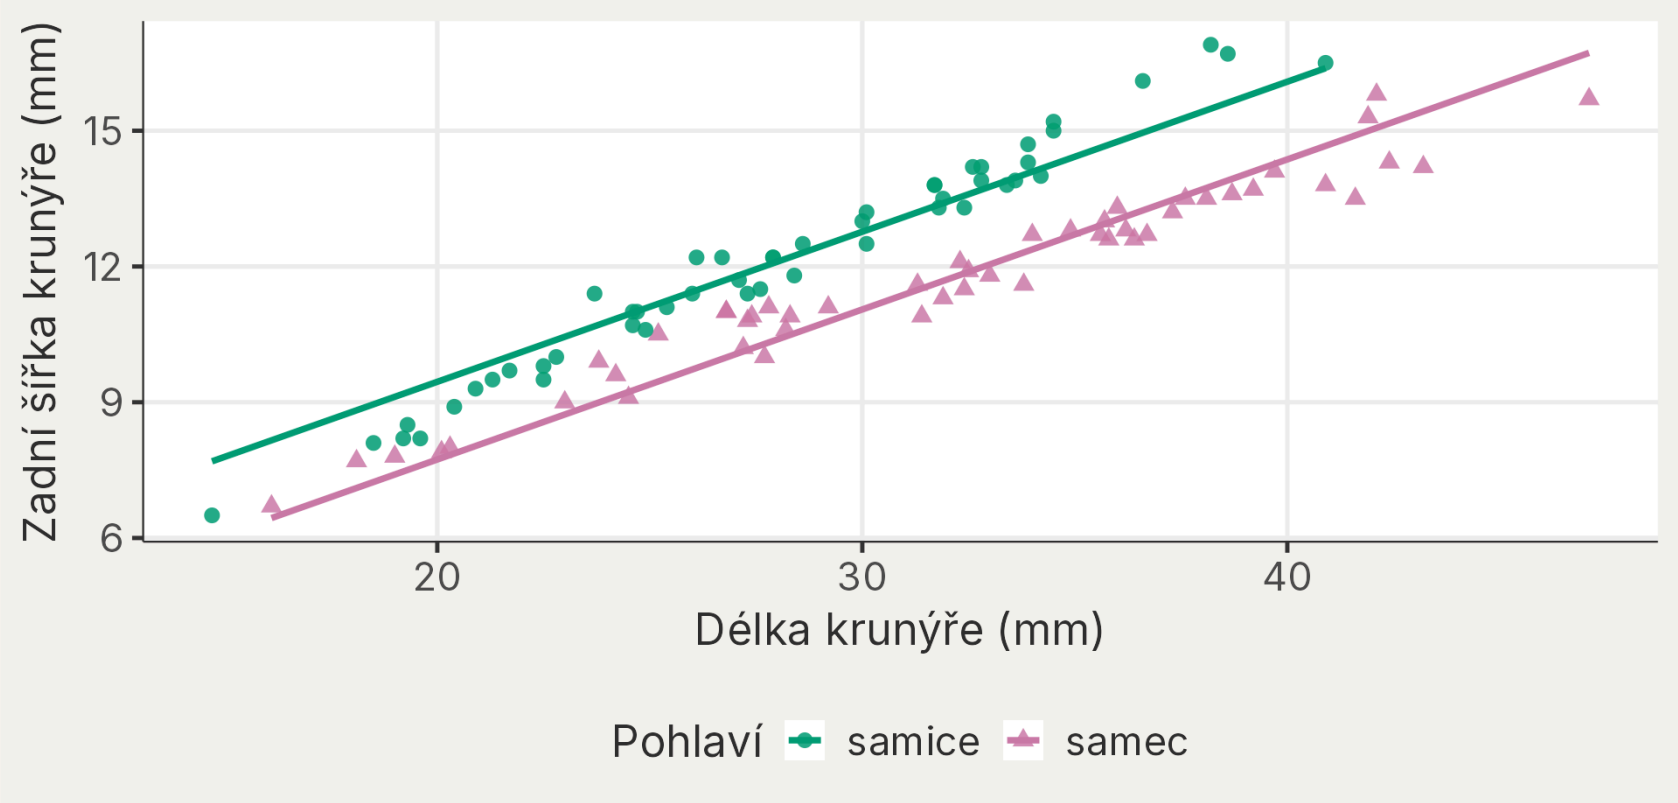
Co naznačují měření krabů?



1. Jaký je směr vztahu?
2. Kde se skupiny překrývají?
3. Vypadají oba sklony stejně?

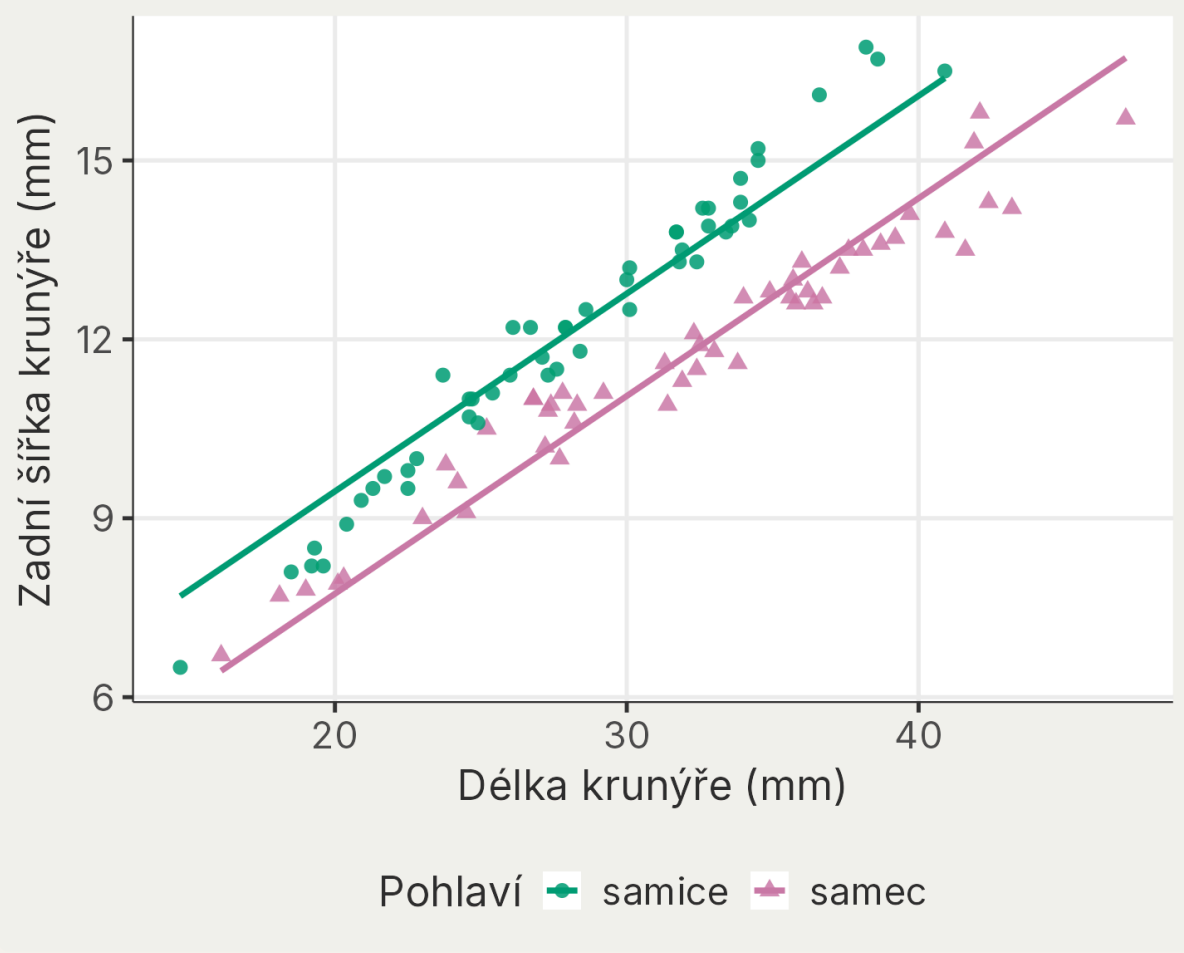
Aditivní model kreslí rovnoběžné přímky

```
1  mod_rovnobezne <-
2    lm(
3      formula = zadni_sirka_mm ~ delka_krunyre_mm + pohlavi,
4      data = data_krabi
5    )
```



`+` dovoluje posun mezi skupinami, ale ukládá jim společný sklon.

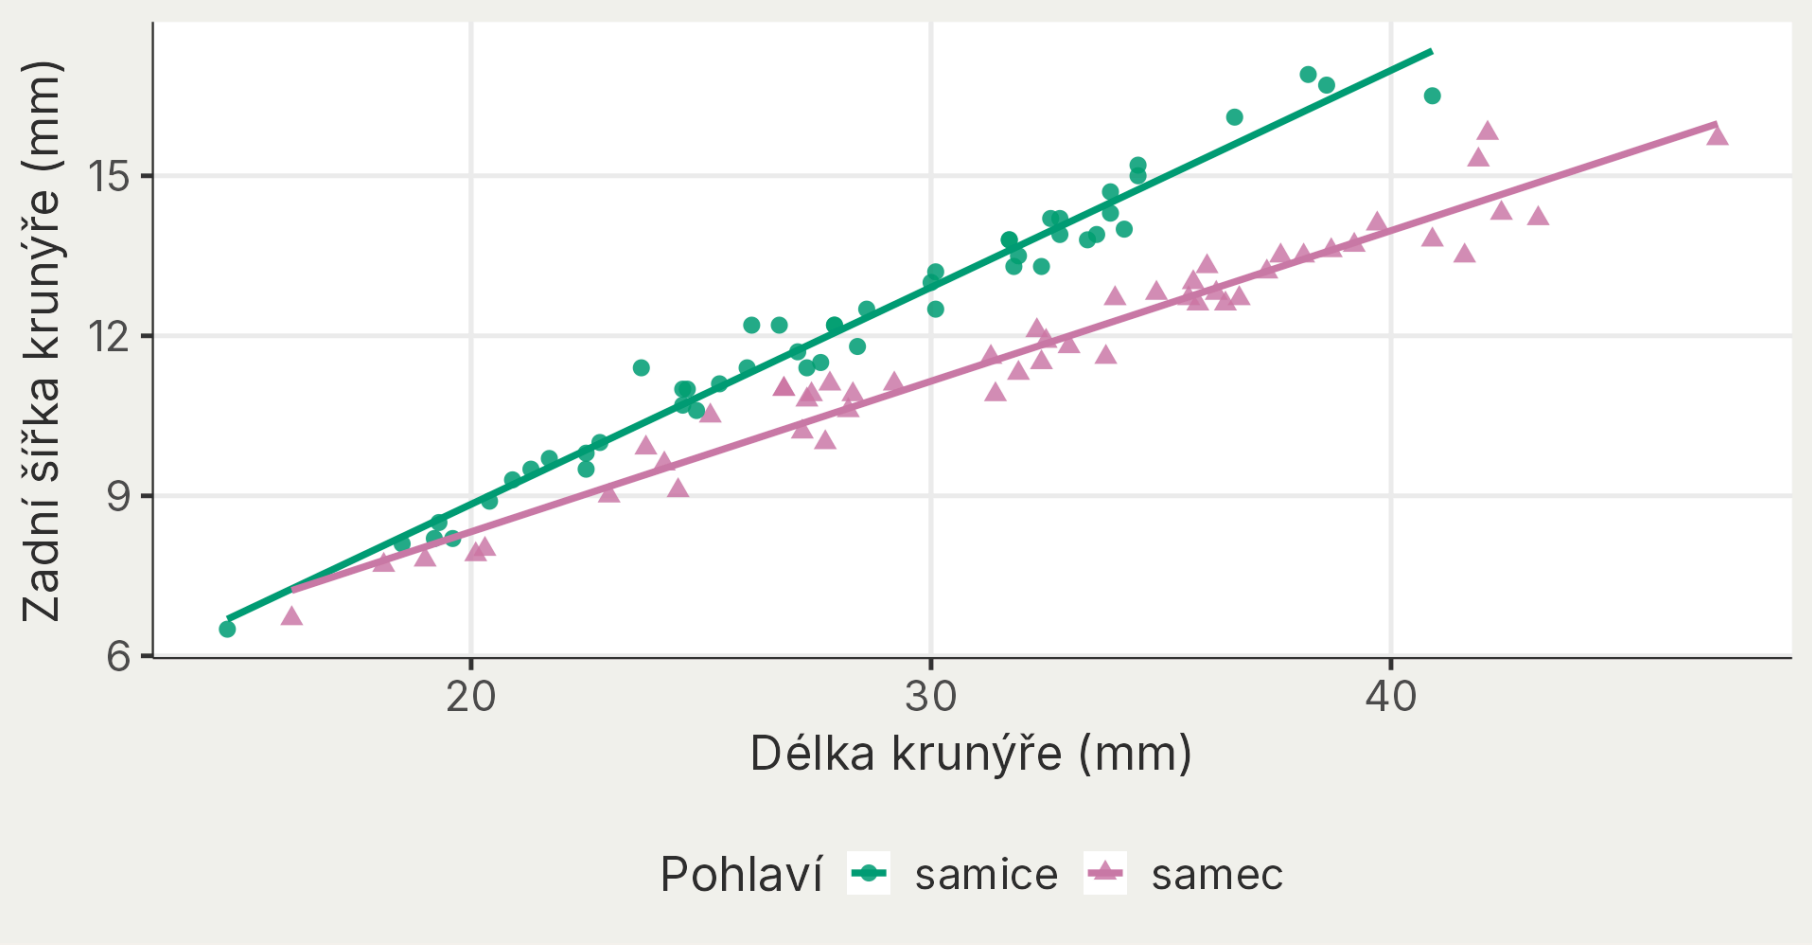
Zůstává rozdíl mezi pohlavími při každé délce stejný?



VE DVOJICI

Porovnejte svislou vzdálenost přímek u kratších a delších krabů. Sedí přímky k bodům i na koncích rozsahu?

Data naznačují různé sklony



Svislá vzdálenost mezi přímkami se s délkou mění.

Když se rozdíl mění, mluvíme o interakci

ADITIVNÍ MODEL

Rozdíl mezi pohlavími je při každé délce stejný.
Rovnoběžné přímky

MODEL S INTERAKCÍ

Rozdíl mezi pohlavími se mění s délkou.
Různé sklony

Interakce: vztah délky a zadní šířky závisí na pohlaví.

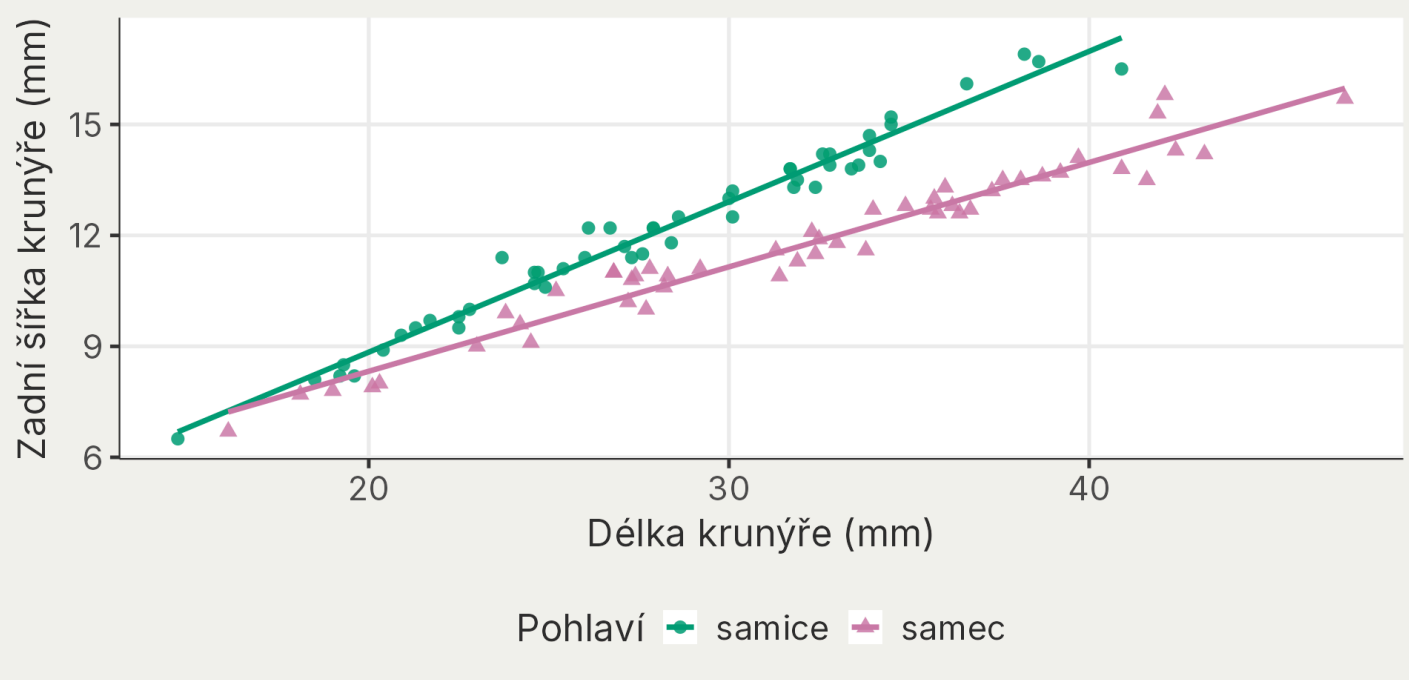
Jak zapsat model s interakcí?

1. `zadni_sirka_mm ~ delka_krunyre_mm + pohlavi`
2. `zadni_sirka_mm ~ delka_krunyre_mm + pohlavi + delka_krunyre_mm:pohlavi`
3. `zadni_sirka_mm ~ delka_krunyre_mm * pohlavi`

> `x * y` je zkratka pro `x + y + x:y`; dvojtečka označuje interakční člen.

Model s interakcí dovoluje dvěma pohlavím různé sklony

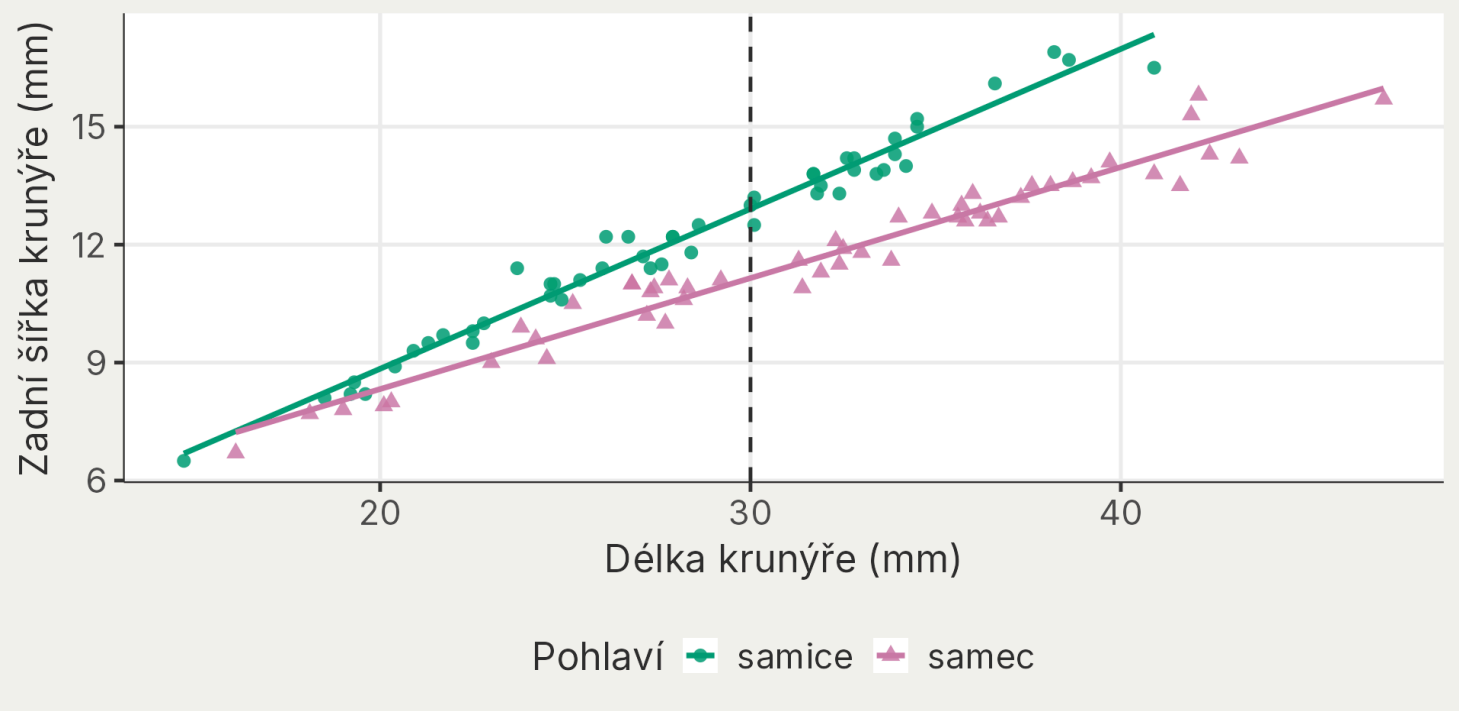
```
1  mod_interakce <-
2    lm(
3      formula = zadni_sirka_mm ~ delka_krunyre_mm * pohlavi,
4      data = data_krabi
5    )
```



Každou přímku kreslíme jen přes délky zastoupené v její skupině.

Co model odhaduje pro dva stejně dlouhé kraby?

```
1  # Společná délka uvnitř rozsahu obou pohlaví
2  delka_porovnani_mm <- 30
```



Která přímka je při 30 mm výše? O kolik přibližně?

Dva odhady při stejné délce krunýře

```r
data_porovnani <-
  data.frame(
    delka_krunyre_mm = rep(x = delka_porovnani_mm, times = 2),
    pohlavi = c("samice", "samec")
  )

data_porovnani$odhad_sirky_mm <-
  predict(
    object = mod_interakce,
    newdata = data_porovnani
  )

data_porovnani
```

```
  delka_krunyre_mm pohlavi odhad_sirky_mm
1               30  samice       12.91000
2               30   samec       11.14947
```

Samec má při 30 mm užší zadní část krunýře

● **Samice**

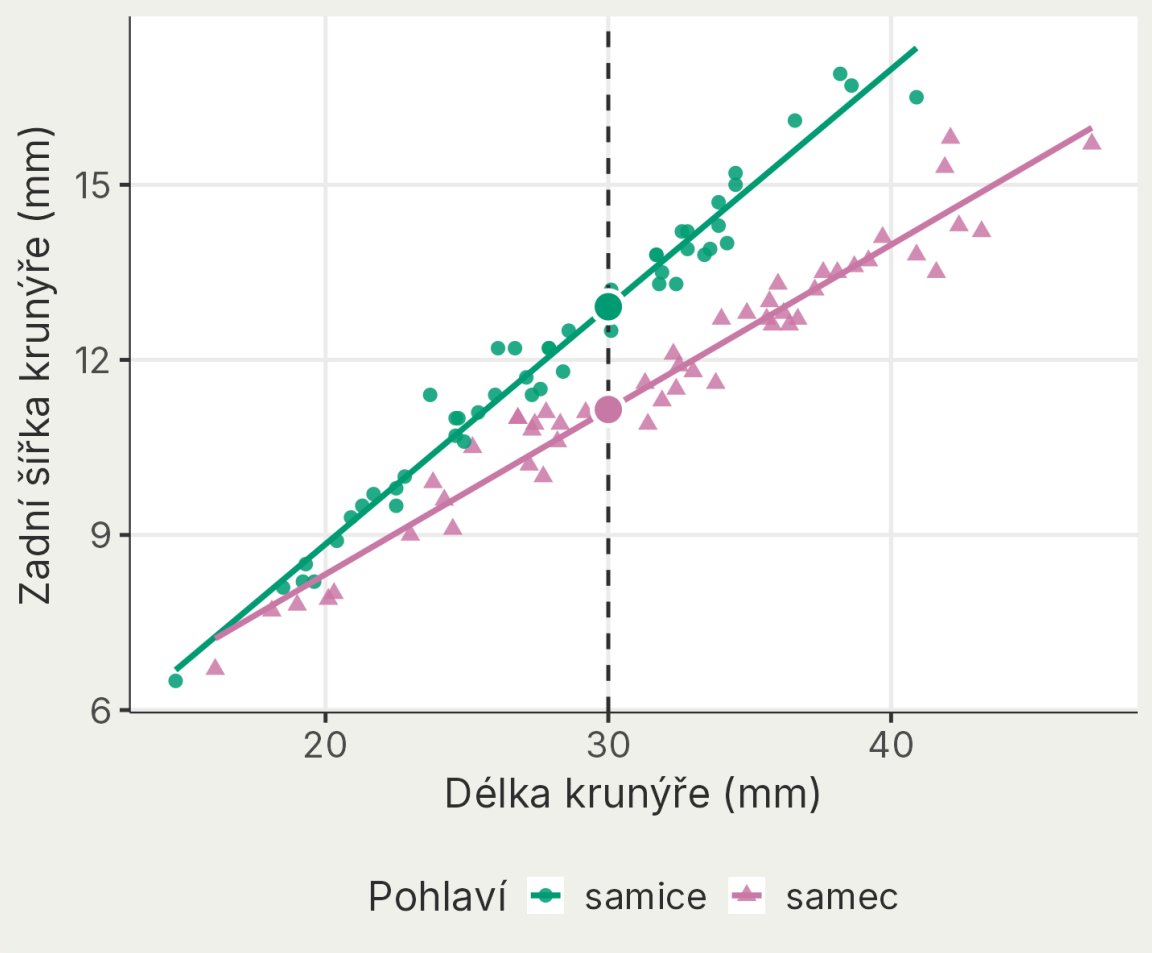
12,91 mm

▲ **Samec**

11,15 mm

Samec – samice

−1,76 mm



Co už můžeme říci o stejně dlouhých krabech?

CO VÍME

- Zadní šířka roste s délkou u obou pohlaví.
- Samčí přímka stoupá pomaleji.
- Při 30 mm má samec zadní šířku o 1,76 mm menší.

CO JEŠTĚ NEVÍME

- Jak tento výsledek vyjadřují koeficienty modelu?
- Jak přesně známe rozdíl sklonů?

Koeficienty interakčního modelu

Jaké jsou koeficienty v `summary()`?

```
souhrn_interakce <-
  summary(object = mod_interakce)

round(
  x = souhrn_interakce$coefficients,
  digits = 3
)
```

```
                            Estimate Std. Error t value Pr(>|t|)
(Intercept)                    0.708      0.294   2.409    0.018
delka_krunyre_mm               0.407      0.010  39.742    0.000
pohlavisamec                   1.973      0.400   4.928    0.000
delka_krunyre_mm:pohlavisamec -0.124      0.013  -9.450    0.000
```

Pro výklad nám stačí sloupec **Estimate**.

První dva koeficienty popisují referenční samice

`(Intercept)`

0,708 mm

Odhad pro samici při délce **0 mm** (hypotetický krab).

`delka_krunyre_mm`

+0,407 mm/mm

Sklon samičí přímky: samice delší o 1 mm má odhadem širší zadní část.

Koeficient pohlaví porovnává skupiny při délce 0 mm

`pohlavisamec` = **+1,973 mm**

Rozdíl **samec – samice**, když `delka_krunyre_mm = 0`.

Není to:

- rozdíl při každé délce;
- rozdíl při 30 mm;
- průměrný rozdíl mezi všemi samci a samicemi.

Biologicky smysluplné srovnání získáme z predikcí uvnitř dat.

Interakční koeficient mění sklon samců vůči samicím

SKLON SAMIC

0,4067 mm/mm

ROZDÍL SKLONŮ SAMEC – SAMICE

−0,1245 mm/mm

$$\text{sklon samců} = 0{,}4067 + (-0{,}1245) \approx 0{,}282\ \text{mm/mm}$$

95% interval spolehlivosti rozdílu sklonů: −0,151 až −0,098 mm/mm

Rozdíl při 30 mm skládají dva známé příspěvky

Rozdíl **samec – samice při 30 mm** tvoří:

1. rozdíl mezi pohlavími při délce 0 mm: +1,9731 mm;
2. 30 mm × změna rozdílu o −0,1245 mm na každý milimetr délky.

$$\text{rozdíl při } 30\ \text{mm} = 1{,}9731 + 30 \times (-0{,}1245) \approx \mathbf{-1{,}76\ mm}$$

Obecně pro délku x, kde β_2 je řádek `pohlavisamec` a β_3 řádek `delka_krunyre_mm:pohlavisamec`:

$$\text{rozdíl}(x) = \beta_2 + \beta_3\, x$$

Je to stejný rozdíl, který jsme odečetli z predikcí.

Platí koeficient `pohlavisamec` při každé délce?

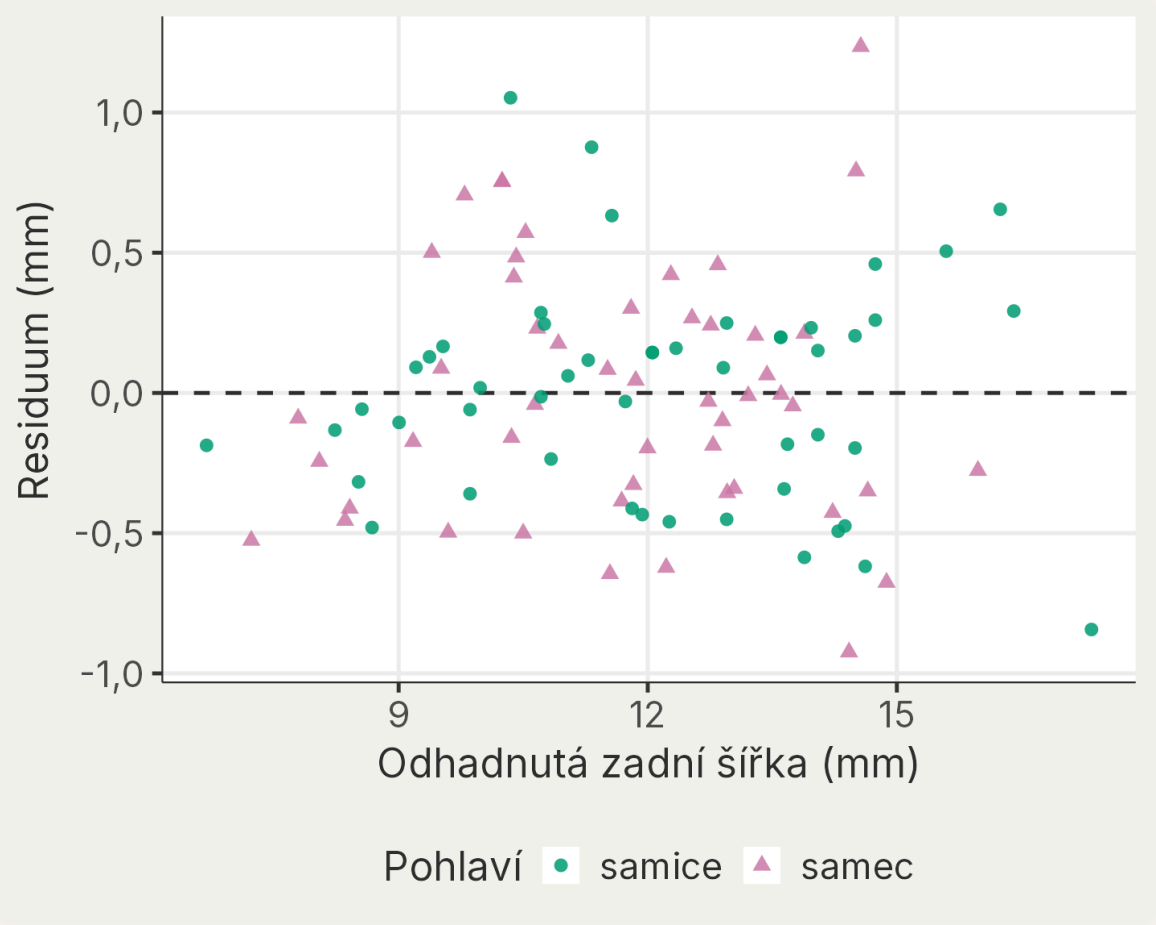
A) Ano, při každé délce.

B) Ne, pouze při délce 0 mm.

C) Ne, pouze při délce 30 mm.

Při jiné délce musíme přidat příspěvek interakčního koeficientu.

Jak dobře přímky popisují změřené kraby?



Residua leží kolem nuly **bez oblouku** a s podobným rozptylem u malých i velkých krabů.

Graf neověří příčinu ani platnost mimo pozorované délky.

Co víme o rozdílu mezi samicemi a samci modré formy?

Bude rozdíl v zadní šířce mezi stejně dlouhou samicí a samcem stejný u malých i velkých krabů?

CO DATA UKAZUJÍ

- Sklon samic 0,407, samců 0,282 mm/mm.
- Rozdíl samec − samice se mění o −0,124 mm na 1 mm délky (95% interval spolehlivosti −0,151 až −0,098).
- Při 30 mm: samec − samice −1,76 mm.

CO ZŮSTÁVÁ OTEVŘENÉ

- Proč se pohlaví liší: data jsou pozorovací.
- Platí to i pro kraby mimo tento výběr?
- A pro kraby menší nebo větší, než jsme změřili?

Když jsou oba prediktory skupiny

Liší se rozdíl mezi pohlavími u modré a oranžové formy?



ODEZVA
Délka krunýře (mm)

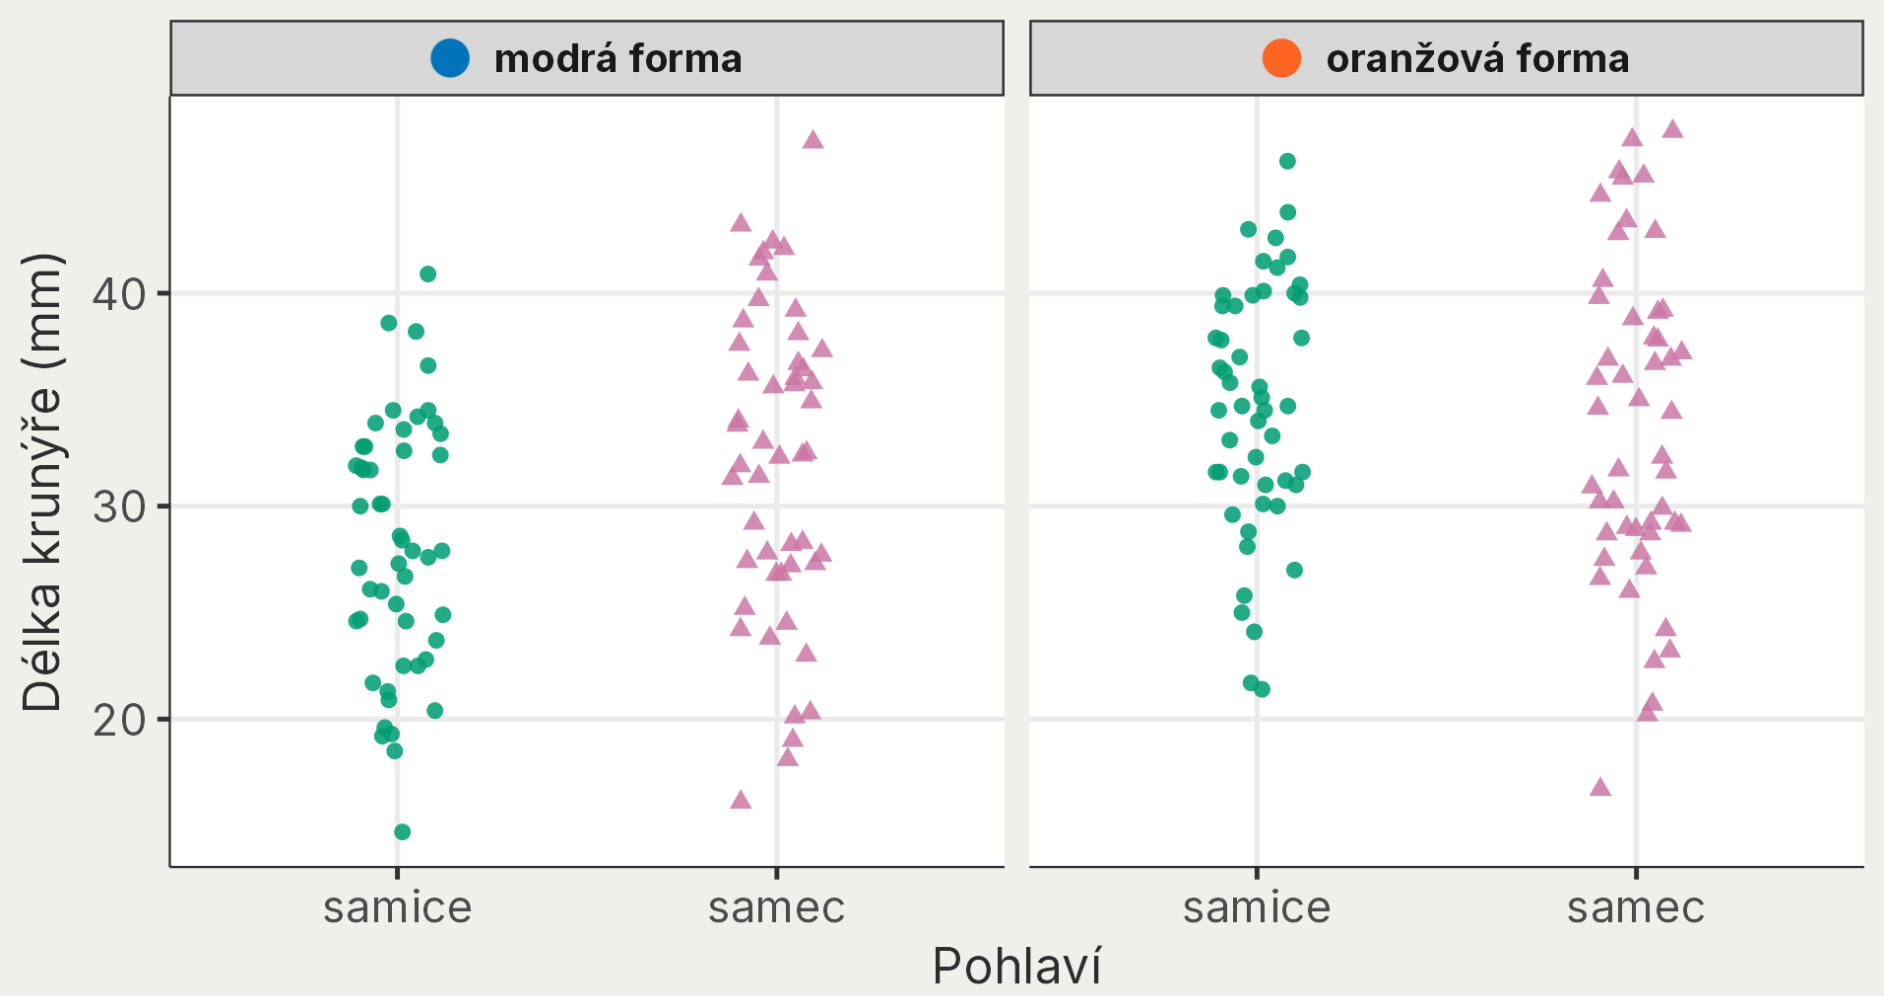
DVA KATEGORIÁLNÍ PREDIKTORY
Barevná forma · pohlaví

Mění se rozdíl **samec – samice** mezi barevnými formami?

Do každé skupiny vybrali autoři stejný počet krabů, takže průměrné délky závisejí i na výběru.

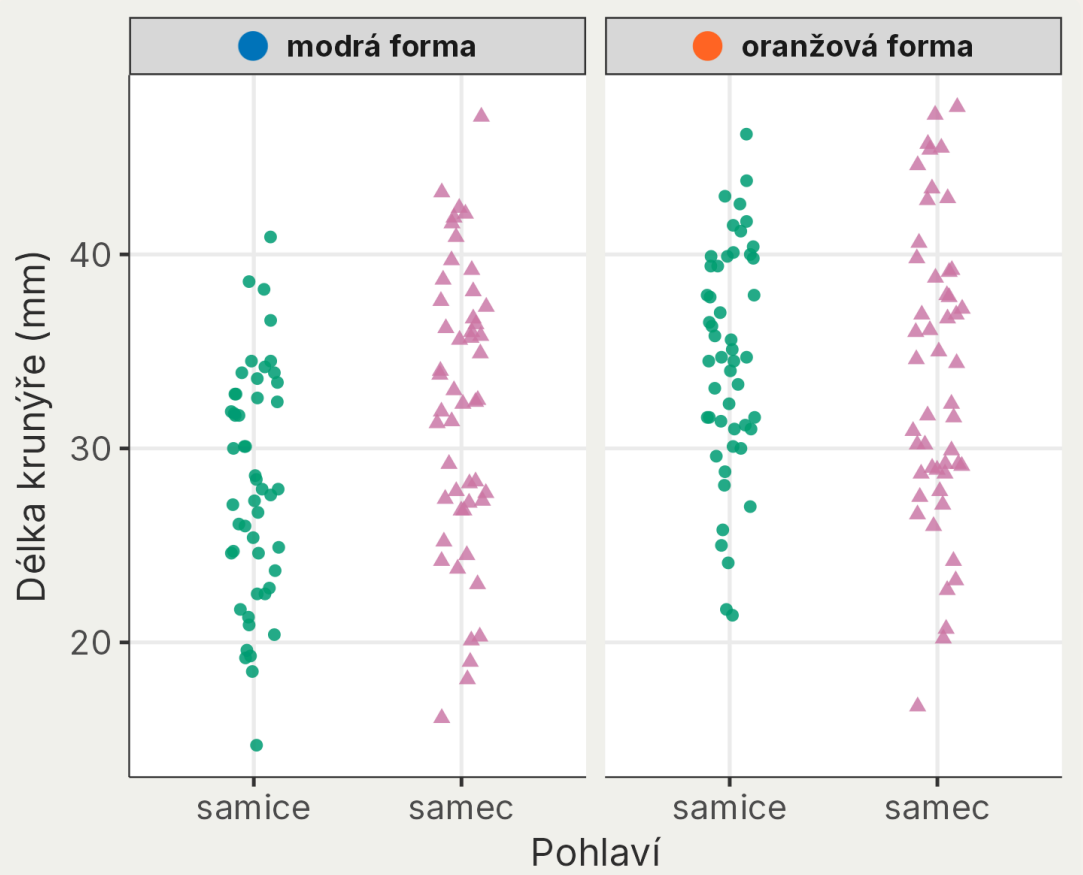
Ilustrace vytvořená pomocí AI.

Jaké délky vidíme ve čtyřech skupinách?



Každý bod je jeden krab. Autoři vybrali do každé skupiny 50 krabů.

Je rozdíl mezi samci a samicemi u obou forem stejný?

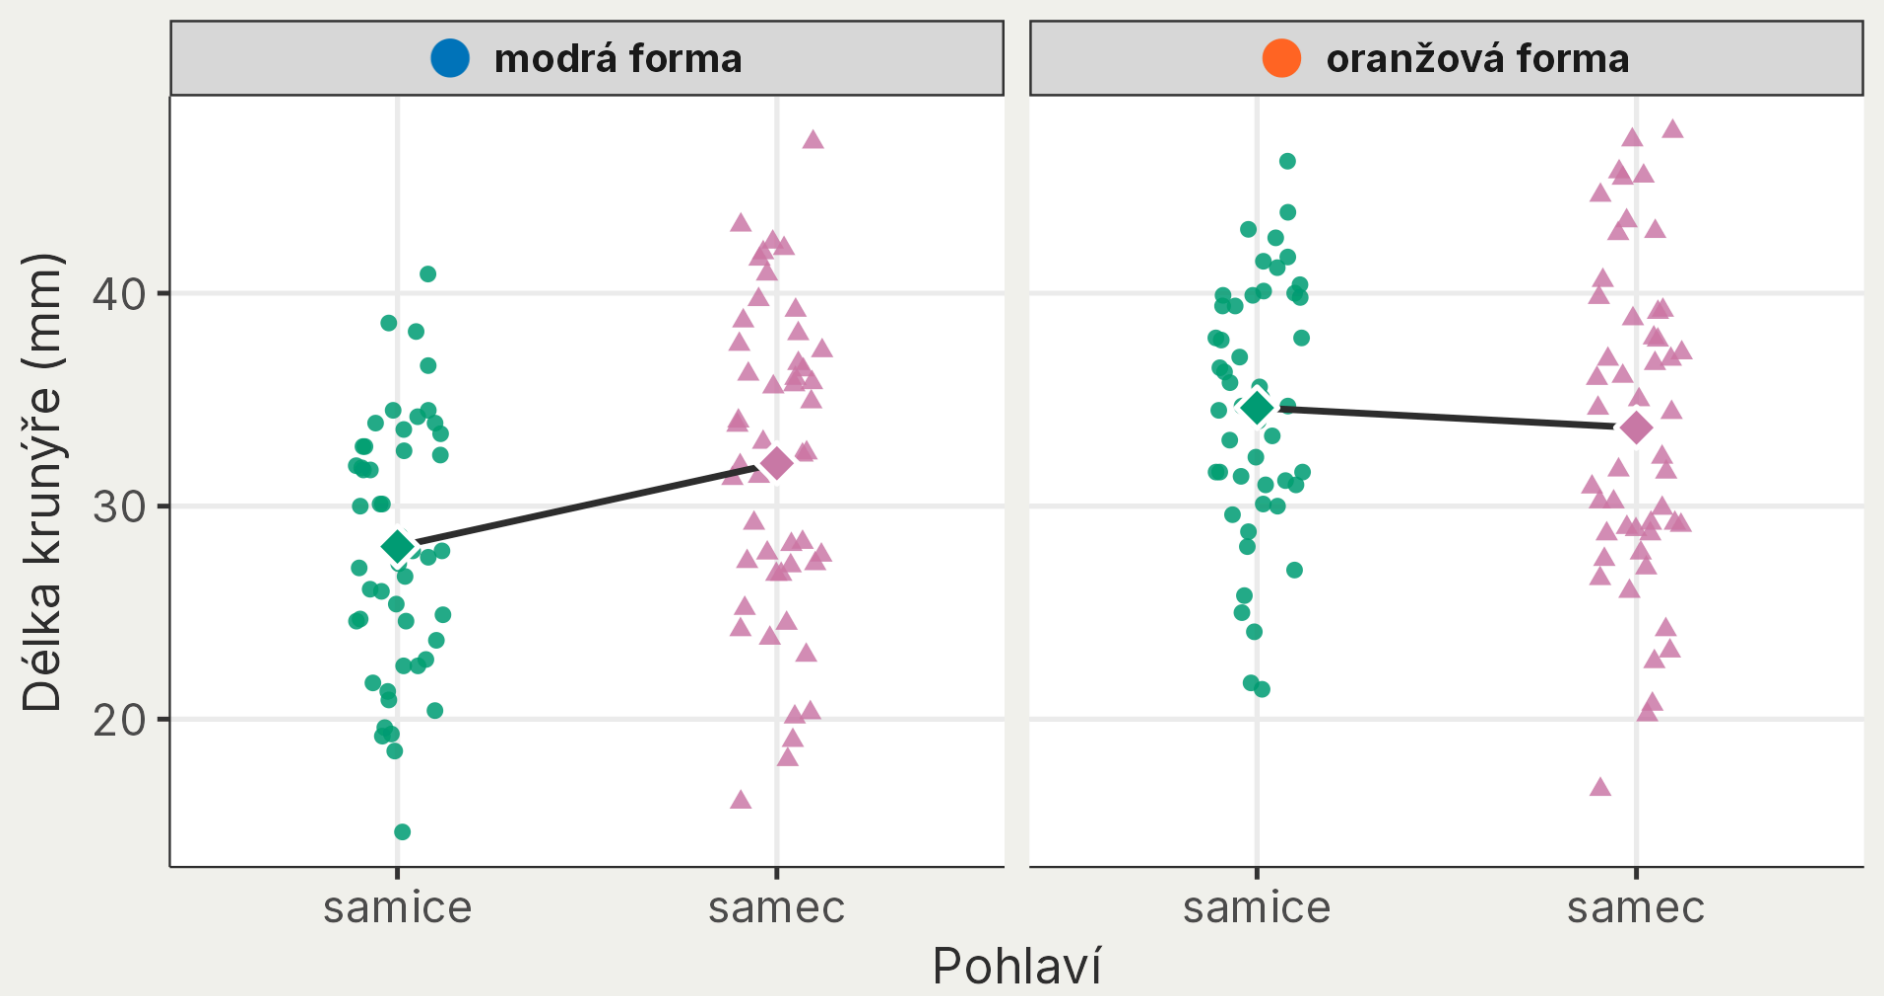


MINUTA BEZ HOVORU

Napište pro každou formu:

- kdo má vyšší průměr;
- zda čekáte podobně velký rozdíl;
- jednu větu, kterou z bodů říci nemůžeme.

Průměry ukazují dva různé rozdíly



Body, osy i náhodné posunutí jsou stejné. Přibyly pouze průměry a spojnice.

Jak velký je rozdíl samec minus samice v každé formě?

MODRÁ FORMA

$$32{,}01 - 28{,}10 = +\mathbf{3{,}91\ mm}$$

ORANŽOVÁ FORMA

$$33{,}69 - 34{,}62 = -\mathbf{0{,}93\ mm}$$

U modré formy jsou samci v průměru delší, u oranžové o něco kratší.

Interakce je rozdíl dvou rozdílů

Rozdíl dvou rozdílů Δ = rozdíl u 🟠 oranžové formy − rozdíl u 🔵 modré formy

$$\Delta = (-0{,}93) - (+3{,}91) = \mathbf{-4{,}84\ mm}$$

Rozdíl mezi pohlavími se při přechodu od modré k oranžové formě změní o **−4,84 mm**.

`forma * pohlavi` zapíše všechny čtyři kombinace

`forma + pohlavi + forma:pohlavi = forma * pohlavi`; referenční kombinace je modrá forma a samice.

```
mod_formy <-
  lm(
    formula = delka_krunyre_mm ~ forma * pohlavi,
    data = data_formy
  )

round(
  x = summary(object = mod_formy)$coefficients,
  digits = 3
)
```

```
                        Estimate Std. Error t value Pr(>|t|)
(Intercept)               28.102      0.950  29.584    0.000
formaoranžová              6.516      1.343   4.851    0.000
pohlavisamec               3.912      1.343   2.912    0.004
formaoranžová:pohlavisamec -4.842     1.900  -2.549    0.012
```

Který údaj je rozdíl samec − samice v oranžové formě?

Koeficient	Odhad (mm)
`(Intercept)`	28,102
`formaoranžová`	+6,516
`pohlavisamec`	+3,912
`formaoranžová:pohlavisamec`	−4,842

A) `pohlavisamec`

B) `formaoranžová:pohlavisamec`

C) `pohlavisamec` + `formaoranžová:pohlavisamec`

D) `formaoranžová`

+3,91 + (−4,84) = **−0,93 mm**: stejný rozdíl, jaký jsme spočítali z průměrů oranžové formy.

Co znamená každý ze čtyř koeficientů?

`(Intercept)`: 🔵 modrá samice

28,10 mm

`pohlavisamec`: samec − samice v 🔵 modré formě

+3,91 mm

`formaoranžová`: 🟠 oranžová − 🔵 modrá mezi samicemi

+6,52 mm

`formaoranžová:pohlavisamec`: změna rozdílu mezi formami

−4,84 mm

95% interval spolehlivosti interakce: −8,59 až −1,10 mm

Odhad pro každou ze čtyř skupin

```r
prumery_formy <-
  emmeans::emmeans(
    object = mod_formy,
    specs = ~ pohlavi | forma
  )

prumery_formy
```

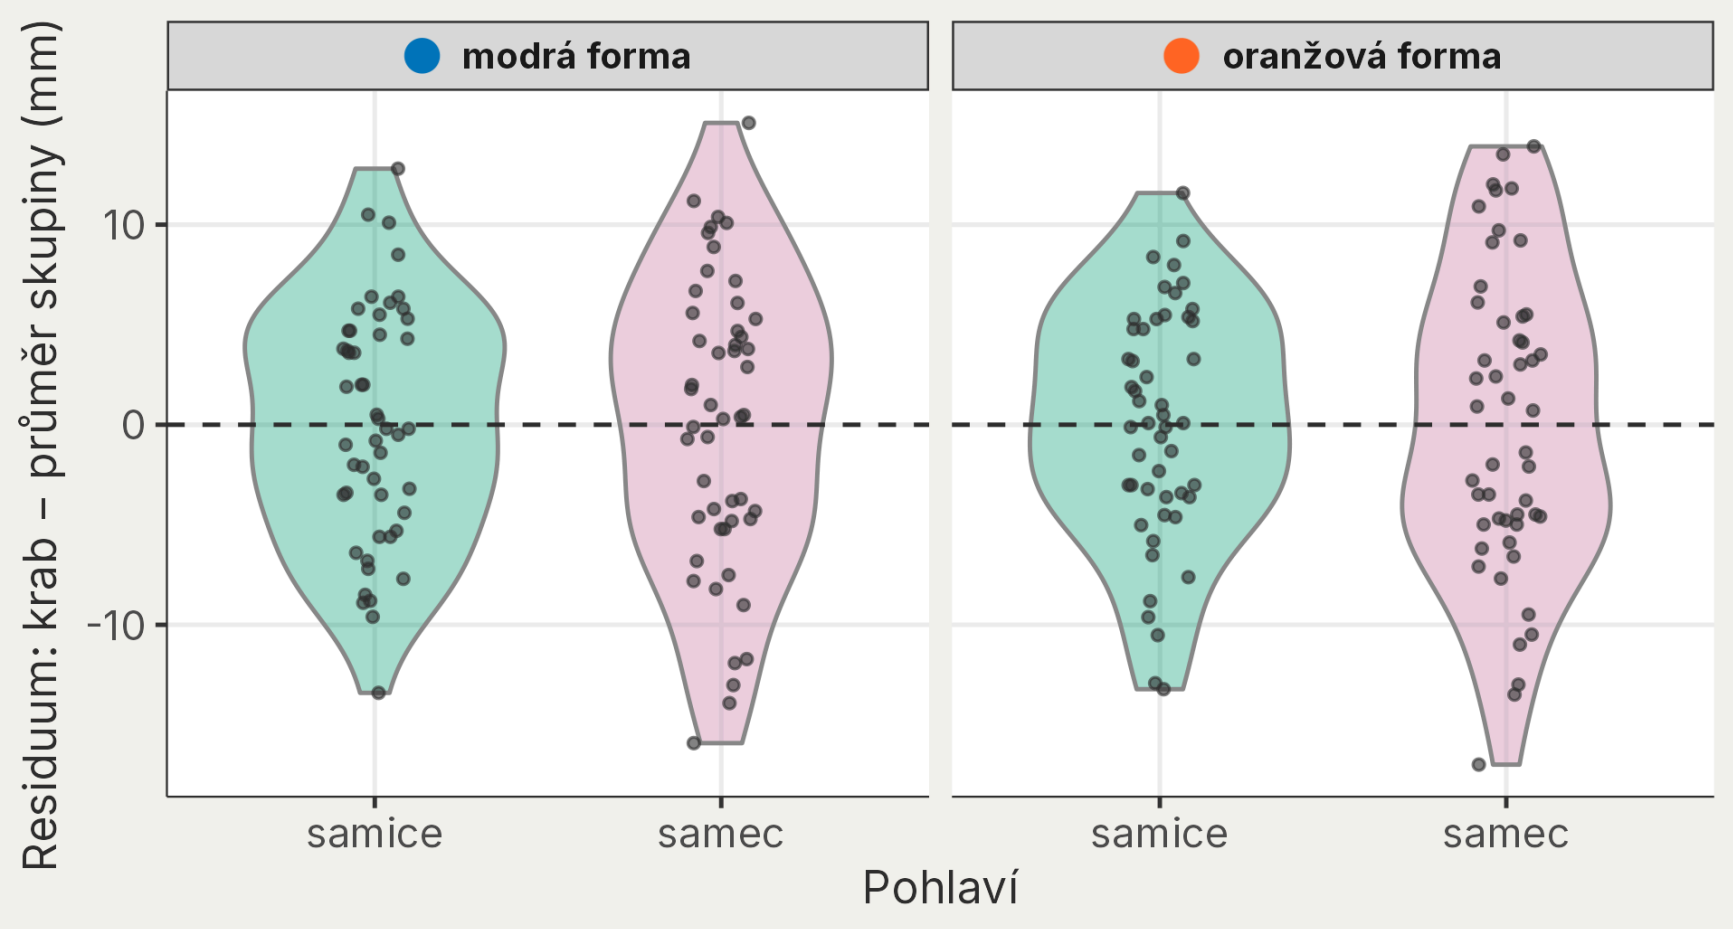
```
forma = modrá:
 pohlavi emmean   SE  df lower.CL upper.CL
 samice    28.1 0.95 196     26.2     30.0
 samec     32.0 0.95 196     30.1     33.9

forma = oranžová:
 pohlavi emmean   SE  df lower.CL upper.CL
 samice    34.6 0.95 196     32.7     36.5
 samec     33.7 0.95 196     31.8     35.6

Confidence level used: 0.95
```

Model má jeden parametr pro každou kombinaci, proto odhady odpovídají pozorovaným skupinovým průměrům.

Residua jsou odchylky jednotlivých krabů od skupinových průměrů



Residuum = délka kraba – průměr jeho skupiny.

Rozdíl mezi pohlavími závisí na barevné formě

- 🔵 Modrá forma: samec − samice = **+3,91 mm**
- 🟠 Oranžová forma: samec − samice = **−0,93 mm**
- Změna rozdílu: **−4,84 mm**; 95% interval spolehlivosti −8,59 až −1,10 mm

Průměrné délky závisejí i na tom, které kraby autoři vybrali. Výsledek popisuje tento soubor, ne velikost krabů v přírodě.

Když jsou oba prediktory čísla

Přibude vysokému stromu s každým centimetrem průměru víc dřeva?

STŘEMCHA POZDNÍ

- severoamerický, u nás invazní strom
- objem dřeva z **průměru kmene** a **výšky**
- 31 pokácených stromů, z amerických jednotek převedeno na cm, m a m^3

VE DVOJICI

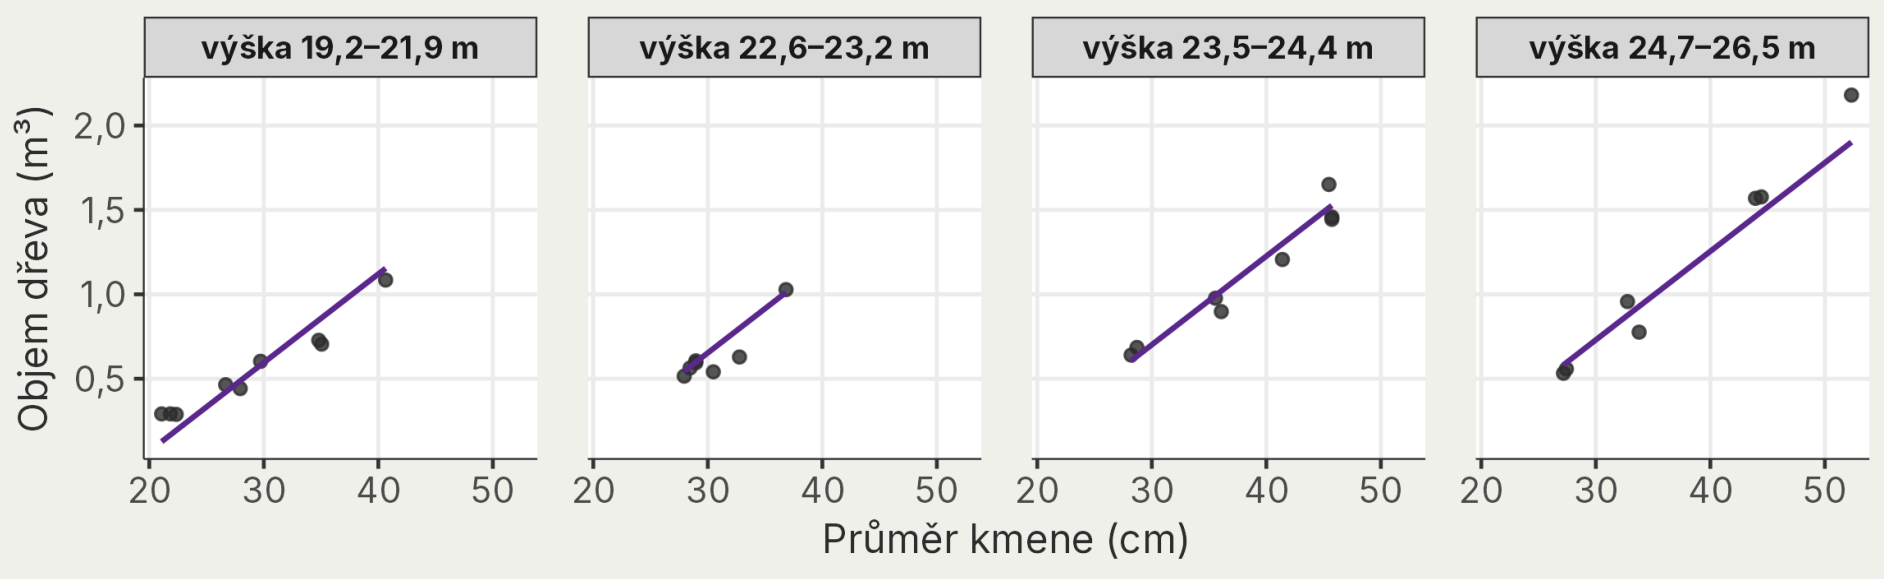
Dva stejně tlusté kmeny ztloustnou o 1 cm. Jeden strom je nízký, druhý vysoký.
Kterému přibude víc dřeva?

Vysokému: nová vrstva dřeva obalí delší kmen.

Meyer (1953), *Forest Mensuration* · `data/stromy.csv`

Vystihne společný sklon nízké i vysoké stromy?

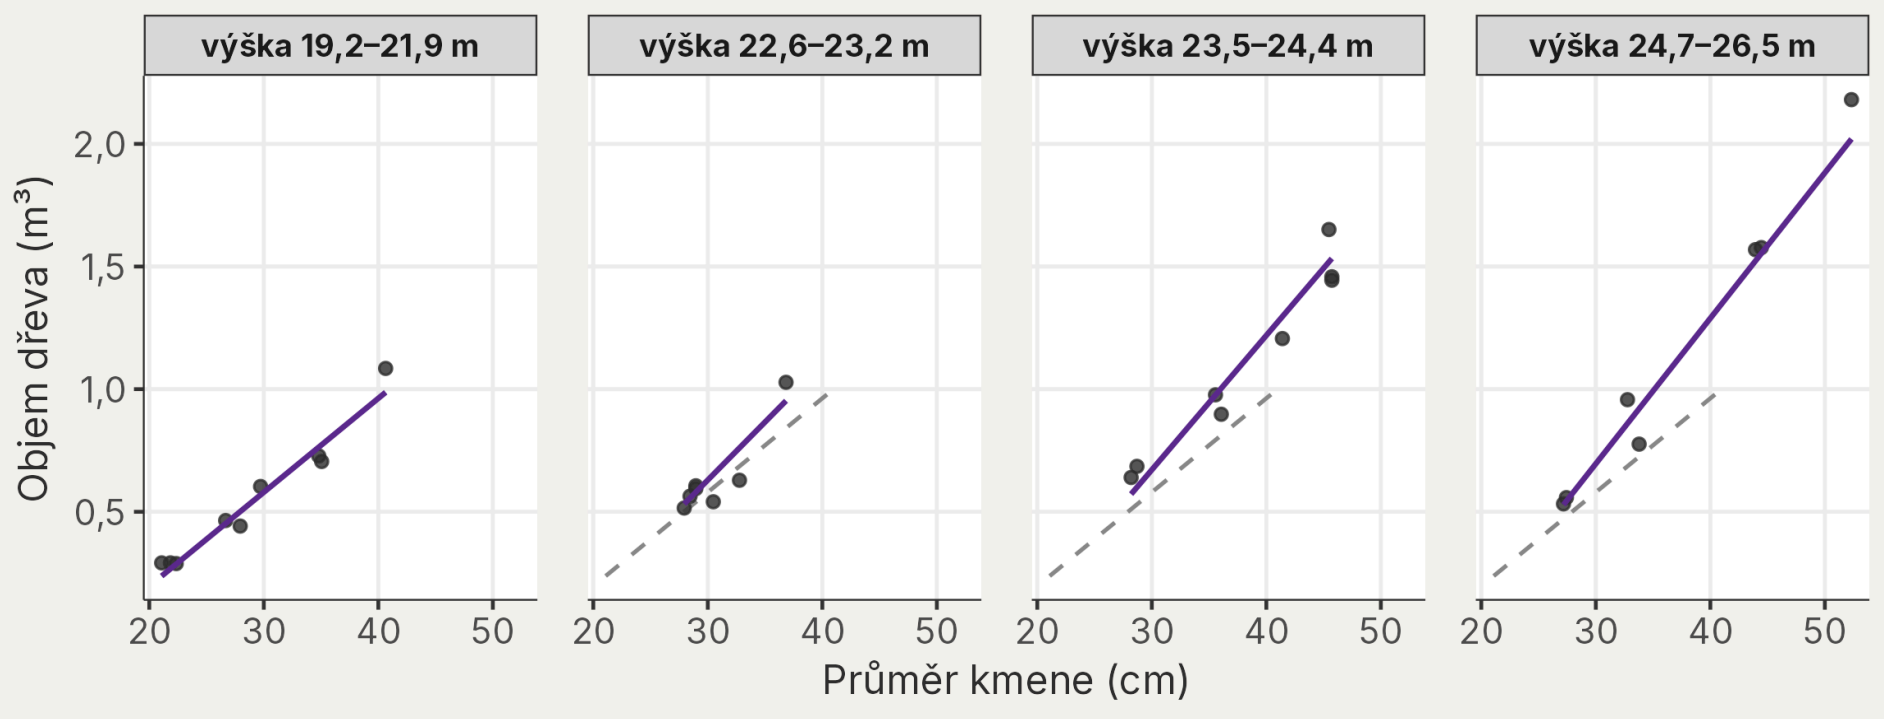
```
1  mod_aditivni <-
2    lm(
3      formula = objem_m3 ~ prumer_cm + vyska_m,
4      data = data_stromy
5    )
```



Ve dvojici: kde leží tenké a tlusté kmeny v krajních panelech?

Panel = výškové pásmo stromů · přímka = model při střední výšce panelu

Mění se sklon přímky s výškou stromu?



Čím vyšší strom, tím strmější přímka.

Šedá přerušovaná = přímka nejnižšího panelu · sklon = m³ na 1 cm průměru

`prumer_cm * vyska_m`: sklon průměru závisí na výšce

```
1  mod_stromy <-
2    lm(
3      formula = objem_m3 ~ prumer_cm * vyska_m,
4      data = data_stromy
5    )
6  round(x = coef(object = mod_stromy), digits = 5)
```

```
     (Intercept)         prumer_cm           vyska_m prumer_cm:vyska_m
         1.96508          -0.06528          -0.12050           0.00493
```

sklon průměru = `prumer_cm` + `prumer_cm:vyska_m` × výška

Výška stromu	21 m	23 m	25 m
Sklon průměru (m³ na 1 cm)	0,038	0,048	0,058

Pro který strom platí koeficient `prumer_cm`?

`prumer_cm` = **−0,065 m³ na 1 cm**

A) Pro každý změřený strom.

B) Jen pro nejnižší stromy v datech.

C) Pro žádný: tlustší kmen má méně dřeva.

D) Jen pro strom vysoký 0 m.

Takový strom v datech není. Sklon průměru proto uvádíme při zvolené výšce uvnitř dat.

Co víme o stromech?

Přibude vysokému stromu s každým centimetrem průměru víc dřeva?

CO DATA UKAZUJÍ

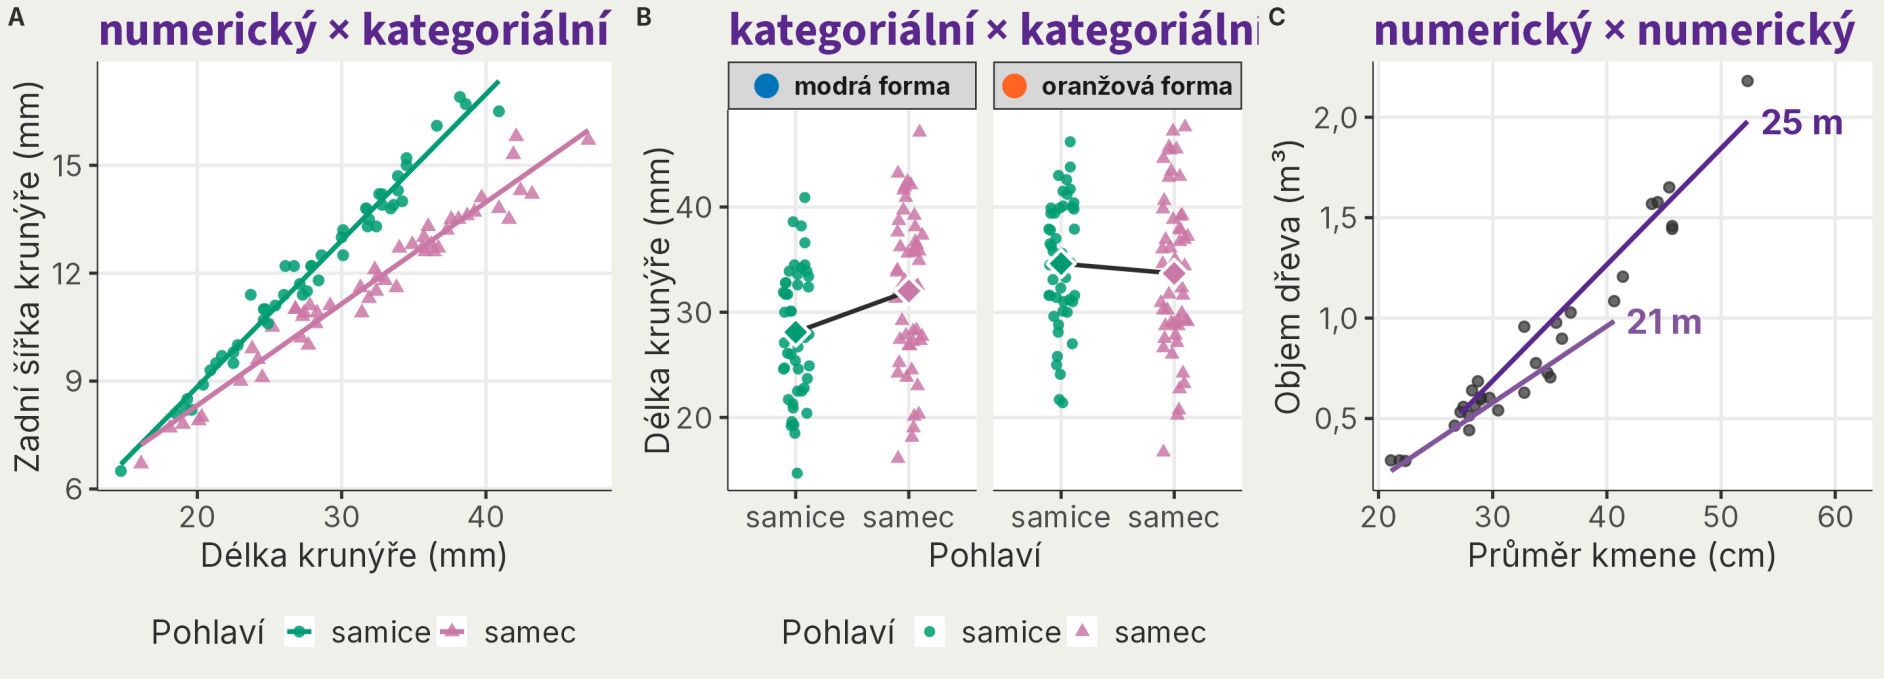
- Kmen 36 cm místo 28 cm podle modelu: +0,31 m³ při 21 m, +0,46 m³ při 25 m.
- Sklon průměru (m³ na 1 cm) roste o 0,0049 na každý 1 m výšky (95% interval spolehlivosti 0,0031 až 0,0068).

CO ZŮSTÁVÁ OTEVŘENÉ

- 31 stromů bez popsaného výběru.
- Residua ani vliv jednotlivých stromů jsme nekontrolovali.
- Nepopsal by vztah lépe zakřivený model?

Jedna myšlenka, tři obrazy

Interakce mění sklon nebo skupinový rozdíl



Co se mění? Rozdíl mezi přímkami podél osy délky.

Co se mění? Rozdíl mezi pohlavími podle formy.

Co se mění? Sklon průměru s výškou stromu.

Co musíme doplnit, aby tvrzení o efektu bylo úplné?

NEÚPLNÉ

„Délka má efekt.“
„Samci jsou větší.“
„Průměr kmene má efekt.“

OPRAVTE TVRZENÍ

- Pro které pohlaví?
- Při jaké délce?
- V které barevné formě?
- Větší v jakém znaku?
- Při jaké výšce?

V modelu s interakcí vždy uvádíme hodnotu nebo úroveň druhého prediktoru.

Jak číst model s interakcí?

1. OTÁZKA

Mění se vztah nebo rozdíl podle druhého prediktoru?

2. DATA A PREDIKCE

Ukažte body a predikce pro konkrétní kombinace.

3. KOEFICIENTY

Hlavní koeficient platí v referenční skupině nebo při nule druhého prediktoru.

4. ZÁVĚR

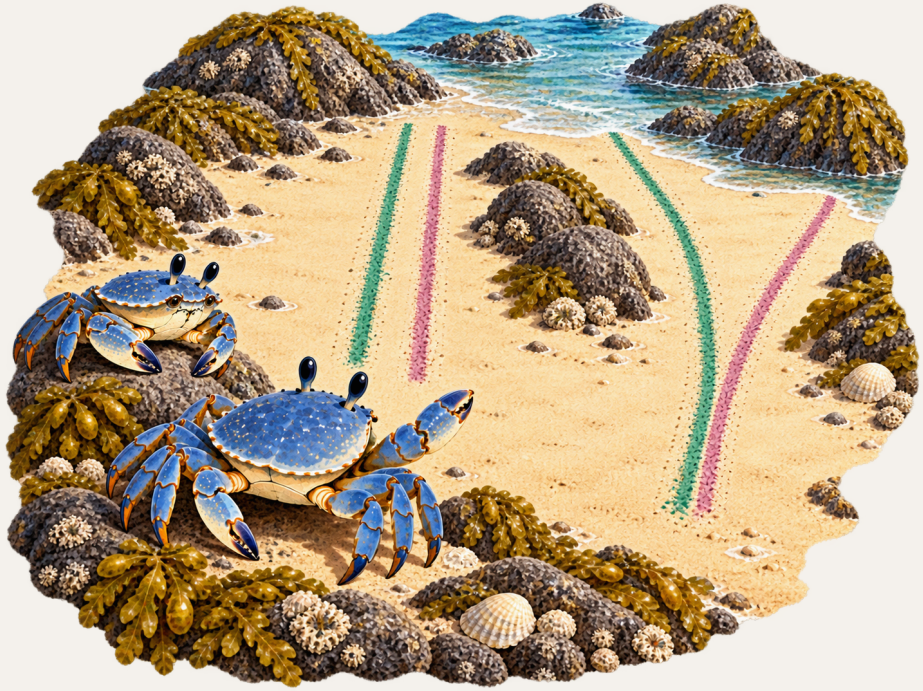
Jen v rozsahu dat a jako souvislost, ne příčina.

Co si odnést

- Interakci potřebujeme, když vztah jednoho prediktoru závisí na druhém; podpořit ji má biologická otázka i graf.
- `x * y` je zkratka pro `x + y + x:y`.
- Hlavní koeficienty jsou podmíněné; skupiny porovnáváme pomocí predikcí při zvolené hodnotě.
- U dvou kategoriálních prediktorů je interakce rozdíl dvou rozdílů.
- U dvou numerických prediktorů se sklon jednoho plynule mění s hodnotou druhého.
- Závěr omezujeme na pozorovaný rozsah a na souvislost v pozorovacích datech.

Data: Campbell, N. A. a Mahon, R. J. (1974) · Meyer, H. A. (1953) · `data/krabi.csv`, `data/stromy.csv`

Který biologicky smysluplný model máme zvolit?



Ilustrace vytvořená pomocí AI.

Aditivní kandidát

```
zadni_sirka_mm ~
delka_krunyre_mm + pohlavi
```

Stálý rozdíl

Interakční kandidát

```
zadni_sirka_mm ~
delka_krunyre_mm * pohlavi
```

Měnící se rozdíl

Jak mezi kandidáty vybírat, ukáže následující lekce.

Kde byste čekali interakci vy?

Uveďte biologickou otázku, u které byste čekali, že vztah dvou znaků závisí na skupině nebo na hodnotě jiného znaku.
Jak by vypadal graf?