BIOSTATISTIKA

L08

# Liší se vztah délky a zadní šířky krunýře mezi samicemi a samci?



Interakce prediktorů

cuni-natur-biostatistics.github.io/materialy.html

Ilustrace vytvořená pomocí AI.

# Co vlastně na krabovi měříme?



Ilustrace vytvořená pomocí AI.

**Délka krunýře** a **zadní šířka krunýře** jsou dvě měření téhož kraba.

# Co si pamatujete z minulé lekce?

Odpovězte samostatně na tři krátké otázky. Společné odpovědi projdeme po hlasování.

# Proč se po přidání maximální teploty změnil sklon roční teploty i jeho SE?

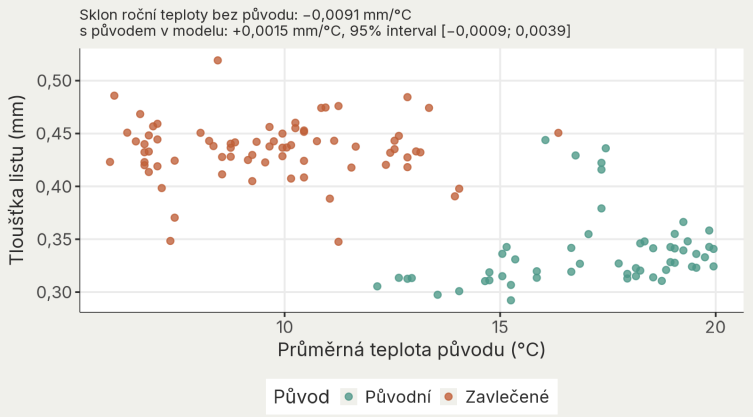
```
> round(coef(summary(mod_rocni_teplota))[, 1:2], 4)
                Estimate Std. Error
(Intercept)       0.5105     0.0115
teplota_rocni_C  -0.0091     0.0008
> round(coef(summary(mod_dve_teploty))[, 1:2], 4)
                Estimate Std. Error
(Intercept)       0.5899     0.0301
teplota_rocni_C  -0.0053     0.0016
teplota_max_C    -0.0048     0.0017
> c(nobs(mod_rocni_teplota), nobs(mod_dve_teploty))
[1] 128 128
```

- První model byl chybný; až druhý ukazuje skutečný účinek roční teploty.
- Maximální teplota stojí ve formuli druhá, a proto převzala část efektu.
- Koeficient teď platí při stejné max. teplotě; obě teploty silně korelují.
- Po přidání prediktoru model použil méně populací než předtím.

**SPRÁVNÁ ODPOVĚĎ**

: Koeficient teď platí při stejné max. teplotě; obě teploty silně korelují.
Nový koeficient odpovídá na užší otázku při stejné maximální teplotě (r ≈ 0,85) a tu nese málo populací, proto SE roste.
Pořadí ve formuli koeficienty nemění.

# S původem v modelu změnil sklon roční teploty znaménko. Proč?




Celkový sklon mísil rozdíl obou původů, které žijí v různě teplých oblastech.

Roční teplota ve skutečnosti list zesiluje, první model měl opačné znaménko.

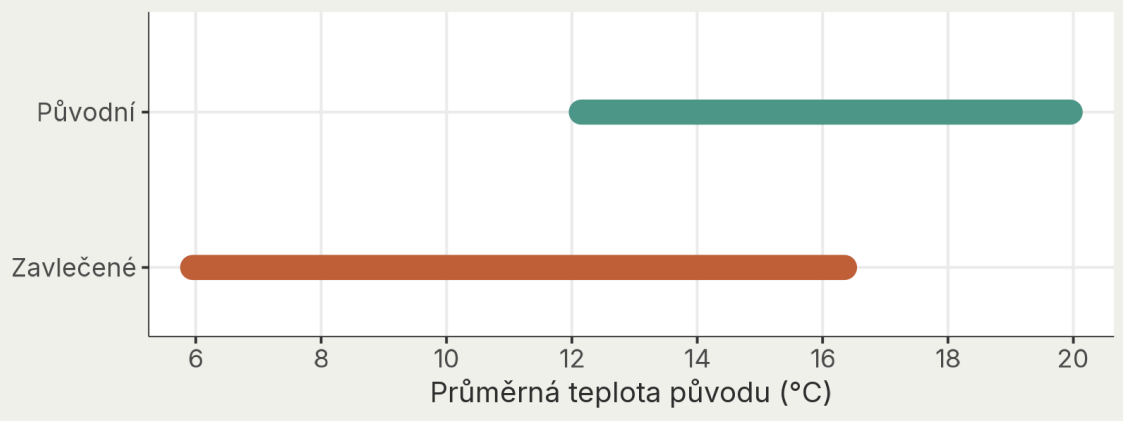
Podmíněný sklon je nevýznamný, roční teplota tedy na list nemá vliv.

Původ a roční teplota spolu nesouvisejí, změna je jen výběrová variabilita.

**SPRÁVNÁ ODPOVĚĎ**

: Celkový sklon mísil rozdíl obou původů, které žijí v různě teplých oblastech.
Zavlečené populace mají tlustší listy a pocházejí z chladnějších oblastí. Původ je konfundující proměnná; uvnitř původu je vztah slabý a jeho interval zahrnuje nulu.

# Chceme porovnat zavlečené a původní populace při roční teplotě 8 °C. Co platí?




- 8 °C leží v rozsahu všech populací (6–20 °C), odhad je proto podložený.
- Původní populace pod 12 °C nemáme; rozdíl při 8 °C stojí na extrapolaci.
- Aditivní model dává stejný rozdíl při každé teplotě, takže na 8 °C nezáleží.
- Model s původem a teplotou neumí předpovídat pro konkrétní teplotu.

**SPRÁVNÁ ODPOVĚĎ**

: Původní populace pod 12 °C nemáme; rozdíl při 8 °C stojí na extrapolaci.

Model rozdíl vypočte při každé teplotě, ale data ho podporují jen v překryvu obou skupin, asi 12–16 °C. Při 8 °C existují jen zavlečené populace.

# Výsledky učení

Po absolvování této přednášky budete schopni:

- rozpoznat biologickou otázku, ve které vztah jednoho prediktoru k odezvě závisí na druhém prediktoru;
- fitovat model s interakcí a zobrazit jeho předpovědi pro kombinace číselných i skupinových prediktorů;
- vyložit koeficienty modelu s interakcí jako podmíněné a porovnávat skupiny nebo různé hodnoty prediktoru pomocí předpovědí;
- vysvětlit interakci dvou skupinových prediktorů jako rozdíl dvou rozdílů;
- omezit závěr na pozorovaný rozsah dat a na souvislost v pozorovacích datech.

# Platí rovnoběžné přímky i pro kraby?

# Proč by se samice a samci mohli lišit tvarem krunýře?

**CO VÍME O KRABECH**

- Zadní část krunýře leží zhruba nad zadečkem.
- Samice pod zadečkem nosí vajíčka.
- Samice a samci se liší poměrem zadní šířky a délky krunýře.

Bude rozdíl v zadní šířce mezi stejně dlouhou samicí a samcem stejný u malých i velkých krabů?

Campbell a Mahon (1974), *Australian Journal of Zoology* 22: 417–425.

# Jeden bod představuje jednoho kraba

```r
data_krabi_vse <-
  read.csv(file = "data/krabi.csv")

# Modrá forma, pohlaví, délka a zadní šířka
data_krabi <-
  data_krabi_vse[
    data_krabi_vse$sp == "B",
    c("sex", "CL", "RW")
  ]
names(data_krabi) <-
  c("pohlavi", "delka_krunyre_mm",
    "zadni_sirka_mm")
data_krabi$pohlavi <-
  factor(
    x = data_krabi$pohlavi,
    levels = c("F", "M"),
    labels = c("samice", "samec")
  )
head(x = data_krabi, n = 3)
```

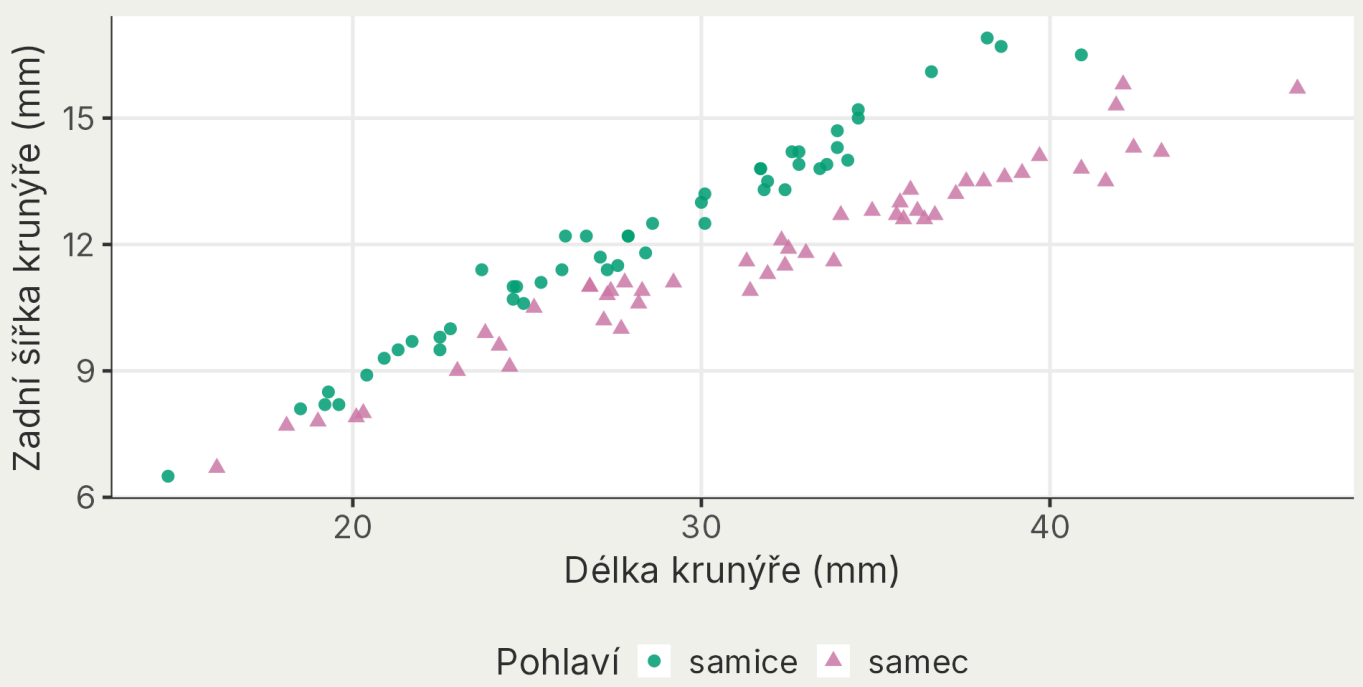
```
  pohlavi delka_krunyre_mm zadni_sirka_mm
1   samec             16.1            6.7
2   samec             18.1            7.7
3   samec             19.0            7.8
```

**100 KRABŮ**

- 🔵 modrá barevná forma
- 50 samic · 50 samců
- délka krunýře v mm
- zadní šířka v mm

Campbell a Mahon (1974) · `data/krabi.csv`

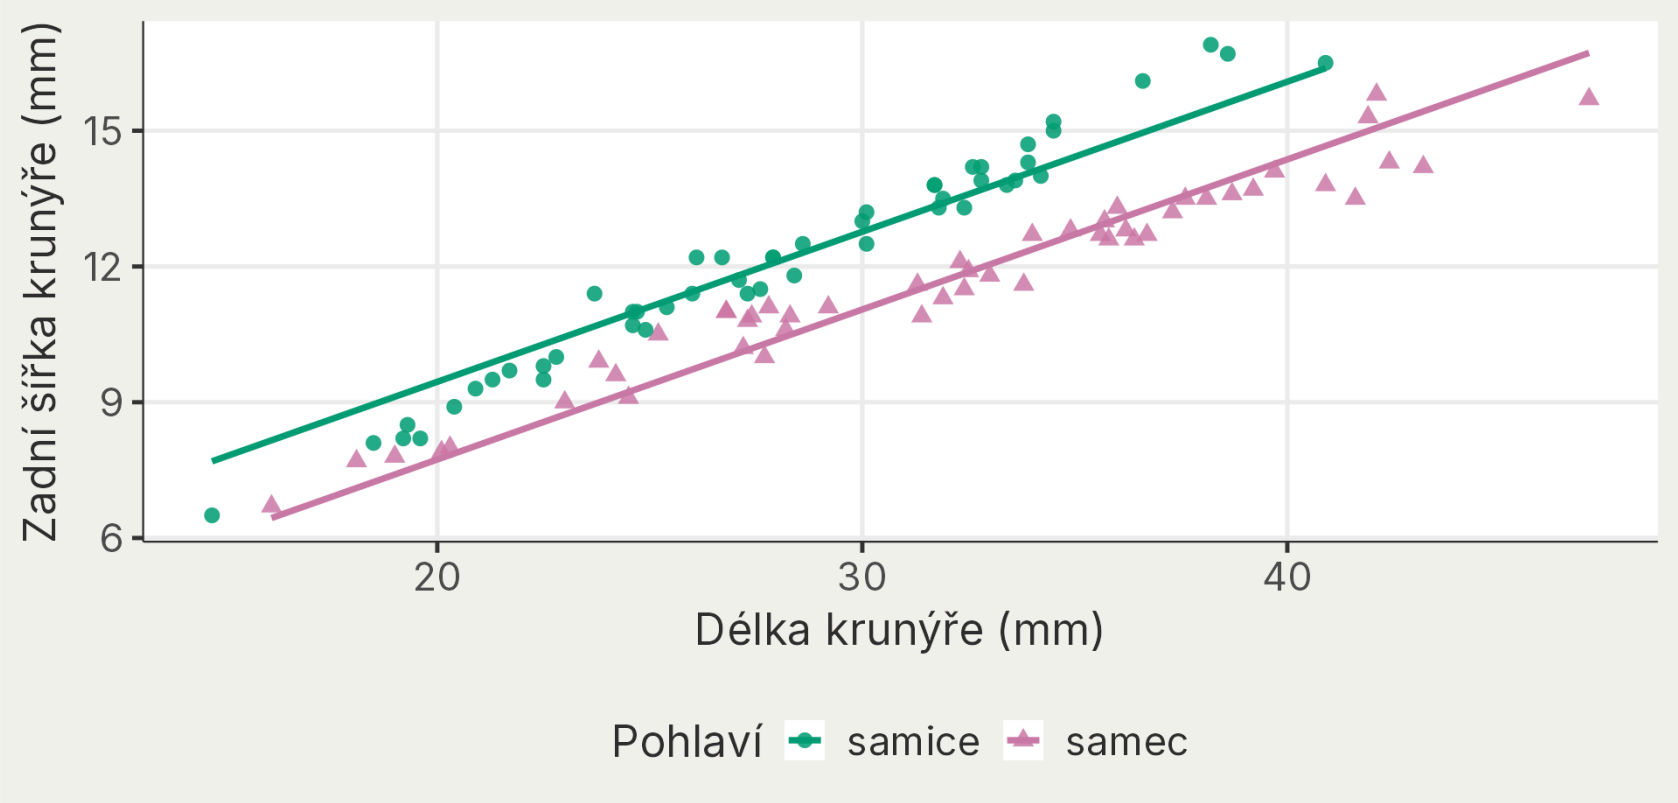
# Co naznačují měření krabů?




1. Jaký je směr vztahu?
2. Kde se skupiny překrývají?
3. Vypadají oba sklony stejně?

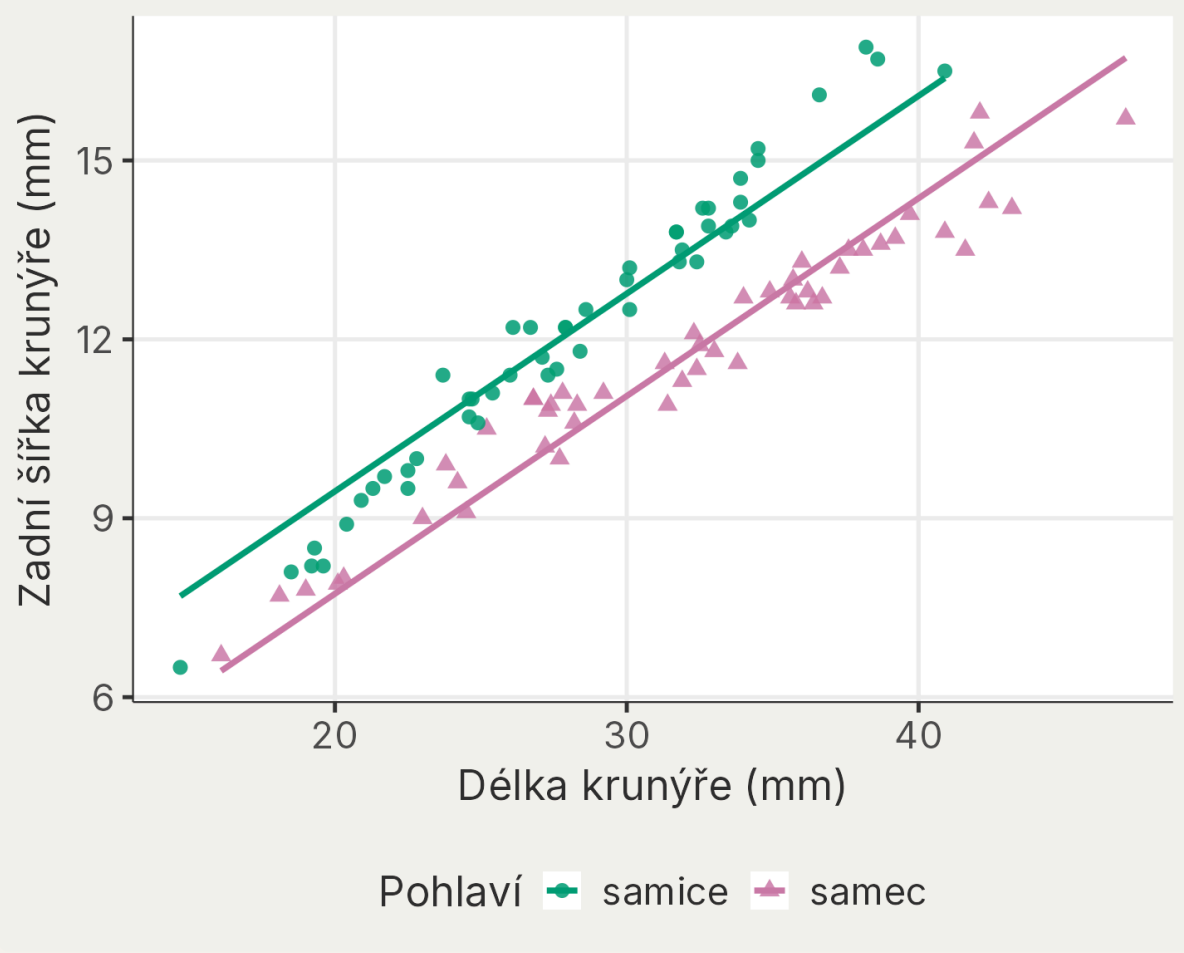
# Aditivní model kreslí rovnoběžné přímky

```
1  mod_rovnobezne <-
2    lm(
3      formula = zadni_sirka_mm ~ delka_krunyre_mm + pohlavi,
4      data = data_krabi
5    )
```




`+` dovoluje posun mezi skupinami, ale ukládá jim společný sklon.

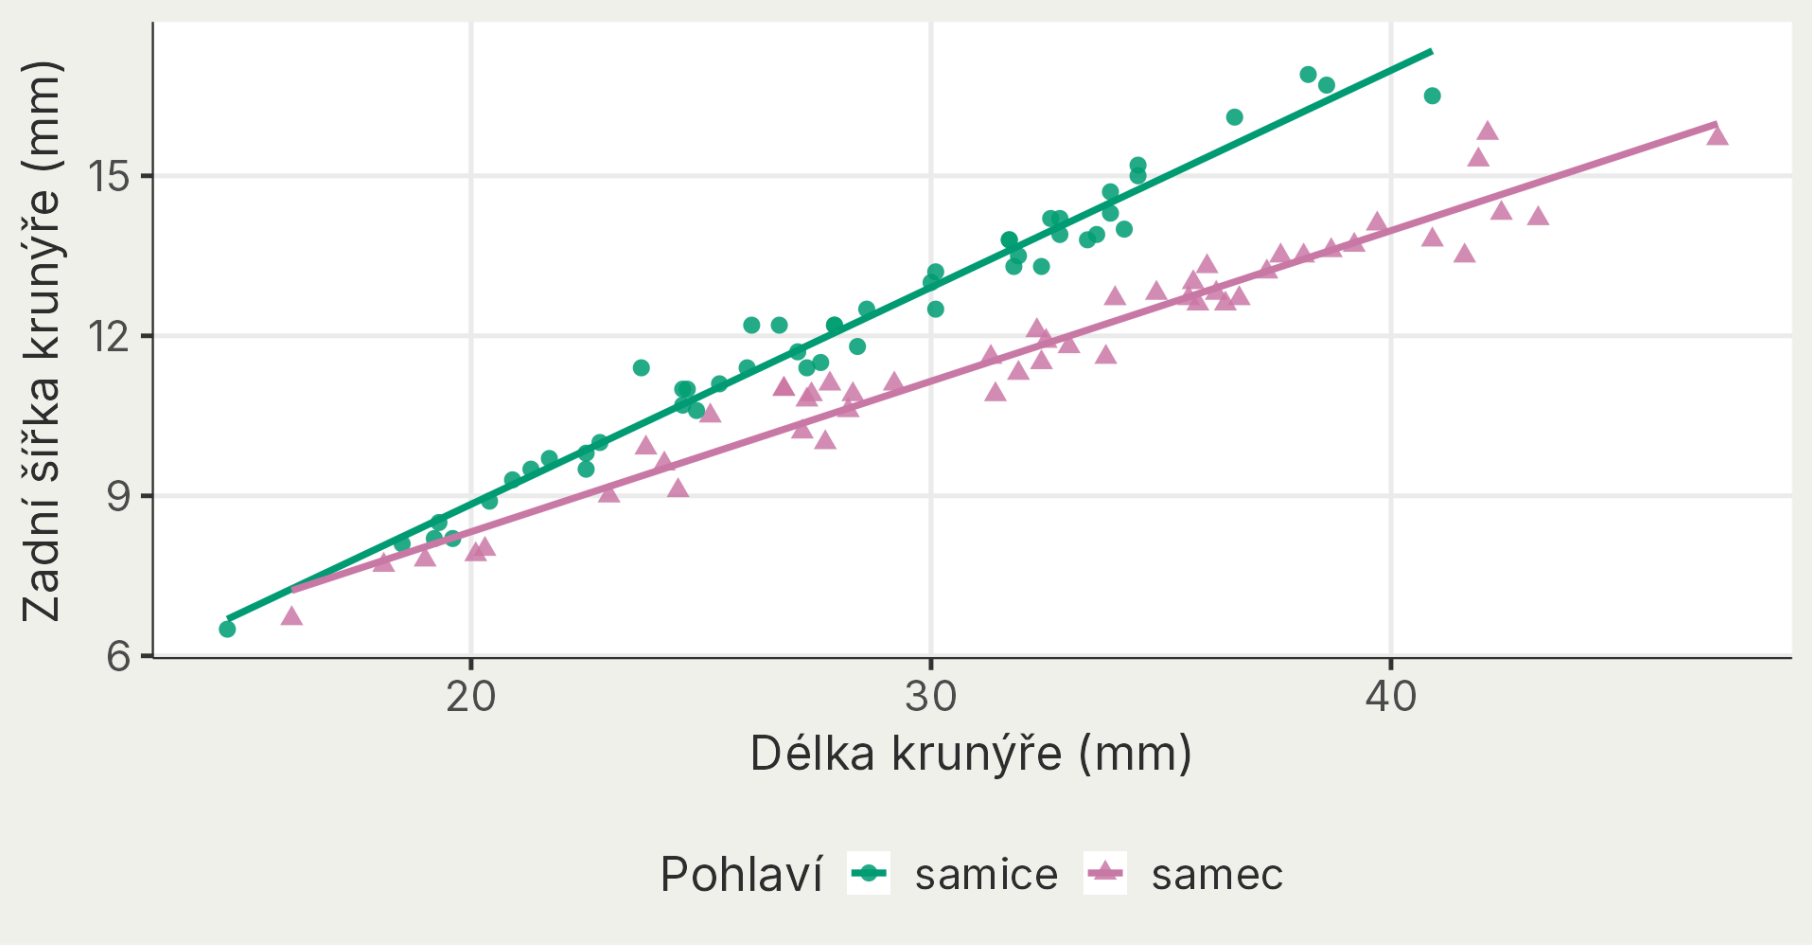
# Zůstává rozdíl mezi pohlavími při každé délce stejný?




**VE DVOJICI**

Porovnejte svislou vzdálenost přímek u kratších a delších krabů. Sedí přímky k bodům i na koncích rozsahu?

# Data naznačují různé sklony




**Svislá vzdálenost mezi přímkami se s délkou mění.**

# Když se rozdíl mění, mluvíme o interakci

**ADITIVNÍ MODEL**

Rozdíl mezi pohlavími je při každé délce stejný.
Rovnoběžné přímky

**MODEL S INTERAKCÍ**

Rozdíl mezi pohlavími se mění s délkou.
Různé sklony

**Interakce:** vztah délky a zadní šířky závisí na pohlaví.

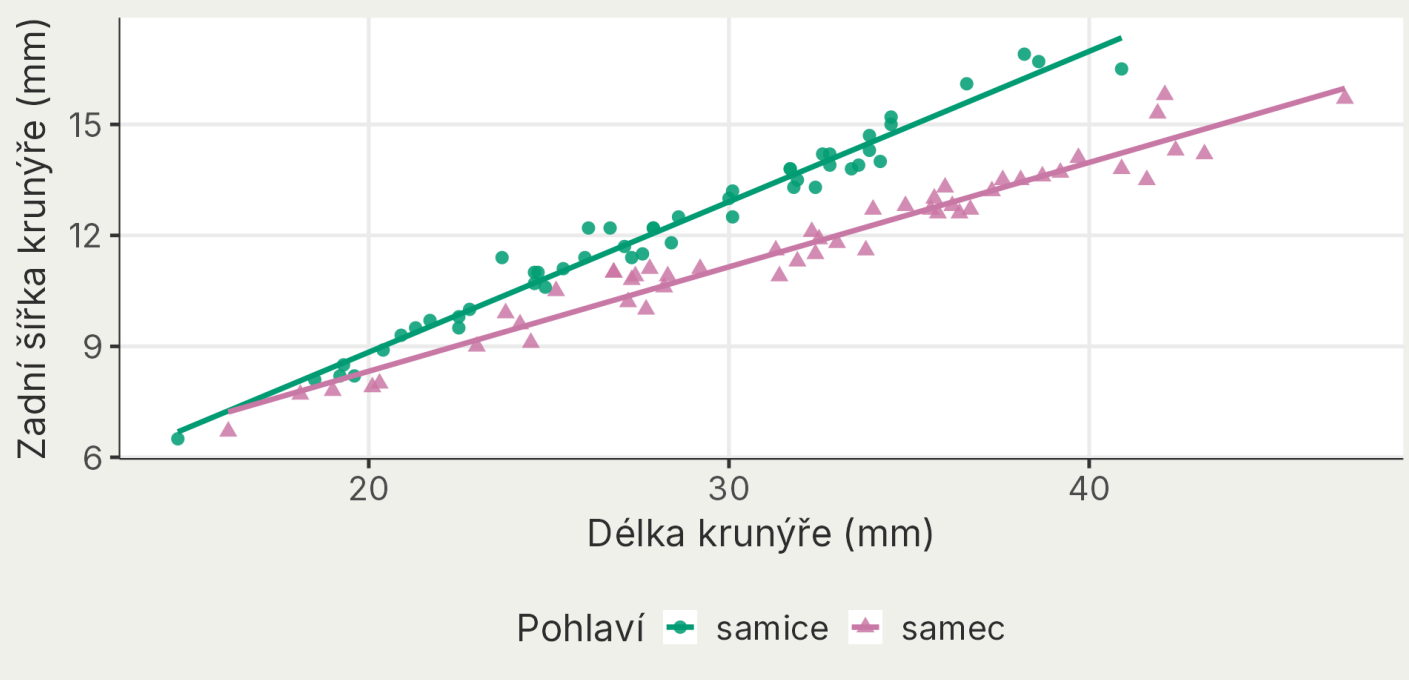
# Jak zapsat model s interakcí?

1. `zadni_sirka_mm ~ delka_krunyre_mm + pohlavi`
2. `zadni_sirka_mm ~ delka_krunyre_mm + pohlavi + delka_krunyre_mm:pohlavi`
3. `zadni_sirka_mm ~ delka_krunyre_mm * pohlavi`

> `x * y` je zkratka pro `x + y + x:y`; dvojtečka označuje interakční člen.

# Model s interakcí dovoluje dvěma pohlavím různé sklony

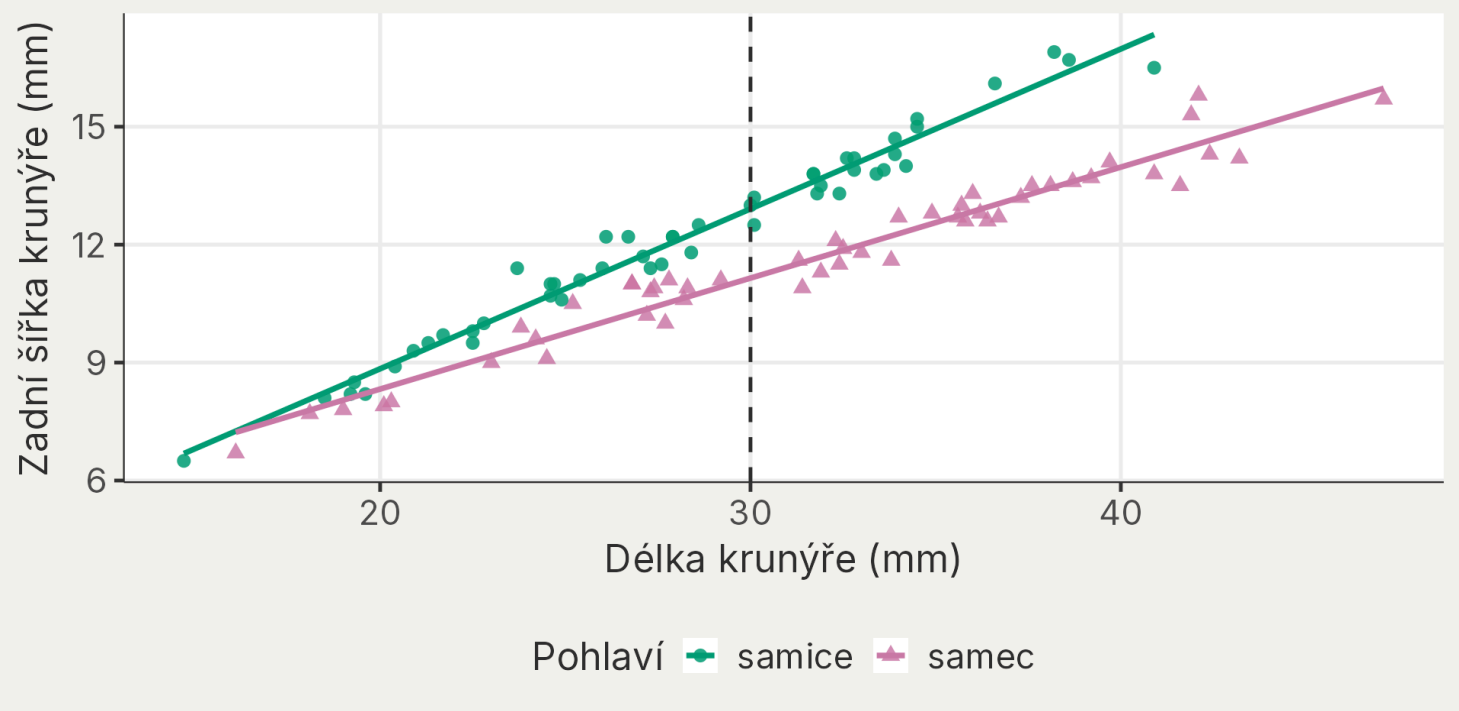
```
1  mod_interakce <-
2    lm(
3      formula = zadni_sirka_mm ~ delka_krunyre_mm * pohlavi,
4      data = data_krabi
5    )
```




Každou přímku kreslíme jen přes délky zastoupené v její skupině.

# Co model odhaduje pro dva stejně dlouhé kraby?

```
1  # Společná délka uvnitř rozsahu obou pohlaví
2  delka_porovnani_mm <- 30
```




**Která přímka je při 30 mm výše? O kolik přibližně?**

# Dva odhady při stejné délce krunýře

```r
data_porovnani <-
  data.frame(
    delka_krunyre_mm = rep(x = delka_porovnani_mm, times = 2),
    pohlavi = c("samice", "samec")
  )

data_porovnani$odhad_sirky_mm <-
  predict(
    object = mod_interakce,
    newdata = data_porovnani
  )

data_porovnani
```

```
  delka_krunyre_mm pohlavi odhad_sirky_mm
1               30  samice       12.91000
2               30   samec       11.14947
```

# Samec má při 30 mm užší zadní část krunýře

● **Samice**

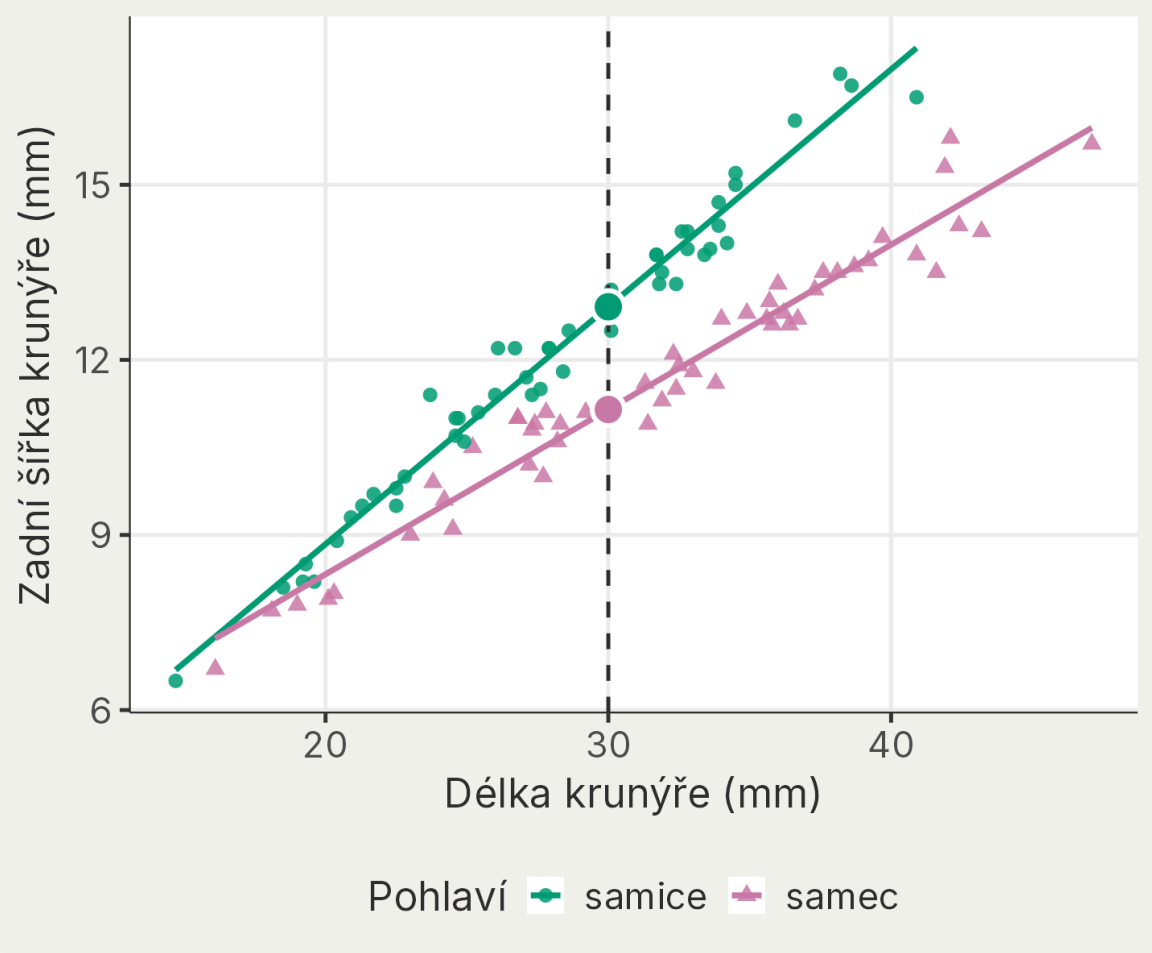
**12,91 mm**

▲ **Samec**

**11,15 mm**

**Samec – samice**

**−1,76 mm**



# Co už můžeme říci o stejně dlouhých krabech?

**CO VÍME**

- Zadní šířka roste s délkou u obou pohlaví.
- Samci mají pomalejší sklon.
- Při 30 mm má samec zadní šířku o 1,76 mm menší.

**CO JEŠTĚ NEVÍME**

- Jak tento výsledek vyjadřují koeficienty modelu?
- Jak přesně známe rozdíl sklonů?

# Koeficienty interakčního modelu

# Jaké jsou koeficienty v `summary()`?

```
souhrn_interakce <-
  summary(object = mod_interakce)

round(
  x = souhrn_interakce$coefficients,
  digits = 3
)
```

```
                            Estimate Std. Error t value Pr(>|t|)
(Intercept)                    0.708      0.294   2.409    0.018
delka_krunyre_mm               0.407      0.010  39.742    0.000
pohlavisamec                   1.973      0.400   4.928    0.000
delka_krunyre_mm:pohlavisamec -0.124      0.013  -9.450    0.000
```

Pro výklad nám stačí sloupec **Estimate**.

# První dva koeficienty popisují referenční samice

`(Intercept)`

## 0,708 mm

Odhad pro samici při délce **0 mm** (hypotetický krab).

`delka_krunyre_mm`

## +0,407 mm/mm

Sklon samičí přímky: samice delší o 1 mm má odhadem širší zadní část.

# Koeficient pohlaví porovnává skupiny při délce 0 mm

`pohlavisamec` = **+1,973 mm**

Rozdíl **samec – samice**, když `delka_krunyre_mm = 0`.

Není to:

- rozdíl při každé délce;
- rozdíl při 30 mm;
- průměrný rozdíl mezi všemi samci a samicemi.

**Biologicky smysluplné srovnání získáme z předpovědí uvnitř dat.**

# Interakční koeficient mění sklon samců vůči samicím

**SKLON SAMIC**

**0,4067 mm/mm**

**ROZDÍL SKLONŮ SAMEC – SAMICE**

**−0,1245 mm/mm**

$$\text{sklon samců} = 0{,}4067 + (-0{,}1245) \approx 0{,}282\ \text{mm/mm}$$

95% interval spolehlivosti rozdílu sklonů: −0,151 až −0,098 mm/mm

# Rozdíl při 30 mm skládají dva známé příspěvky

Rozdíl **samec – samice při 30 mm** tvoří:

1. rozdíl mezi pohlavími při délce 0 mm: +1,9731 mm;
2. 30 mm × změna rozdílu o −0,1245 mm na každý milimetr délky.

$$\text{rozdíl při } 30 \text{ mm} = 1{,}9731 + 30 \times (-0{,}1245) \approx \mathbf{-1{,}76 \text{ mm}}$$

Obecně pro délku $x$, kde $\beta$ označuje koeficient modelu:

$$\text{rozdíl}(x) = \beta_{\text{samec}} + x\,\beta_{\text{délka:samec}}$$

Je to stejný rozdíl, který jsme odečetli z předpovědí.

# Platí koeficient `pohlavisamec` při každé délce?

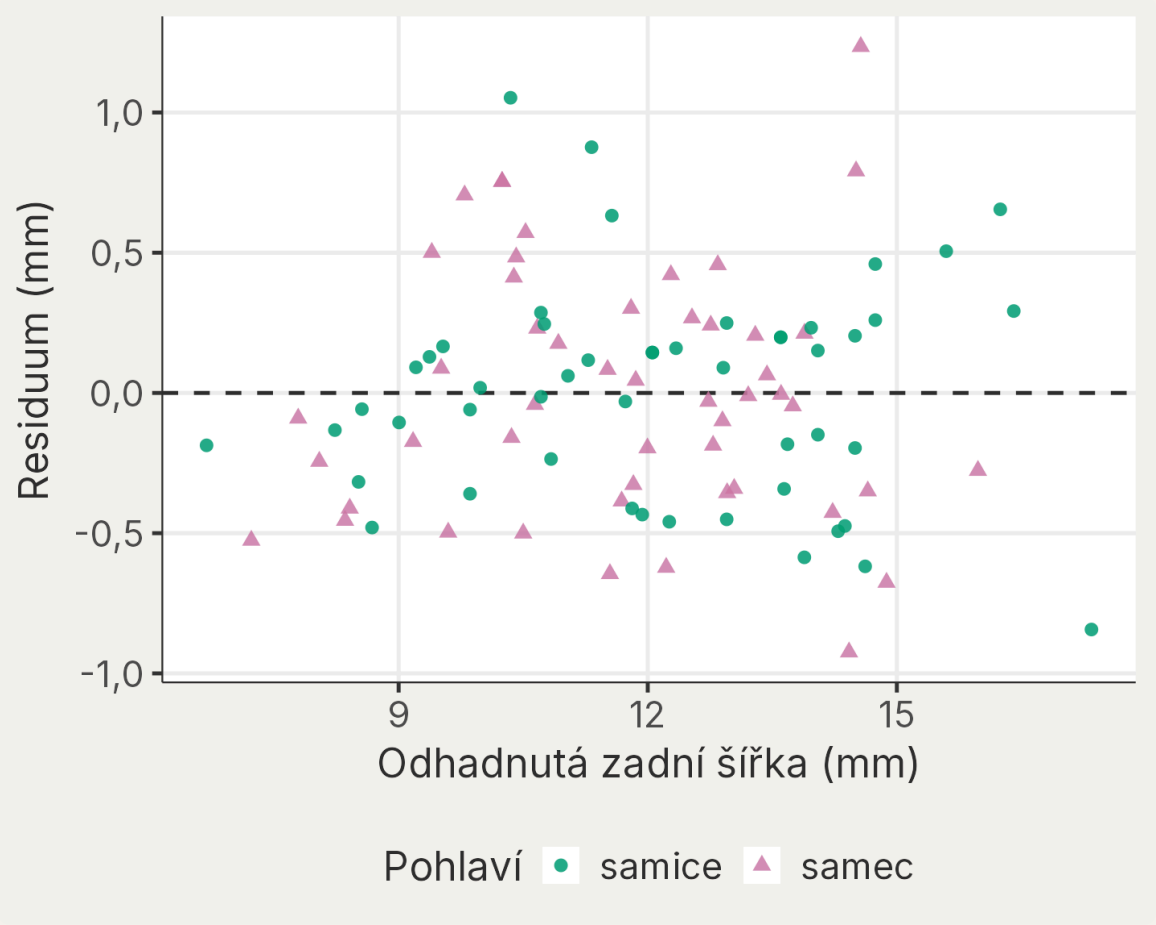
**A)** Ano, při každé délce.

**B)** Ne, pouze při délce 0 mm.

**C)** Ne, pouze při délce 30 mm.

Při jiné délce musíme přidat příspěvek interakčního koeficientu.

# Jak dobře přímky popisují změřené kraby?




Residua leží kolem nuly **bez oblouku** a s podobným rozptylem u malých i velkých krabů.

Graf neověří příčinu ani platnost mimo pozorované délky.

# Co víme o rozdílu mezi samicemi a samci modré formy?

Bude rozdíl v zadní šířce mezi stejně dlouhou samicí a samcem stejný u malých i velkých krabů?

**CO DATA UKAZUJÍ**

- Sklon samic 0,407, samců 0,282 mm/mm.
- Rozdíl samec − samice se mění o −0,124 mm na 1 mm délky (95% interval spolehlivosti −0,151 až −0,098).
- Při 30 mm: samec − samice −1,76 mm.

**CO ZŮSTÁVÁ OTEVŘENÉ**

- Proč se pohlaví liší: data jsou pozorovací.
- Platí to i pro kraby mimo tento vzorek?
- A pro kraby menší nebo větší, než jsme změřili?

# Když jsou oba prediktory skupiny

# Liší se rozdíl mezi pohlavími u modré a oranžové formy?



**ODEZVA**
Délka krunýře (mm)

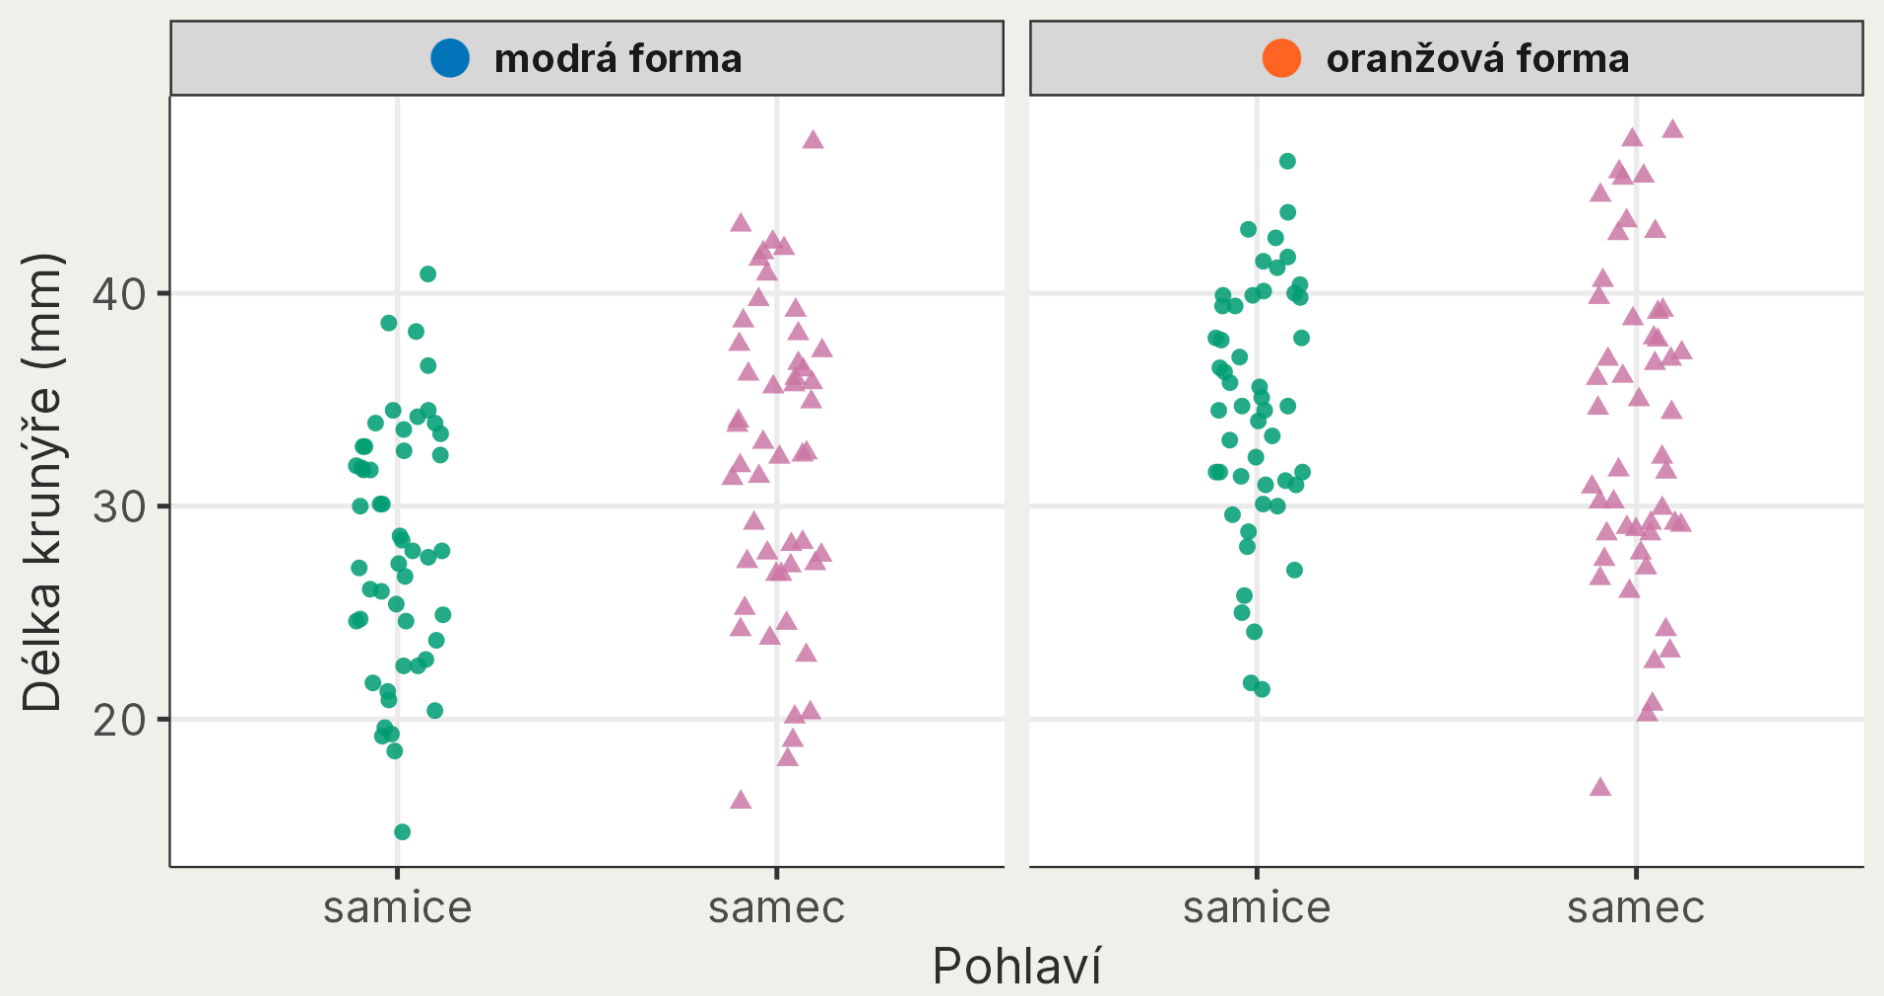
**DVA SKUPINOVÉ PREDIKTORY**
Barevná forma · pohlaví

Mění se rozdíl **samec – samice** mezi barevnými formami?

Do každé skupiny vybrali autoři stejný počet krabů, takže průměrné délky závisejí i na výběru.

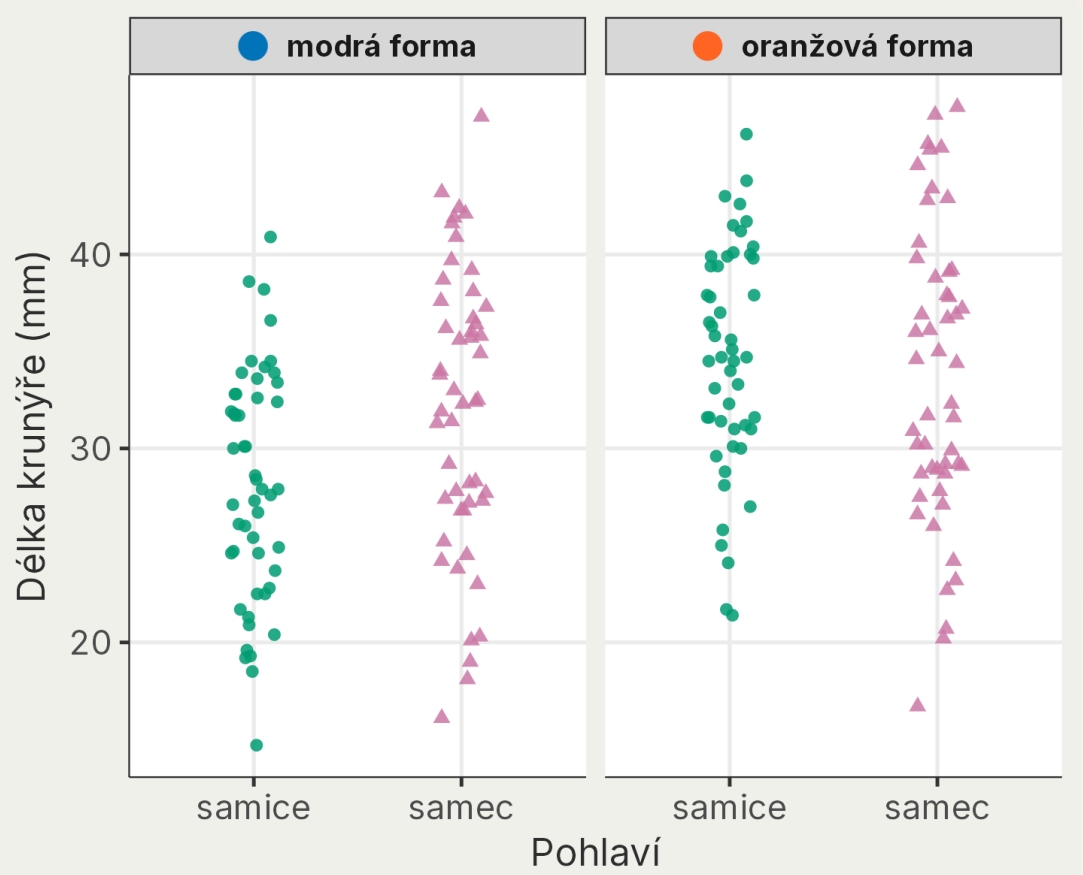
Ilustrace vytvořená pomocí AI.

# Jaké délky vidíme ve čtyřech skupinách?




Každý bod je jeden krab. Autoři vybrali do každé skupiny 50 krabů.

# Je rozdíl mezi samci a samicemi u obou forem stejný?

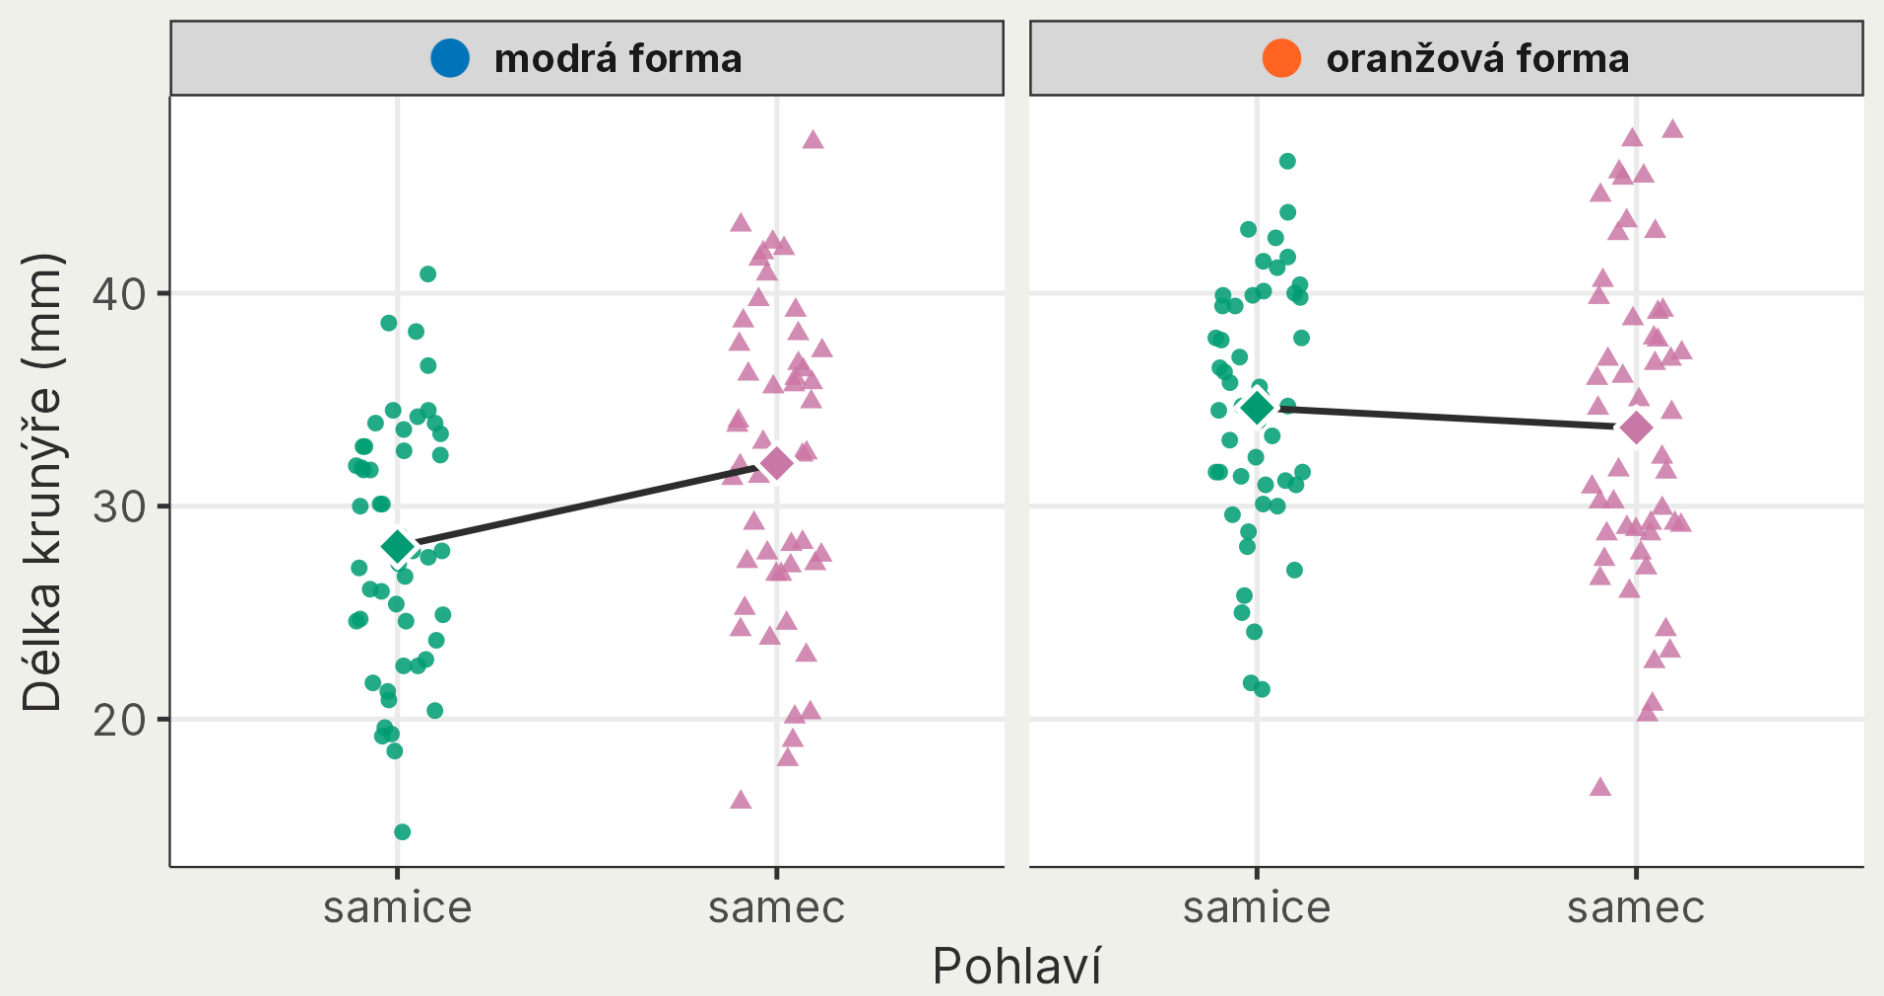



**MINUTA BEZ HOVORU**

Napište pro každou formu:

- kdo má vyšší průměr;
- zda čekáte podobně velký rozdíl;
- jednu větu, kterou z bodů říci nemůžeme.

# Průměry ukazují dva různé rozdíly




Body, osy i náhodné posunutí jsou stejné. Přibyly pouze průměry a spojnice.

# Jak velký je rozdíl samec minus samice v každé formě?

**MODRÁ FORMA**

$$32{,}01 - 28{,}10 = +\mathbf{3{,}91\ mm}$$

**ORANŽOVÁ FORMA**

$$33{,}69 - 34{,}62 = -\mathbf{0{,}93\ mm}$$

U modré formy jsou samci v průměru delší, u oranžové o něco kratší.

# Interakce je rozdíl dvou rozdílů

**Rozdíl dvou rozdílů** $\Delta$ = rozdíl u 🟠 oranžové formy − rozdíl u 🔵 modré formy

$$\Delta = (-0{,}93) - (+3{,}91) = \mathbf{-4{,}84\ mm}$$

Rozdíl mezi pohlavími se při přechodu od modré k oranžové formě změní o **−4,84 mm**.

# `forma * pohlavi` zapíše všechny čtyři kombinace

`forma + pohlavi + forma:pohlavi = forma * pohlavi`; referenční kombinace je modrá forma a samice.

```
mod_formy <-
  lm(
    formula = delka_krunyre_mm ~ forma * pohlavi,
    data = data_formy
  )

round(
  x = summary(object = mod_formy)$coefficients,
  digits = 3
)
```

```
                        Estimate Std. Error t value Pr(>|t|)
(Intercept)               28.102      0.950  29.584    0.000
formaoranžová              6.516      1.343   4.851    0.000
pohlavisamec               3.912      1.343   2.912    0.004
formaoranžová:pohlavisamec -4.842     1.900  -2.549    0.012
```

# Který údaj je rozdíl samec − samice v oranžové formě?

| Koeficient | Odhad (mm) |
|---|---|
| `(Intercept)` | 28,102 |
| `formaoranžová` | +6,516 |
| `pohlavisamec` | +3,912 |
| `formaoranžová:pohlavisamec` | −4,842 |

**A)** `pohlavisamec`

**B)** `formaoranžová:pohlavisamec`

**C)** `pohlavisamec` + `formaoranžová:pohlavisamec`

**D)** `formaoranžová`

+3,91 + (−4,84) = **−0,93 mm**: stejný rozdíl, jaký jsme spočítali z průměrů oranžové formy.

# Co znamená každý ze čtyř koeficientů?

`(Intercept)`: 🔵 modrá samice

28,10 mm

`pohlavisamec`: samec − samice v 🔵 modré formě

+3,91 mm

`formaoranžová`: 🟠 oranžová − 🔵 modrá mezi samicemi

+6,52 mm

`formaoranžová:pohlavisamec`: změna rozdílu mezi formami

−4,84 mm

95% interval spolehlivosti interakce: −8,59 až −1,10 mm

# Odhad pro každou ze čtyř skupin

```r
prumery_formy <-
  emmeans::emmeans(
    object = mod_formy,
    specs = ~ pohlavi | forma
  )

prumery_formy
```

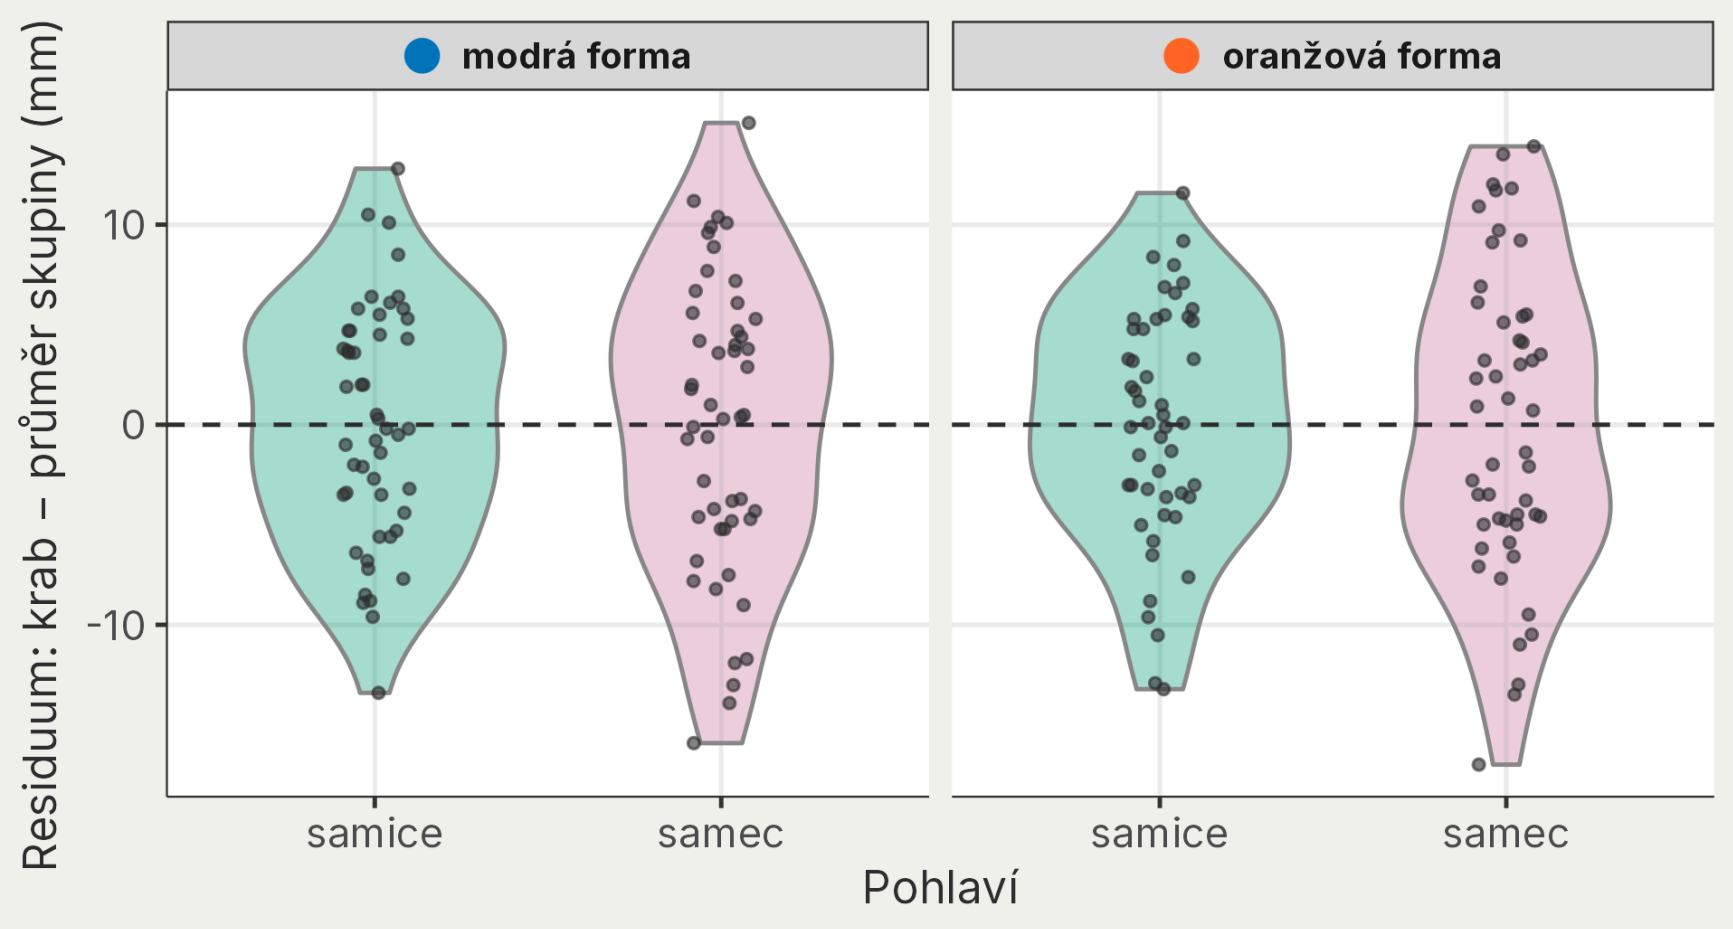
```
forma = modrá:
 pohlavi emmean   SE  df lower.CL upper.CL
 samice    28.1 0.95 196     26.2     30.0
 samec     32.0 0.95 196     30.1     33.9

forma = oranžová:
 pohlavi emmean   SE  df lower.CL upper.CL
 samice    34.6 0.95 196     32.7     36.5
 samec     33.7 0.95 196     31.8     35.6

Confidence level used: 0.95
```

Model má jeden parametr pro každou kombinaci, proto odhady odpovídají pozorovaným skupinovým průměrům.

# Residua jsou odchylky jednotlivých krabů od skupinových průměrů




Residuum = délka kraba – průměr jeho skupiny.

# Rozdíl mezi pohlavími závisí na barevné formě

- 🔵 Modrá forma: samec − samice = **+3,91 mm**
- 🟠 Oranžová forma: samec − samice = **−0,93 mm**
- Změna rozdílu: **−4,84 mm**; 95% interval spolehlivosti −8,59 až −1,10 mm

Průměrné délky závisejí i na tom, které kraby autoři vybrali. Výsledek popisuje tento soubor, ne velikost krabů v přírodě.

# Když jsou oba prediktory čísla

# Přibude vysokému stromu s každým centimetrem průměru víc dřeva?

**STŘEMCHA POZDNÍ**

- severoamerický, u nás invazní strom
- objem dřeva z **průměru kmene** a **výšky**
- 31 pokácených stromů, z amerických jednotek převedeno na cm, m a $m^3$

**VE DVOJICI**

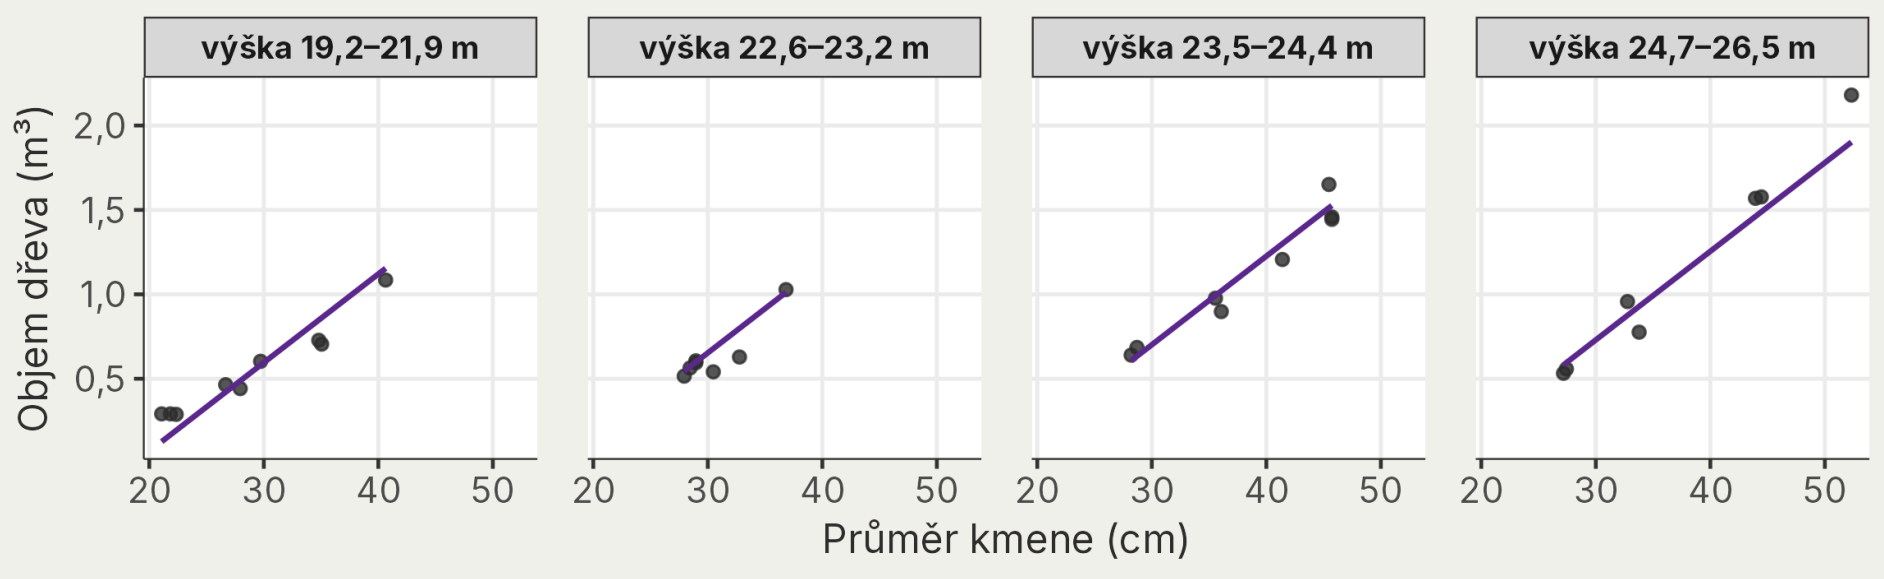
Dva stejně tlusté kmeny ztloustnou o 1 cm. Jeden strom je nízký, druhý vysoký.
Kterému přibude víc dřeva?

Vysokému: nová vrstva dřeva obalí delší kmen.

Meyer (1953), *Forest Mensuration* · `data/stromy.csv`

# Vystihne společný sklon nízké i vysoké stromy?

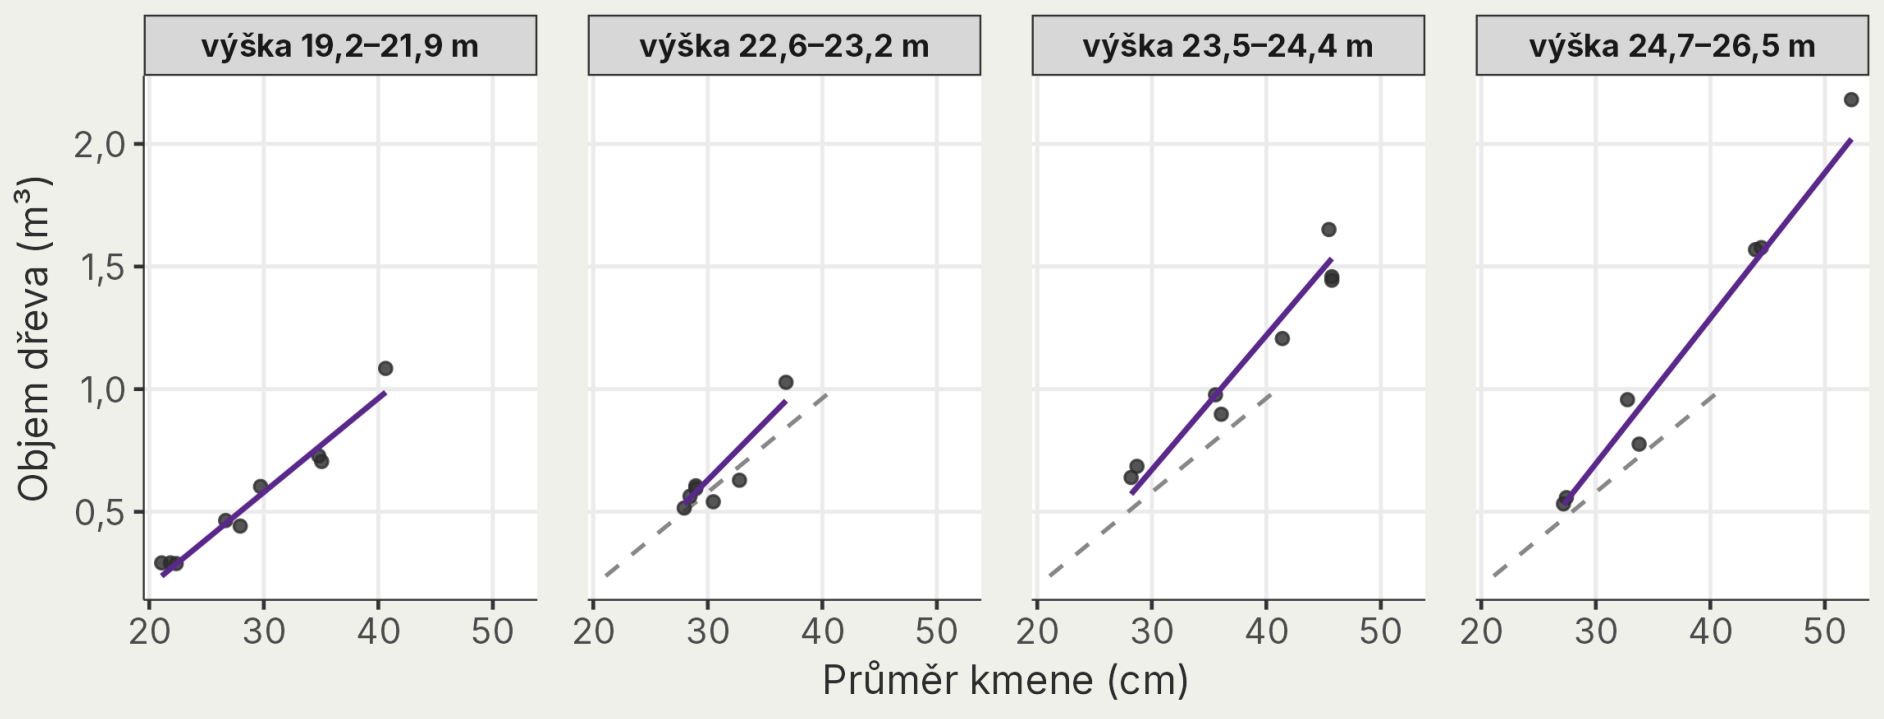
```
1  mod_aditivni <-
2    lm(
3      formula = objem_m3 ~ prumer_cm + vyska_m,
4      data = data_stromy
5    )
```




**Ve dvojici:** kde leží tenké a tlusté kmeny v krajních panelech?

Panel = výšková čtvrtina stromů · přímka = model při střední výšce panelu

# Mění se sklon přímky s výškou stromu?




**Čím vyšší strom, tím strmější přímka.**

Šedá přerušovaná = přímka nejnižšího panelu · sklon = m³ na 1 cm průměru

# `prumer_cm * vyska_m`: sklon průměru závisí na výšce

```
1  mod_stromy <-
2    lm(
3      formula = objem_m3 ~ prumer_cm * vyska_m,
4      data = data_stromy
5    )
6  round(x = coef(object = mod_stromy), digits = 5)
```

```
     (Intercept)         prumer_cm           vyska_m prumer_cm:vyska_m
         1.96508          -0.06528          -0.12050           0.00493
```

sklon průměru = `prumer_cm` + `prumer_cm:vyska_m` × výška

| Výška stromu | 21 m | 23 m | 25 m |
|---|---|---|---|
| Sklon průměru (m³ na 1 cm) | 0,038 | 0,048 | 0,058 |

# Pro který strom platí koeficient `prumer_cm`?

`prumer_cm` = **−0,065 m³ na 1 cm**

**A)** Pro každý změřený strom.

**B)** Jen pro nejnižší stromy v datech.

**C)** Pro žádný: tlustší kmen má méně dřeva.

**D)** Jen pro strom vysoký 0 m.

Takový strom v datech není. Sklon průměru proto uvádíme při zvolené výšce uvnitř dat.

# Co víme o stromech?

Přibude vysokému stromu s každým centimetrem průměru víc dřeva?

**CO DATA UKAZUJÍ**

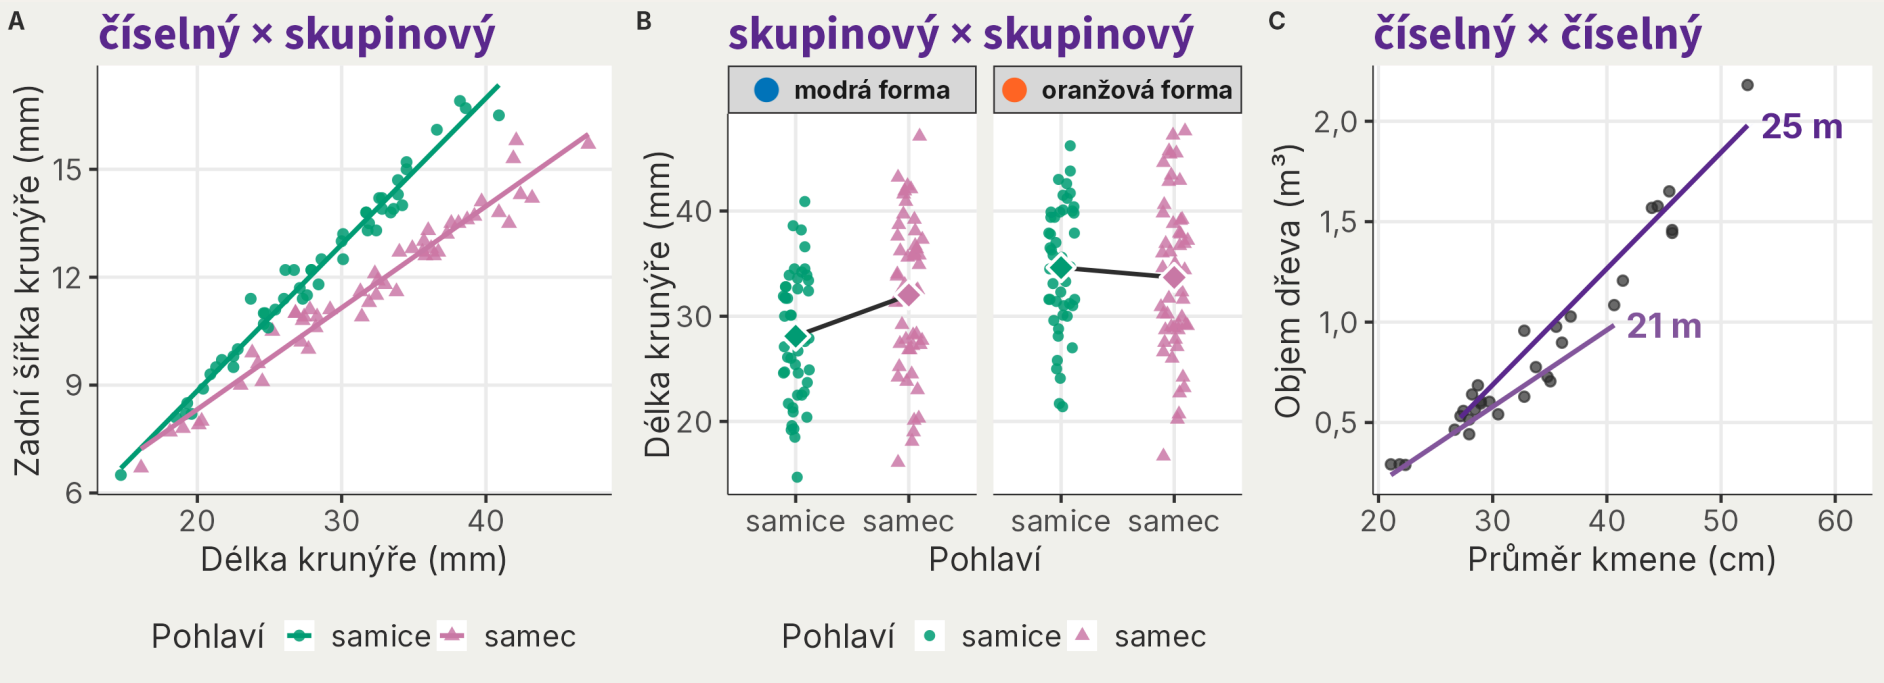
- Kmen 36 cm místo 28 cm podle modelu: **+0,31 m³** při 21 m, **+0,46 m³** při 25 m.
- Sklon průměru (m³ na 1 cm) roste o **0,0049** na každý 1 m výšky (95% interval spolehlivosti 0,0031 až 0,0068).

**CO ZŮSTÁVÁ OTEVŘENÉ**

- 31 stromů bez popsaného výběru.
- Rezidua ani vliv jednotlivých stromů jsme nekontrolovali.
- Nepopsal by vztah lépe zakřivený model?

# Jedna myšlenka, tři obrazy

# Interakce mění sklon nebo skupinový rozdíl




**Co se mění?** Rozdíl mezi přímkami podél osy délky.

**Co se mění?** Rozdíl mezi pohlavími podle formy.

**Co se mění?** Sklon průměru s výškou stromu.

# Co musíme doplnit, aby tvrzení o efektu bylo úplné?

**NEÚPLNÉ**

„Délka má efekt.“
„Samci jsou větší.“
„Průměr kmene má efekt.“

**OPRAVTE TVRZENÍ**

- Pro které pohlaví?
- Při jaké délce?
- V které barevné formě?
- Větší v jakém znaku?
- Při jaké výšce?

V modelu s interakcí vždy uvádíme hodnotu nebo úroveň druhého prediktoru.

# Jak číst model s interakcí?

**1. OTÁZKA**

Mění se vztah nebo rozdíl podle druhého prediktoru?

**2. DATA A PŘEDPOVĚDI**

Ukažte body a předpovědi pro konkrétní kombinace.

**3. KOEFICIENTY**

Hlavní koeficient platí v referenční skupině nebo při nule druhého prediktoru.

**4. ZÁVĚR**

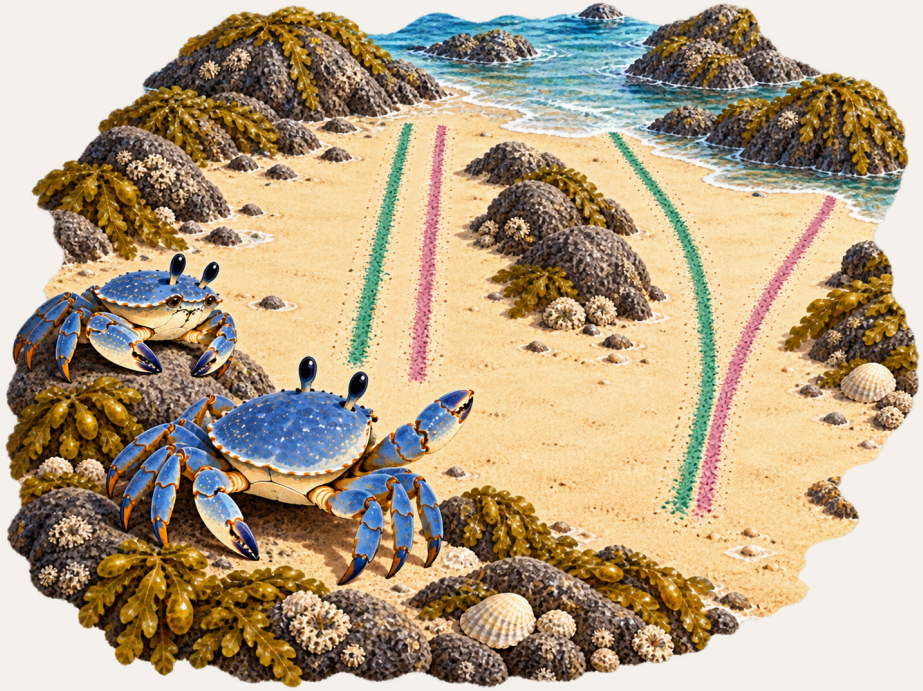
Jen v rozsahu dat a jako souvislost, ne příčina.

# Co si odnést

- Interakci potřebujeme, když vztah jednoho prediktoru závisí na druhém; podpořit ji má biologická otázka i graf.
- `x * y` je zkratka pro `x + y + x:y`.
- Hlavní koeficienty jsou podmíněné; skupiny porovnáváme pomocí předpovědí při zvolené hodnotě.
- U dvou skupinových prediktorů je interakce rozdíl dvou rozdílů.
- U dvou číselných prediktorů se sklon jednoho plynule mění s hodnotou druhého.
- Závěr omezujeme na pozorovaný rozsah a na souvislost v pozorovacích datech.

Data: Campbell, N. A. a Mahon, R. J. (1974) · Meyer, H. A. (1953) · `data/krabi.csv`, `data/stromy.csv`

# Který biologicky smysluplný model máme zvolit?



Ilustrace vytvořená pomocí AI.

### Aditivní kandidát

```
zadni_sirka_mm ~
delka_krunyre_mm + pohlavi
```

Stálý rozdíl

### Interakční kandidát

```
zadni_sirka_mm ~
delka_krunyre_mm * pohlavi
```

Měnící se rozdíl

Jak mezi kandidáty vybírat, ukáže následující lekce.

# Kde byste čekali interakci vy?

Uveďte biologickou otázku, u které byste čekali, že vztah dvou znaků závisí na skupině nebo na hodnotě jiného znaku.
Jak by vypadal graf?